Estadísticas y Data Science

EST108 | Ingeniería Comercial

Universidad Adolfo Ibáñez

Apuntes por **Agustín Miranda**

Primer semestre de 2026

Basado en el material de la profesora Florencia Darrigrandi.

Índice general

Introducción: ¿Qué es la estadística? **7**

1. Probabilidad **9**
1.1. ¿Qué es la probabilidad? . . . 9
1.2. ¿Qué es un experimento? . . . 9
1.3. Espacio muestral y eventos . . . 9
1.3.1. Operaciones entre eventos . . . 10
1.4. Interpretaciones de la probabilidad . . . 10
1.4.1. Interpretación clásica o equiprobable . . . 10
1.4.2. Interpretación frecuentista . . . 11
1.4.3. Interpretación subjetiva (bayesiana) . . . 11
1.5. Los axiomas de Kolmogorov . . . 12
1.5.1. Propiedades derivadas . . . 13
1.6. Probabilidad condicional . . . 15
1.6.1. Definición . . . 16
1.6.2. Regla de la multiplicación . . . 17
1.7. Independencia de eventos . . . 17
1.8. Probabilidad total y Teorema de Bayes . . . 19
1.8.1. Partición del espacio muestral . . . 19
1.8.2. Teorema de probabilidades totales . . . 19
1.8.3. Teorema de Bayes . . . 21

2. Variable aleatoria discreta **25**
2.1. ¿Qué es una variable aleatoria? . . . 25
2.2. Clasificación de las variables aleatorias . . . 26
2.3. Función de masa de probabilidad . . . 27
2.3.1. Propiedades . . . 28
2.4. Función de distribución acumulada . . . 29
2.4.1. Propiedades . . . 29
2.4.2. Cálculo de probabilidades con la FDA . . . 30
2.5. Valor esperado y varianza . . . 32
2.5.1. Valor esperado . . . 32
2.5.2. Varianza . . . 34

2.6. Distribuciones importantes 38
2.6.1. Distribución de Bernoulli 38
2.6.2. Distribución Binomial 41
2.6.3. Distribución de Poisson 43

3. Variable aleatoria continua **47**
3.1. De lo discreto a lo continuo 47
3.1.1. Del histograma a la densidad 47
3.1.2. El límite: de la suma a la integral 48
3.2. Función de densidad de probabilidad 49
3.3. Función de distribución acumulada 50
3.4. Valor esperado y varianza 52
3.5. Distribución Uniforme continua 53
3.6. Distribución Exponencial 55
3.7. Distribución Normal 58
3.7.1. ¿Por qué $\sqrt{2\pi}$? 59
3.7.2. La distribución Normal estándar 63

4. Muestreo y distribución de muestreo **67**
4.1. Población, muestra y parámetro 67
4.2. Muestra aleatoria 69
4.3. Estadístico y estimador 70
4.4. Propiedades de los estimadores puntuales 71
4.4.1. Insesgadez 71
4.4.2. Eficiencia 71
4.4.3. Consistencia 73
4.5. Función de verosimilitud e información de Fisher 73
4.5.1. Función de verosimilitud 74
4.5.2. Log-verosimilitud y función score 75
4.5.3. Información de Fisher 76
4.6. Teorema de Cramér-Rao 78
4.7. Por qué estas propiedades y no otras 80
4.7.1. Por qué la insesgadez 80
4.7.2. Por qué la eficiencia 81
4.7.3. Por qué la consistencia 81
4.7.4. Las tres propiedades como sistema coherente 81
4.8. La media muestral como estimador óptimo 82
4.9. Distribución muestral y Teorema del Límite Central 84

5. Introducción a la inferencia estadística **89**
5.1. Test de hipótesis 89
5.1.1. Hipótesis nula e hipótesis alternativa 90
5.1.2. La lógica del test: por qué partimos de H_0 90
5.1.3. Errores en el test de hipótesis 92
5.2. Estimación por intervalos de confianza 93
5.3. Pruebas de hipótesis 93
5.3.1. El procedimiento de cinco pasos 93
5.3.2. Prueba para la media con varianza conocida 93
5.3.3. Prueba para la media con varianza desconocida 93

Introducción: ¿Qué es la estadística?

—El término «estadística» deriva del latín *statisticum collegium* (consejo de Estado), y de la palabra italiana *statista* («hombre de estado», «político» o «estadista»). Pero su uso contemporáneo fue acuñado por el historiador y jurista alemán Gottfried Achenwall en 1749 para referirse al análisis de datos acerca del Estado, significando «ciencia del Estado».

Durante el siglo XIX e inicios del XX, el término se fue transformando en una disciplina matemática propiamente rigurosa bajo el trabajo de Francis Galton, Karl Pearson, Ronald Fisher, entre otros que acuñaron los métodos estadísticos modernos que conocemos hoy en día.

De esta manera, podemos definir a la estadística como la ciencia de recolectar, analizar, presentar e interpretar datos.

Tema 1

Probabilidad

1.1 ¿Qué es la probabilidad?

La probabilidad es el lenguaje matemático para cuantificar la incertidumbre.

1.2 ¿Qué es un experimento?

Un experimento es el modelo matemático para cualquier procedimiento que puede ser repetido infinitamente y tiene un conjunto de posibles resultados, que conocemos como:

1.3 Espacio muestral y eventos

Definición 1.1 — Espacio muestral

El espacio muestral (denotado usualmente Ω o S) es el conjunto de **todos los resultados posibles** de un experimento aleatorio.

Definición formal:

$$\Omega = \{\omega : \omega \text{ es un resultado posible del experimento}\}$$

Cada elemento $\omega \in \Omega$ se llama **punto muestral** o **resultado elemental**.

Los subconjuntos de Ω son llamados **eventos**. Dado que los eventos son subconjuntos de Ω, las operaciones de la teoría de conjuntos —unión, intersección y complemento— se aplican directamente, adquiriendo aquí una interpretación probabilística:

1.3.1 Operaciones entre eventos

Ω	Espacio muestral
ω	Resultado (punto o elemento)
A	Evento (subconjunto de Ω)
A^c	Complemento de A (no A)
$A \cup B$	Unión (A o B)
$A \cap B$ o AB	Intersección (A y B)
$A - B$	Diferencia (ω en A pero no en B)
$A \subset B$	Inclusión (A implica B)
$\emptyset$	Evento imposible (siempre falso)
Ω	Evento seguro (siempre verdadero)
$A \cap B = \emptyset$	A y B son mutuamente excluyentes

1.4 Interpretaciones de la probabilidad

Antes de formalizar la probabilidad, es útil preguntarse qué *significa* que un evento tenga probabilidad p. Existen tres respuestas clásicas a esta pregunta, cada una con supuestos y limitaciones distintas.

1.4.1 Interpretación clásica o equiprobable

Definición 1.2 — Espacio equiprobable

Un espacio muestral Ω es **equiprobable** si todos sus elementos tienen igual probabilidad de ocurrir. En este caso, la probabilidad de un evento A se define como:

$$P(A) = \frac{\#A}{\#\Omega} = \frac{\text{casos favorables}}{\text{casos totales}}$$

donde $\#A$ denota la cardinalidad del conjunto A.

Esta interpretación es la más antigua, se remonta a los trabajos del matemático francés Pierre-Simon Laplace (1749-1827) sobre juegos de azar, y es la que se aplica naturalmente cuando todos los resultados del experimento son igualmente posibles: lanzar una moneda justa, tirar un dado equilibrado, extraer una carta de una baraja bien mezclada.

Observación. *La condición de equiprobabilidad debe justificarse, no asumirse. Un error común es definir el espacio muestral de forma que los elementos no sean igualmente probables y luego aplicar la fórmula de Laplace de todos modos. Por*

ejemplo, si una urna contiene 4 fichas con el número 1 y 2 fichas con el número 2, el espacio muestral correcto es $\Omega = \{1_a, 1_b, 1_c, 1_d, 2_a, 2_b\}$ *con* $\#\Omega = 6$*, y no* $\Omega = \{1, 2\}$ *con* $\#\Omega = 2$*, pues en este último los elementos no son equiprobables.*

1.4.2 Interpretación frecuentista

La interpretación frecuentista define la probabilidad de un evento A como el límite de su frecuencia relativa cuando el experimento se repite un número muy grande de veces bajo condiciones idénticas:

$$P(A) = \lim_{n\to\infty} \frac{n_A}{n}$$

donde n es el número total de repeticiones y n_A es el número de veces que ocurrió A.

Esta es la interpretación que subyace a la estadística aplicada: si lanzamos una moneda 10.000 veces y obtenemos cara en 5.032 de ellas, estimamos $P(\text{cara}) \approx 0.5$. A mayor número de repeticiones, mejor la estimación.

Observación. *La interpretación frecuentista tiene una limitación fundamental: exige que el experimento sea repetible en condiciones idénticas. Esto la hace inaplicable a eventos únicos o irrepetibles — como la probabilidad de que llueva mañana en Santiago, o de que una empresa quiebre el próximo año — para los cuales no existe una frecuencia relativa observable.*

1.4.3 Interpretación subjetiva (bayesiana)

La interpretación subjetiva define la probabilidad como un **grado de creencia racional** sobre la ocurrencia de un evento, basado en la información disponible. No requiere repetición del experimento ni equiprobabilidad de los resultados.

Bajo esta visión, dos agentes con información distinta pueden asignar probabilidades distintas al mismo evento sin que ninguno esté "equivocado". Lo que se exige es que las creencias sean *coherentes*, es decir, que satisfagan los axiomas de Kolmogórov que presentaremos en la siguiente sección.

Observación. *Las tres interpretaciones no son mutuamente excluyentes en la práctica. La interpretación clásica es un caso especial de la frecuentista bajo simetría perfecta; y la frecuentista puede entenderse como un caso especial de la subjetiva cuando la evidencia empírica es abrumadora. Lo que unifica las tres es que, en todos los casos, la función* P *debe satisfacer los axiomas que veremos en la sección 1.1.*

1.5 Los axiomas de Kolmogorov

Los axiomas de probabilidad son las condiciones mínimas que deben verificarse para que una función definida sobre un conjunto de sucesos determine consistentemente sus probabilidades. Fueron formulados por el matemático soviético Andréi Kolmogórov en 1933. Y estos son:

Sea Ω un espacio muestral y $\mathcal{A}$ una σ-álgebra de subconjuntos de Ω.

Definición 1.3 — σ-álgebra

Sea Ω un espacio muestral. Una **σ-álgebra** $\mathcal{A}$ sobre Ω es una colección de subconjuntos de Ω que satisface las siguientes tres propiedades:

S1) $\Omega \in \mathcal{A}$.

S2) Si $A \in \mathcal{A}$, entonces $A^c \in \mathcal{A}$ (cerrada bajo complementos).

S3) Si $A_1, A_2, \ldots \in \mathcal{A}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$ (cerrada bajo uniones contables).

A los elementos de $\mathcal{A}$ los llamamos **eventos**, y a la terna $(\Omega, \mathcal{A})$ se la denomina **espacio medible**.

En la práctica, para espacios muestrales finitos o contables, $\mathcal{A}$ corresponde simplemente al conjunto de todos los subconjuntos posibles de Ω — también llamado *conjunto potencia* y denotado 2^{Ω} — por lo que no es necesario preocuparse por esta distinción. La σ-álgebra cobra importancia técnica en espacios continuos, donde no todos los subconjuntos de Ω admiten una asignación de probabilidad consistente.

A los elementos de $\mathcal{A}$ los llamamos **eventos** o **sucesos**, y más precisamente **conjuntos $\mathcal{A}$-medibles**. A la terna $(\Omega, \mathcal{A})$ se la denomina **espacio medible** o **espacio probabilizable**, según el contexto.

Corolario de S1 y S2: $\emptyset \in \mathcal{A}$, pues $\emptyset = \Omega^c$ y $\Omega \in \mathcal{A}$ por S1, luego S2 garantiza que $\Omega^c = \emptyset \in \mathcal{A}$.

Axioma 1.1 — Axiomas de Kolmogórov

Una función $P : \mathcal{A} \longrightarrow \mathbb{R}$ es una **función de probabilidad** sobre $(\Omega, \mathcal{A})$ si se cumplen los siguientes axiomas:

A1) La probabilidad de cualquier suceso S es no negativa:

$$P(S) \geq 0 \quad \forall S \in \mathcal{A}.$$

A2) La probabilidad del suceso seguro es igual a uno:

$$P(\Omega) = 1.$$

A3) Si $\{S_n\}_{n\in\mathbb{N}} \subseteq \mathcal{A}$ son sucesos mutuamente excluyentes, es decir, $S_i \cap S_j = \emptyset \quad \forall i \neq j$, entonces:

$$P\left(\bigcup_{n=1}^{\infty} S_n\right) = \sum_{n=1}^{\infty} P(S_n).$$

A la terna $(\Omega, \mathcal{A}, P)$ se la denomina **espacio de probabilidad**, esto es, un espacio de sucesos (espacio muestral) en el que se han definido los posibles sucesos a considerar (la σ-álgebra de sucesos) y la probabilidad de cada suceso (la función de probabilidad).

Una vez establecidos los tres axiomas, podemos nombrar formalmente el objeto que hemos construido.

Definición 1.4 — Espacio de probabilidad

Un **espacio de probabilidad** es una terna $(\Omega, \mathcal{A}, P)$ donde:

- Ω es el espacio muestral,
- $\mathcal{A}$ es una σ-álgebra sobre Ω (véase Definición 1.3),
- $P : \mathcal{A} \to [0, 1]$ es una función de probabilidad que satisface los axiomas A1, A2 y A3.

El espacio de probabilidad $(\Omega, \mathcal{A}, P)$ es el objeto matemático fundamental sobre el que descansa toda la teoría. Cualquier noción probabilística que desarrollemos — variables aleatorias, esperanza, independencia — vive dentro de este marco.

1.5.1 Propiedades derivadas

De los axiomas de Kolmogórov se deducen las siguientes propiedades. A diferencia de los axiomas, estas no se asumen sino que se *demuestran*.

Proposición 1.1 — Probabilidad del complemento

Para cualquier evento $A \in \mathcal{A}$:

$$P(A^c) = 1 - P(A)$$

Demostración. Como A y A^c son mutuamente excluyentes y $A \cup A^c = \Omega$, por A3:

$$P(A \cup A^c) = P(A) + P(A^c)$$

Por A2, $P(\Omega) = 1$, luego $1 = P(A) + P(A^c)$, de donde:

$$P(A^c) = 1 - P(A)$$

■

Proposición 1.2 — Probabilidad del evento imposible

$$P(\emptyset) = 0$$

Demostración. Basta notar que $\emptyset = \Omega^c$. Aplicando la proposición anterior:

$$P(\emptyset) = P(\Omega^c) = 1 - P(\Omega) = 1 - 1 = 0$$

■

Proposición 1.3 — Monotonía y diferencia de eventos

Si $A \subset B$, entonces:

$$P(A) \leq P(B) \qquad \text{y} \qquad P(B - A) = P(B) - P(A)$$

Demostración. Si $A \subset B$, entonces B puede descomponerse como unión disjunta:

$$B = A \cup (B - A), \qquad A \cap (B - A) = \emptyset$$

Por A3:

$$P(B) = P(A) + P(B - A)$$

Como por A1 $P(B - A) \geq 0$, se sigue que $P(A) \leq P(B)$. Despejando:

$$P(B - A) = P(B) - P(A)$$

■

Proposición 1.4 — Aditividad general (regla de la suma)

Para cualquier par de eventos $A, B \in \mathcal{A}$:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Demostración. Descomponemos $A \cup B$ en tres partes mutuamente excluyentes:

$$A \cup B = (A - B) \cup (A \cap B) \cup (B - A)$$

Por A3:

$$P(A \cup B) = P(A - B) + P(A \cap B) + P(B - A)$$

Aplicando la proposición anterior a $A \cap B \subset A$ y $A \cap B \subset B$:

$$P(A - B) = P(A) - P(A \cap B), \qquad P(B - A) = P(B) - P(A \cap B)$$

Sustituyendo:

$$P(A \cup B) = P(A) - P(A \cap B) + P(A \cap B) + P(B) - P(A \cap B)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

■

Propiedad	**Expresión**	**Condición**
Complemento	$P(A^c) = 1 - P(A)$	—
Evento imposible	$P(\emptyset) = 0$	—
Monotonía	$P(A) \leq P(B)$	$A \subset B$
Diferencia	$P(B - A) = P(B) - P(A)$	$A \subset B$
Regla de la suma	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$	—

1.6 Probabilidad condicional

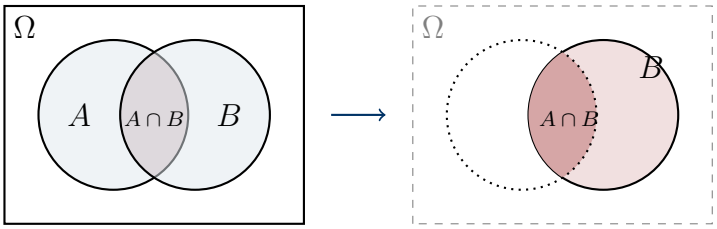
Hasta ahora hemos calculado probabilidades sobre el espacio muestral completo Ω. Sin embargo, muchas veces disponemos de información parcial: sabemos que cierto evento B *ya ocurrió*, y queremos actualizar la probabilidad de otro evento A a la luz de ese conocimiento.

Motivación: la reducción del espacio muestral

La idea central es la siguiente. Si sabemos con certeza que B ocurrió, entonces los resultados fuera de B dejan de ser posibles. En efecto, nuestro universo de referencia se **reduce** de Ω a B: el evento B pasa a funcionar como un nuevo espacio muestral.

Dentro de este universo reducido, la única parte de A que sigue siendo relevante es la que cae dentro de B, es decir, $A \cap B$. La figura 1.1 ilustra esta reducción.

Ahora bien, para que las probabilidades dentro de este nuevo universo B vuelvan a sumar 1, debemos *re-escalar* dividiendo por $P(B)$. Esto motiva la siguiente definición.



Sin condicionar Condicionado en B

Figura 1.1: Al condicionar en B, el espacio muestral se reduce de Ω a B. Lo único relevante de A pasa a ser $A \cap B$.

1.6.1 Definición

Definición 1.5 — Probabilidad condicional

Sean A y B dos eventos con $P(B) \neq 0$. La **probabilidad condicional de A dado B** se define como:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

La condición $P(B) \neq 0$ es esencial: no tiene sentido condicionar en un evento que no puede ocurrir, pues el universo reducido sería vacío.

Observación. *La probabilidad condicional $P(\cdot \mid B)$ es, ella misma, una función de probabilidad legítima sobre el espacio reducido: satisface los tres axiomas de Kolmogórov. En particular, $P(B \mid B) = 1$, lo que confirma que B actúa como el nuevo evento seguro.*

Demostración. Verificamos los tres axiomas para $P(\cdot \mid B)$:

A1 — No negatividad: Sea $A \in \mathcal{A}$. Como $A \cap B \subseteq B$ y P satisface A1, tenemos $P(A \cap B) \geq 0$. Como además $P(B) > 0$ por hipótesis:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \geq 0$$

A2 — Normalización:

$$P(\Omega \mid B) = \frac{P(\Omega \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1$$

donde usamos que $\Omega \cap B = B$.

A3 — Aditividad contable: Sean $A_1, A_2, \ldots \in \mathcal{A}$ eventos mutuamente excluyentes. Entonces los eventos $A_1 \cap B,\ A_2 \cap B, \ldots$ también son mutuamente excluyentes,

pues:

$$(A_i \cap B) \cap (A_j \cap B) = (A_i \cap A_j) \cap B = \emptyset \cap B = \emptyset \quad \forall\, i \neq j$$

Aplicando A3 de Kolmogórov a la función P original:

$$P\left(\bigcup_{n=1}^{\infty} A_n \;\middle|\; B\right) = \frac{P((\bigcup_{n=1}^{\infty} A_n) \cap B)}{P(B)} = \frac{P(\bigcup_{n=1}^{\infty}(A_n \cap B))}{P(B)} = \frac{\sum_{n=1}^{\infty} P(A_n \cap B)}{P(B)} = \sum_{n=1}^{\infty} P(A_n \mid B)$$

donde usamos la distributividad de la intersección sobre la unión. ■

1.6.2 Regla de la multiplicación

Despejando $P(A \cap B)$ de la definición anterior obtenemos una identidad muy útil para calcular probabilidades de intersecciones:

Proposición 1.5 — Regla de la multiplicación

Sean A y B dos eventos con $P(B) \neq 0$. Entonces:

$$P(A \cap B) = P(A \mid B) \cdot P(B)$$

Demostración. Despejando $P(A \cap B)$ directamente de la Definición 1.5:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \implies P(A \cap B) = P(A \mid B) \cdot P(B)$$

■

Esta regla es especialmente útil en experimentos secuenciales —por ejemplo, extracciones sucesivas sin reposición— donde la probabilidad de cada etapa depende del resultado de la anterior.

1.7 Independencia de eventos

Al estudiar la probabilidad condicional, vimos que $P(A \mid B)$ cuantifica cómo el conocimiento de B modifica la probabilidad de A. Surge entonces una pregunta natural: ¿qué ocurre cuando ese conocimiento no modifica nada? Es decir, ¿cuándo saber que B ocurrió es completamente irrelevante para A?

Definición 1.6 — Independencia de eventos

Sean A y B dos eventos con $P(B) \neq 0$. Decimos que A y B son **independientes** si:

$$P(A \mid B) = P(A)$$

Es decir, el conocimiento de que B ocurrió no altera la probabilidad de A.

Observación. *Esta definición exige $P(B) \neq 0$ para que $P(A \mid B)$ esté definida. La proposición siguiente elimina esa restricción y constituye el criterio operacional que se usa en la práctica.*

Proposición 1.6 — Criterio de independencia

Sean A y B dos eventos. A y B son independientes si y solo si:

$$P(A \cap B) = P(A) \cdot P(B)$$

Demostración. Partimos de la definición de independencia $P(A \mid B) = P(A)$ y aplicamos la regla de la multiplicación (Proposición 1.5):

$$P(A \cap B) = P(A \mid B) \cdot P(B) = P(A) \cdot P(B)$$

■

Esta caracterización es más general que la definición porque no requiere $P(B) \neq 0$, y es simétrica en A y B — lo que hace evidente que si A es independiente de B, entonces B es independiente de A.

Observación. ***Independencia vs. exclusión mutua.*** *Estos conceptos son frecuentemente confundidos, pero son casi opuestos. Si A y B son mutuamente excluyentes ($A \cap B = \emptyset$) y ambos tienen probabilidad positiva, entonces:*

$$P(A \cap B) = 0 \neq P(A) \cdot P(B)$$

luego no son independientes. De hecho, la exclusión mutua implica la máxima dependencia posible: saber que A ocurrió hace imposible que ocurra B.

Proposición 1.7 — Independencia de complementos

Si A y B son independientes, entonces A^c y B^c también son independientes.

Demostración. Por la Proposición 1.6, basta mostrar que $P(A^c \cap B^c) = P(A^c) \cdot P(B^c)$.

Observamos primero que $A^c \cap B^c = (A \cup B)^c$ por las leyes de De Morgan. Luego, usando la Proposición 1.1 y la regla de la suma (Proposición 1.4):

$$P(A^c \cap B^c) = P((A \cup B)^c) = 1 - P(A \cup B)$$

$$= 1 - P(A) - P(B) + P(A \cap B)$$

Como A y B son independientes, $P(A \cap B) = P(A) \cdot P(B)$:

$$= 1 - P(A) - P(B) + P(A) \cdot P(B)$$

Factorizando:

$$= (1 - P(A))(1 - P(B)) = P(A^c) \cdot P(B^c)$$

■

1.8 Probabilidad total y Teorema de Bayes

1.8.1 Partición del espacio muestral

Definición 1.7 — Partición

Una colección de eventos $A_1, A_2, \ldots, A_k$ constituye una **partición** del espacio muestral Ω si satisface:

P1) Son **mutuamente excluyentes**: $A_i \cap A_j = \emptyset$ para todo $i \neq j$.

P2) Son **exhaustivos**: $\bigcup_{i=1}^{k} A_i = \Omega$.

Intuitivamente, una partición divide a Ω en piezas que no se solapan y que, en conjunto, lo cubren por completo. Exactamente uno de los eventos A_i ocurre siempre.

1.8.2 Teorema de probabilidades totales

A veces no es posible calcular $P(B)$ de manera directa, pero sí conocemos cómo se comporta B dentro de cada pieza de una partición. El teorema de probabilidades totales permite recomponer $P(B)$ a partir de esa información parcial.

La idea geométrica se aprecia en la figura 1.2: la partición $\{A_1, A_2, A_3\}$ divide a Ω en franjas, y el evento B queda automáticamente descompuesto en las piezas disjuntas $B \cap A_1$, $B \cap A_2$ y $B \cap A_3$.

Teorema 1.1 — Probabilidades totales

Sea $A_1, A_2, \ldots, A_k$ una partición de Ω con $P(A_i) > 0$ para todo i. Entonces,

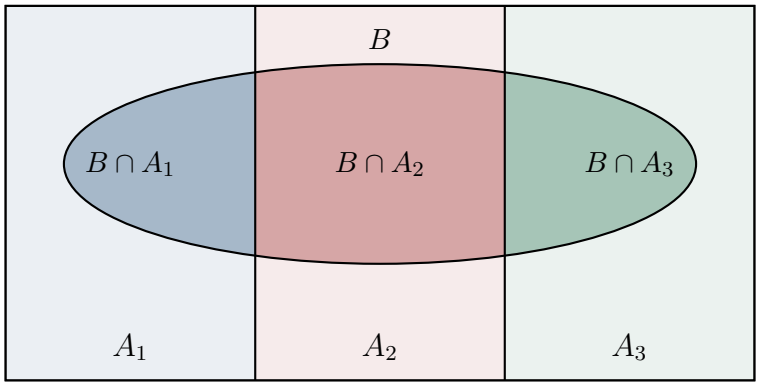


Figura 1.2: La partición $\{A_1, A_2, A_3\}$ descompone al evento B en las piezas disjuntas $B \cap A_i$.

para cualquier evento B:

$$P(B) = \sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)$$

Demostración. La demostración consta de tres pasos.

Paso 1 — Descomposición de B. Como los A_i son exhaustivos, $B = B \cap \Omega = B \cap \left(\bigcup_{i=1}^{k} A_i\right)$. Por distributividad:

$$B = \bigcup_{i=1}^{k} (B \cap A_i)$$

Paso 2 — Aditividad. Como los A_i son mutuamente excluyentes, también lo son los eventos $B \cap A_i$:

$$(B \cap A_i) \cap (B \cap A_j) = B \cap (A_i \cap A_j) = B \cap \emptyset = \emptyset \quad \forall\, i \neq j$$

Aplicando el axioma A3:

$$P(B) = \sum_{i=1}^{k} P(B \cap A_i)$$

Paso 3 — Regla de la multiplicación. Aplicando la Proposición 1.5 a cada término:

$$P(B \cap A_i) = P(B \mid A_i)\, P(A_i)$$

Sustituyendo:

$$P(B) = \sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)$$

■

Observación. *El teorema puede leerse como un* ***promedio ponderado****: la probabilidad total de B es el promedio de las probabilidades condicionales $P(B \mid A_i)$, donde cada una se pondera por el "peso" $P(A_i)$ de su pieza en la partición.*

1.8.3 Teorema de Bayes

El teorema de probabilidades totales responde a la pregunta: ¿cuál es la probabilidad de B? El teorema de Bayes responde la pregunta *inversa*: si observamos que B ocurrió, ¿cuál es la probabilidad de que la pieza responsable haya sido A?

Versión simple: dos eventos

Comencemos con el caso más sencillo, en que la partición consta de un evento A y su complemento A^c.

Teorema 1.2 — Regla de Bayes (forma simple)

Sean A y B dos eventos con $P(A) > 0$ y $P(B) > 0$. Entonces:

$$P(A \mid B) = \frac{P(B \mid A)\, P(A)}{P(B)}$$

Demostración. Por la definición de probabilidad condicional aplicada a $P(A \mid B)$, y luego la regla de la multiplicación en el numerador:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B \mid A)\, P(A)}{P(B)}$$

■

Esta forma es la más fácil de memorizar y expone la idea esencial: el teorema **invierte** la condicional, permitiéndonos pasar de $P(B \mid A)$ a $P(A \mid B)$.

Versión general: una partición

Cuando disponemos de una partición completa $A_1, \ldots, A_k$ y no conocemos $P(B)$ directamente, podemos expandir el denominador mediante el teorema de probabilidades totales. Esto da la forma general.

Teorema 1.3 — Regla de Bayes (forma general)

Sea $A_1, A_2, \ldots, A_k$ una partición de Ω con $P(A_i) > 0$ para todo i, y sea B un evento con $P(B) > 0$. Entonces, para cada j:

$$P(A_j \mid B) = \frac{P(B \mid A_j)\, P(A_j)}{\sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)}$$

Demostración. Partimos de la forma simple aplicada a A_j:

$$P(A_j \mid B) = \frac{P(B \mid A_j)\, P(A_j)}{P(B)}$$

y reemplazamos el denominador $P(B)$ por su expresión según el Teorema 1.1 de probabilidades totales:

$$P(A_j \mid B) = \frac{P(B \mid A_j)\, P(A_j)}{\sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)}$$

■

Observación. *La forma simple es el caso particular de la general con $k = 2$, tomando $A_1 = A$ y $A_2 = A^c$. En efecto, el denominador se convierte en $P(B \mid A)\, P(A) + P(B \mid A^c)\, P(A^c) = P(B)$.*

Interpretación geométrica y un ejemplo concreto

La forma simple de Bayes tiene una lectura geométrica muy intuitiva, que además revela *por qué* la fórmula es válida. La clave está en que la probabilidad de la intersección $P(A \cap B)$ puede calcularse de dos maneras distintas, según el orden en que descompongamos:

$$P(A \cap B) = P(B \mid A)\, P(A) = P(A \mid B)\, P(B)$$

Igualando las dos expresiones y despejando $P(A \mid B)$ se obtiene directamente el teorema de Bayes. Toda la fuerza del resultado descansa en esta simple identidad.

Consideremos un ejemplo concreto. Supongamos un grupo de 12 personajes, cada uno de los cuales puede ser un asesino (A) o no (A^c), y puede comportarse de manera sospechosa (B) o no (B^c). La siguiente tabla de contingencia resume cuántos hay de cada tipo:

De la tabla leemos directamente:

$$P(A) = \tfrac{4}{12}, \quad P(B) = \tfrac{5}{12}, \quad P(B \mid A) = \tfrac{3}{4}, \quad P(A \mid B) = \tfrac{3}{5}, \quad P(A \cap B) = \tfrac{3}{12}$$

	B	B^c	suma
A	**3**	**1**	4
A^c	**2**	**6**	8
suma	5	7	12

Figura 1.3: Tabla de contingencia: hay 3 asesinos sospechosos, 1 asesino no sospechoso, 2 no asesinos sospechosos y 6 no asesinos no sospechosos.

Ahora bien, la identidad geométrica se aprecia en la figura 1.4: el área del rectángulo $A \cap B$ es la misma sin importar cómo la construyamos. A la izquierda la obtenemos tomando primero la fracción $P(A)$ y luego, dentro de ella, la fracción $P(B \mid A)$. A la derecha tomamos primero $P(B)$ y luego $P(A \mid B)$. Ambos caminos llegan al mismo rectángulo.

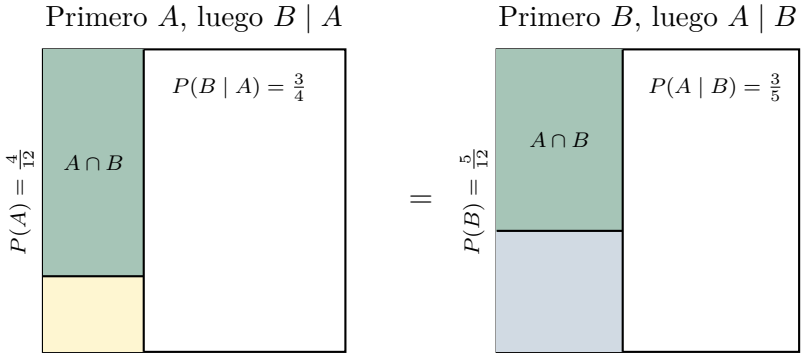


Figura 1.4: El área de $A \cap B$ se construye de dos formas: $P(A)\,P(B \mid A)$ (izquierda) y $P(B)\,P(A \mid B)$ (derecha). Como ambas dan la misma área, igualarlas produce el teorema de Bayes.

Verifiquémoslo numéricamente. Por la izquierda:

$$P(B \mid A)\,P(A) = \tfrac{3}{4} \cdot \tfrac{4}{12} = \tfrac{3}{12}$$

Por la derecha:

$$P(A \mid B)\,P(B) = \tfrac{3}{5} \cdot \tfrac{5}{12} = \tfrac{3}{12}$$

Ambas coinciden, como debía ser. Y despejando $P(A \mid B)$ de la igualdad recuperamos Bayes:

$$P(A \mid B) = \frac{P(B \mid A)\,P(A)}{P(B)} = \frac{\frac{3}{4} \cdot \frac{4}{12}}{\frac{5}{12}} = \frac{3}{5}$$

que es exactamente el valor que habíamos leído directamente de la tabla.

Observación. *El teorema de Bayes es la herramienta formal que permite* ***invertir***

condicionales: pasar de $P(B \mid A_j)$ —lo que típicamente conocemos— a $P(A_j \mid B)$ —lo que deseamos inferir. En el lenguaje bayesiano, $P(A_j)$ es la ***probabilidad a priori*** *(lo que sabemos antes de observar) y $P(A_j \mid B)$ es la* ***probabilidad a posteriori*** *(lo que sabemos después de observar la evidencia B).*

El teorema de Bayes nació de una pregunta filosófica, no técnica. En su *Investigación sobre el entendimiento humano*, Hume había planteado que la inducción carece de justificación lógica (que consiste en observar patrones o casos específicos en el mundo real para llegar a una conclusión general): por más veces que hayamos observado que el sol sale cada mañana, ninguna cantidad de observaciones pasadas garantiza lógicamente que saldrá mañana. Los fundamentos de esto se deben a la visión empirista radical de este filósofo, pues para Hume la única fuente del conocimiento debe ser la experiencia sensible. Si esto es así, el conocimiento empírico —incluida toda la ciencia newtoniana— descansaría sobre una base irracional.

Thomas Bayes, ministro presbiteriano inglés y contemporáneo de Hume, buscaba una respuesta rigurosa a ese problema. La encontró escondida dentro de la definición de probabilidad condicional que ya existía: su fórmula revela que conocer $P(B \mid A)$ es suficiente para inferir $P(A \mid B)$ —pasar del efecto a la causa, de la evidencia observable a la hipótesis no observable. No se necesita certeza lógica para aprender racionalmente; basta un mecanismo coherente de actualización de creencias, y ese mecanismo es la fórmula de Bayes.

A más evidencia acumulada, más convergen las probabilidades a posteriori hacia la verdad, independientemente de cuál fuera la creencia inicial. Es una respuesta pragmática y matemáticamente precisa al escepticismo de Hume. Por eso el teorema —publicado póstumamente en 1763 por su amigo Richard Price— aparece hoy en dominios tan distintos como el diagnóstico médico, los filtros de spam, la navegación autónoma y el aprendizaje automático: en todos ellos subyace el mismo problema que preocupaba a Hume y a Bayes, esto es, dado lo que observo, ¿qué puedo inferir sobre lo que no veo?

Tema 2

Variable aleatoria discreta

2.1 ¿Qué es una variable aleatoria?

Hasta ahora hemos trabajado con eventos — subconjuntos abstractos del espacio muestral Ω. Sin embargo, en la práctica queremos asociar *números* a los resultados de un experimento aleatorio: el número de clientes que llegan en una hora, el monto de una transacción, la cantidad de fallas en un proceso. Para eso necesitamos una función que traduzca los elementos de Ω a la recta numérica. Ese objeto es la **variable aleatoria**.

Definición 2.1 — Variable aleatoria

Sea $(\Omega, \mathcal{A}, P)$ un espacio de probabilidad. Una **variable aleatoria** es una función:

$$X : \Omega \longrightarrow \mathbb{R}$$

que satisface la condición de **medibilidad**: para todo $x \in \mathbb{R}$,

$$\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{A}$$

Es decir, el conjunto de resultados para los cuales X no supera el valor x siempre es un evento — pertenece a la σ-álgebra $\mathcal{A}$.

Observación. *La condición de medibilidad exige que $\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{A}$ para todo $x \in \mathbb{R}$. Esto garantiza que siempre tenga sentido calcular $P(X \leq x)$ — si ese conjunto no perteneciera a $\mathcal{A}$, la función P no estaría definida sobre él. En espacios finitos o contables, toda función $X : \Omega \to \mathbb{R}$ es automáticamente medible, por lo que la condición solo cobra relevancia técnica en espacios continuos.*

Observación. *Usaremos letras mayúsculas (X, Y, Z) para denotar variables aleatorias y letras minúsculas (x, y, z) para los valores concretos que estas pueden tomar. La notación $P(X = x)$ significa la probabilidad del evento $\{\omega \in \Omega : X(\omega) = x\}$.*

Ejemplo: suma de dos dados

Lanzamos dos dados equilibrados. El espacio muestral es:

$$\Omega = \{(i, j) : i, j \in \{1, 2, 3, 4, 5, 6\}\}, \quad \#\Omega = 36$$

Definimos la variable aleatoria X como la *suma* de los valores obtenidos:

$$X(i, j) = i + j$$

Por ejemplo, $X(1, 2) = 3$, $X(3, 3) = 6$ y $X(6, 6) = 12$. La figura 2.1 ilustra cómo X mapea elementos de Ω a valores en $\mathbb{R}$.

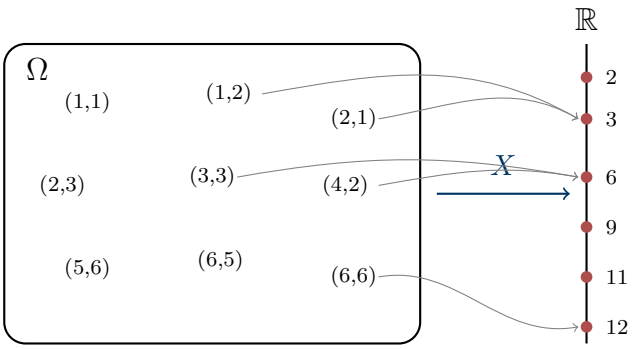


Figura 2.1: La variable aleatoria X como función $\Omega \to \mathbb{R}$. Distintos elementos de Ω pueden mapearse al mismo valor real (por ejemplo, $(1, 2)$ y $(2, 1)$ ambos mapean a $X = 3$).

Nótese un hecho importante: varios elementos de Ω mapean al mismo valor de X. Los pares $(1, 2)$ y $(2, 1)$ producen ambos $X = 3$; los pares $(1, 5)$, $(2, 4)$, $(3, 3)$, $(4, 2)$ y $(5, 1)$ producen todos $X = 6$. Esto es lo esperable — la variable aleatoria *resume* información del resultado, colapsando múltiples resultados en un mismo número.

2.2 Clasificación de las variables aleatorias

Definición 2.2 — Variable aleatoria discreta

Una variable aleatoria X es **discreta** si su recorrido $\text{Rec}(X) = \{x \in \mathbb{R} : P(X = x) > 0\}$ es finito o contable. Es decir, sus valores posibles pueden listarse como una sucesión $x_1, x_2, x_3, \ldots$

Definición 2.3 — Variable aleatoria continua

Una variable aleatoria X es **continua** si su recorrido abarca un intervalo (o unión de intervalos) de la recta numérica. En este caso, $P(X = x) = 0$ para todo valor particular x, y la probabilidad solo tiene sentido sobre intervalos.

Observación. *La distinción entre discreta y continua no es solo técnica — implica herramientas matemáticas distintas. Para variables discretas usaremos sumas; para variables continuas, integrales. En este capítulo nos concentramos en el caso discreto. El caso continuo se trata en el Tema 3.*

En el ejemplo de los dos dados, $X = i + j$ toma valores en $\{2, 3, 4, \ldots, 12\}$ — un conjunto finito — por lo que es una variable aleatoria **discreta**. En cambio, el tiempo de espera hasta que llega el próximo cliente puede tomar cualquier valor en $[0, +\infty)$, por lo que sería **continua**.

2.3 Función de masa de probabilidad

Una vez definida una variable aleatoria discreta X, la pregunta natural es: ¿cómo se distribuye la probabilidad sobre sus valores posibles? La función de masa de probabilidad responde exactamente eso — asigna a cada valor posible de X la probabilidad de que X tome ese valor.

Definición 2.4 — Función de masa de probabilidad

Sea X una variable aleatoria discreta con recorrido $\mathrm{Rec}(X)$. La **función de masa de probabilidad** de X es la función $p_X : \mathbb{R} \to [0, 1]$ definida por:

$$p_X(x) = P(X = x) = P(\{\omega \in \Omega : X(\omega) = x\})$$

para todo $x \in \mathbb{R}$, donde $p_X(x) = 0$ para todo $x \notin \mathrm{Rec}(X)$.

El nombre **función de masa** no es arbitrario — proviene de la mecánica clásica. Si imaginamos los valores del recorrido $x \in \mathrm{Rec}(X)$ como posiciones sobre una recta, y las probabilidades $p_X(x)$ como **masas puntuales** concentradas en esas posiciones, entonces la distribución de probabilidad discreta es formalmente idéntica a un sistema físico de partículas. Esta analogía no es solo pedagógica — es una identidad matemática exacta que veremos reflejada en las definiciones de valor esperado y varianza.

Observación. ***Sobre la terminología.*** *En el curso, y en muchos textos de estadística aplicada, esta función se denomina función de distribución de probabilidad. Esta terminología es técnicamente imprecisa: el término distribución está reservado más apropiadamente para la función de distribución acumulada*

$F_X(x) = P(X \leq x)$, que veremos en la sección siguiente. La denominación correcta para $p_X(x) = P(X = x)$ es ***función de masa de probabilidad****, que es la que usaremos en este apunte. La distinción se vuelve especialmente importante en el Tema 3, cuando introduzcamos la* ***función de densidad de probabilidad*** *para variables continuas — un objeto distinto que también suele llamarse coloquialmente "función de distribución", generando confusión.*

Observación. ***Sobre la notación.*** *En este apunte usamos $p_X(x)$ para la función de masa de probabilidad, distinguiéndola de P — la función de probabilidad sobre eventos definida en los axiomas de Kolmogórov (Definición 1.4). La distinción es:*

$P(A)$	*probabilidad de un evento $A \in \mathcal{A}$*	*(Kolmogórov)*
$p_X(x)$	*probabilidad de que X tome el valor x*	*(función de masa)*

La relación entre ambas es: $p_X(x) = P(\{\omega : X(\omega) = x\})$ — la función de masa es simplemente P aplicada al evento $\{X = x\}$.

En el curso y en muchos textos aplicados esta función también aparece denotada $P(x)$, $p(x)$ o $f(x)$. Todas son la misma cosa. Usaremos $p_X(x)$ por claridad, pero reconoceremos cualquiera de estas notaciones en evaluaciones.

2.3.1 Propiedades

La función de masa de probabilidad satisface dos propiedades que se deducen directamente de los axiomas de Kolmogórov.

Proposición 2.1 — Propiedades de la función de masa

Sea p_X la función de masa de probabilidad de una variable aleatoria discreta X. Entonces:

P1) $0 \leq p_X(x) \leq 1$ para todo $x \in \mathbb{R}$.

P2) $\displaystyle\sum_{x \in \text{Rec}(X)} p_X(x) = 1$.

Demostración. **P1)** Por definición $p_X(x) = P(\{X = x\})$. Como P satisface A1:

$$P(\{X = x\}) \geq 0$$

Como $\{X = x\} \subseteq \Omega$ y $P(\Omega) = 1$, por la Proposición 1.3:

$$P(\{X = x\}) \leq P(\Omega) = 1$$

Luego $0 \leq p_X(x) \leq 1$. □

P2) Los eventos $\{X = x\}$ para $x \in \text{Rec}(X)$ son mutuamente excluyentes y exhaustivos, luego forman una partición de Ω. Aplicando A3:

$$\sum_{x \in \text{Rec}(X)} p_X(x) = \sum_{x \in \text{Rec}(X)} P(X = x) = P\left(\bigcup_{x \in \text{Rec}(X)} \{X = x\} \right) = P(\Omega) = 1$$

■

Observación. *Estas dos propiedades también caracterizan completamente a las funciones de masa: cualquier función $p : \mathbb{R} \to [0, 1]$ que satisfaga P1 y P2 es la función de masa de alguna variable aleatoria discreta. Son el análogo discreto de los axiomas de Kolmogórov para la función de probabilidad sobre eventos.*

2.4 Función de distribución acumulada

La función de masa $p_X(x)$ responde preguntas del tipo $P(X = x)$ — la probabilidad de un valor exacto. Sin embargo, en la práctica casi siempre nos interesan preguntas sobre intervalos: ¿cuál es la probabilidad de que X no supere cierto umbral? ¿De que caiga entre dos valores? La función de distribución acumulada es la herramienta que responde esas preguntas de manera eficiente.

Definición 2.5 — Función de distribución acumulada

Sea X una variable aleatoria discreta con función de masa p_X. La **función de distribución acumulada** (FDA) de X es la función $F_X : \mathbb{R} \to [0, 1]$ definida por:

$$F_X(x) = P(X \leq x) = \sum_{t \leq x} p_X(t) \qquad \text{para todo } x \in \mathbb{R}$$

donde la suma recorre todos los valores $t \in \text{Rec}(X)$ con $t \leq x$.

2.4.1 Propiedades

Proposición 2.2 — Propiedades de la FDA

Sea F_X la función de distribución acumulada de una variable aleatoria discreta X. Entonces:

P1) F_X es **no decreciente**: si $a \leq b$ entonces $F_X(a) \leq F_X(b)$.

P2) F_X tiene **límites en el infinito**:

$$\lim_{x \to -\infty} F_X(x) = 0 \qquad \text{y} \qquad \lim_{x \to +\infty} F_X(x) = 1$$

P3) F_X es **continua por la derecha**: para todo $x \in \mathbb{R}$,

$$\lim_{t \to x^+} F_X(t) = F_X(x)$$

Demostración. **P1)** Si $a \leq b$, entonces el conjunto $\{t \in \text{Rec}(X) : t \leq a\} \subseteq \{t \in \text{Rec}(X) : t \leq b\}$. Como $p_X(t) \geq 0$ para todo t, sumar sobre un conjunto más grande no puede disminuir el resultado:

$$F_X(a) = \sum_{t \leq a} p_X(t) \leq \sum_{t \leq b} p_X(t) = F_X(b) \qquad \square$$

P2) Cuando $x \to -\infty$, no hay valores de $\text{Rec}(X)$ que satisfagan $t \leq x$, luego la suma es vacía y vale 0. Cuando $x \to +\infty$, todos los valores de $\text{Rec}(X)$ satisfacen $t \leq x$, luego por P2 de la Proposición 2.1:

$$\lim_{x \to +\infty} F_X(x) = \sum_{t \in \text{Rec}(X)} p_X(t) = 1 \qquad \square$$

P3) Para t suficientemente cerca de x por la derecha, no hay valores de $\text{Rec}(X)$ en el intervalo $(x, t]$ — el recorrido es discreto, luego existe un salto mínimo entre valores consecutivos. Por tanto $F_X(t) = F_X(x)$ para t suficientemente próximo a x por la derecha, lo que prueba la continuidad por la derecha. ■

Observación. *La propiedad P3 explica la convención de los puntos* ***cerrados*** *y* ***abiertos*** *en la gráfica de la FDA: en cada salto, el punto cerrado (valor que toma F_X) está siempre a la derecha, reflejando que F_X incluye el valor x mismo en la suma — es decir, $P(X \leq x)$ y no $P(X < x)$.*

2.4.2 Cálculo de probabilidades con la FDA

La utilidad principal de la FDA es que permite calcular probabilidades sobre intervalos con una simple resta, sin necesidad de sumar término a término.

Proposición 2.3 — Probabilidades de intervalos

Sea F_X la FDA de una variable aleatoria discreta X. Para cualquier $a < b$:

$$P(a < X \leq b) = F_X(b) - F_X(a)$$

Demostración. Los eventos $\{X \leq a\}$ y $\{a < X \leq b\}$ son mutuamente excluyentes y su unión es $\{X \leq b\}$. Por A3:

$$P(X \leq b) = P(X \leq a) + P(a < X \leq b)$$

Despejando:

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F_X(b) - F_X(a)$$

■

Observación. *Nótese que el intervalo es abierto en a y cerrado en b: $P(a < X \leq b)$ excluye a e incluye b. Esto es consecuencia directa de la continuidad por la derecha de F_X. Para otros tipos de intervalos:*

$$\begin{aligned} P(X > a) &= 1 - F_X(a) \\ P(X \geq a) &= 1 - F_X(a) + p_X(a) = 1 - F_X(a^-) \\ P(a \leq X \leq b) &= F_X(b) - F_X(a) + p_X(a) \end{aligned}$$

Ejemplo: demanda diaria de un tractor

Una empresa arrienda su tractor para trabajos de remoción. La demanda diaria X — el número de veces que se usa el tractor en un día — tiene la siguiente distribución de probabilidad, donde $P(5)$ se deduce de la propiedad P2 de la función de masa: la suma de todas las probabilidades debe ser 1, luego $p_X(5) = 1 - 0.10 - 0.20 - 0.30 - 0.25 - 0.10 = 0.05$.

x	$p_X(x)$	$F_X(x)$
0	0.10	0.10
1	0.20	0.30
2	0.30	0.60
3	0.25	0.85
4	0.10	0.95
5	0.05	1.00

La figura 2.2 muestra la FDA como función escalera. Cada salto ocurre en un valor de $\text{Rec}(X)$ y su altura es exactamente $p_X(x)$.

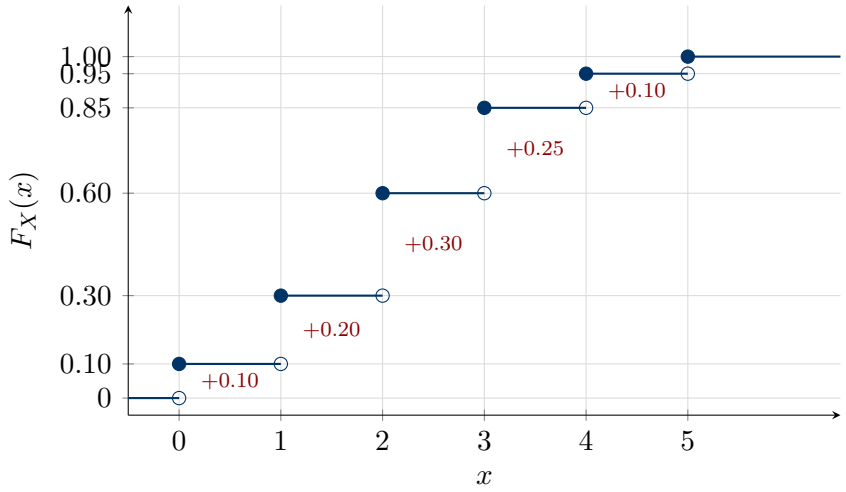


Figura 2.2: Función de distribución acumulada F_X para el ejemplo del tractor. Los puntos cerrados indican continuidad por la derecha. Los saltos en rojo corresponden a $p_X(x)$.

Usando la proposición de intervalos:

$$P(X > 3) = 1 - F_X(3) = 1 - 0.85 = 0.15$$

$$P(1 < X \leq 4) = F_X(4) - F_X(1) = 0.95 - 0.30 = 0.65$$

2.5 Valor esperado y varianza

2.5.1 Valor esperado

Sabemos que una variable aleatoria discreta X puede tomar distintos valores con distintas probabilidades. Una pregunta natural es: ¿cuál es el valor *típico* o *central* de X? La respuesta es el **valor esperado** — un promedio ponderado de los valores posibles de X, donde cada valor se pondera por su probabilidad.

Definición 2.6 — Valor esperado

Sea X una variable aleatoria discreta con función de masa p_X y recorrido $\text{Rec}(X)$. El **valor esperado**, **valor medio** o **esperanza** de X, denotado $E(X)$, μ_X o μ, es:

$$E(X) = \sum_{x \in \text{Rec}(X)} x \cdot p_X(x)$$

La definición del valor esperado no es arbitraria — tiene un origen físico preciso. En mecánica clásica, el **centro de masa** de un sistema de partículas con masas

m_i en posiciones x_i es:

$$\bar{x} = \frac{\sum_i m_i x_i}{\sum_i m_i}$$

Si normalizamos las masas para que sumen 1 — definiendo $p_i = m_i / \sum_j m_j$ — obtenemos exactamente:

$$\bar{x} = \sum_i x_i \, p_i = E(X)$$

El valor esperado es el punto donde la distribución estaría en equilibrio si la colocáramos sobre un fulcro. La figura 2.3 muestra este paralelismo explícitamente.

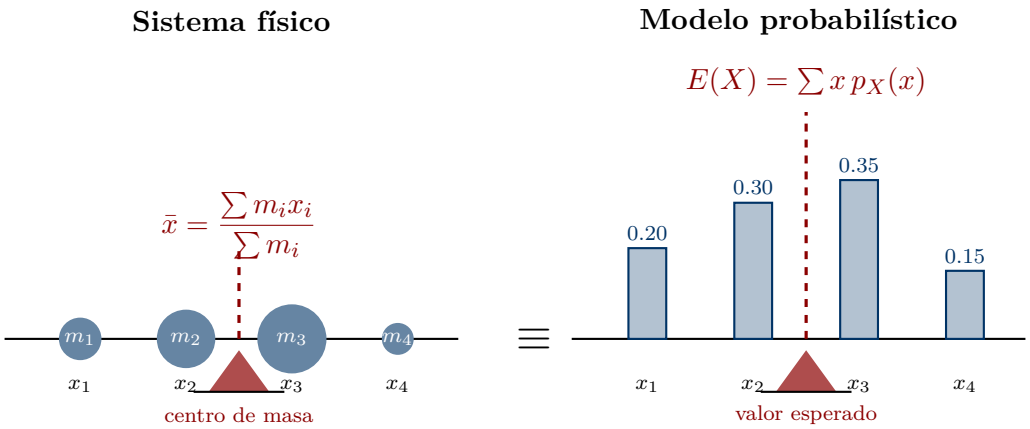


Figura 2.3: El valor esperado como centro de masa. Las masas físicas m_i normalizadas corresponden a las probabilidades $p_X(x_i)$; el punto de equilibrio físico corresponde a $E(X)$.

Proposición 2.4 — Valor esperado de una función de X

Sea $h : \mathbb{R} \to \mathbb{R}$ una función. El valor esperado de $h(X)$ es:

$$E(h(X)) = \sum_{x \in \text{Rec}(X)} h(x) \cdot p_X(x)$$

Proposición 2.5 — Linealidad del valor esperado

Si a y b son constantes, entonces:

$$E(aX + b) = aE(X) + b$$

Demostración. Aplicamos la Proposición 2.4 con $h(x) = ax + b$:

$$E(aX+b) = \sum_{x \in \text{Rec}(X)} (ax+b)\, p_X(x) = a \sum_{x \in \text{Rec}(X)} x\, p_X(x) + b \sum_{x \in \text{Rec}(X)} p_X(x) = aE(X)+b$$

donde en el último paso usamos la definición de $E(X)$ y la propiedad P2 de la función de masa ($\sum p_X(x) = 1$). ■

Ejemplo: demanda mensual

Una empresa registra la demanda mensual X de un producto durante dos años y obtiene la siguiente distribución:

x	300	400	500	600
$p_X(x)$	0.20	0.30	0.35	0.15

El valor esperado es:

$$E(X) = 300(0.20) + 400(0.30) + 500(0.35) + 600(0.15) = 60 + 120 + 175 + 90 = 445$$

La figura 2.4 muestra la función de masa con el valor esperado marcado como centro de la distribución.

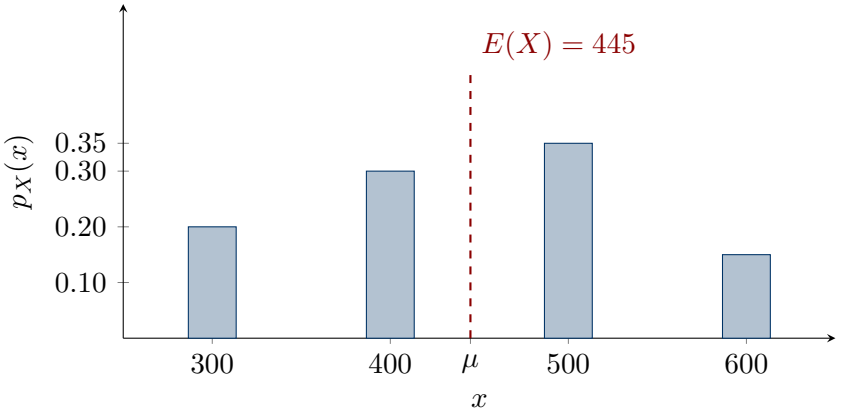


Figura 2.4: Función de masa p_X para la demanda mensual. La línea roja marca el valor esperado $E(X) = 445$ — el centro de masa de la distribución.

2.5.2 Varianza

El valor esperado nos dice dónde está el centro de la distribución, pero no dice nada sobre qué tan dispersos están los valores de X alrededor de ese centro. Dos distribuciones pueden tener el mismo $E(X)$ y ser completamente distintas en su dispersión. La **varianza** cuantifica esa dispersión.

Definición 2.7 — Varianza

Sea X una variable aleatoria discreta con $E(X) = \mu$. La **varianza** de X, denotada $\text{Var}(X)$, $V(X)$, σ_X^2 o σ^2, es:

$$\text{Var}(X) = E\Big[(X-\mu)^2\Big] = \sum_{x \in \text{Rec}(X)} (x-\mu)^2 \, p_X(x)$$

La **desviación estándar** de X es $\sigma_X = \sqrt{\text{Var}(X)}$.

La razón de elevar al cuadrado en la definición de la varianza es puramente **matemática**, y se entiende mejor a través del **método de mínimos cuadrados**. El problema fundamental es el siguiente: dado un conjunto de observaciones $x_1, x_2, \ldots, x_n$, ¿qué valor μ minimiza la dispersión total? Es decir, ¿cuál es el mejor representante central de los datos?

La respuesta depende de cómo midamos la dispersión. Si definimos la dispersión total como la suma de las desviaciones al cuadrado:

$$S(\mu) = \sum_{i=1}^{n} (x_i - \mu)^2$$

entonces minimizar $S(\mu)$ respecto a μ es trivial — derivamos e igualamos a cero:

$$\frac{dS}{d\mu} = -2\sum_{i=1}^{n}(x_i - \mu) = 0 \implies \mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

El minimizador es exactamente la **media aritmética**. Esto no es una coincidencia — es la razón por la que la media y la varianza están tan profundamente ligadas: la varianza mide la dispersión respecto al único punto que la minimiza.

Gauss y Legendre eligieron el cuadrado sobre cualquier alternativa porque produce estas propiedades matemáticas superiores:

- Es **convexa** — tiene un único mínimo global, garantizando que la solución es única.
- Es **diferenciable en todas partes** — permite minimizar analíticamente sin casos especiales.
- Tiene **solución analítica cerrada** — la media, obtenida directamente sin métodos numéricos.
- Conecta naturalmente con la **distribución normal**, cuya densidad es proporcional a $e^{-x^2/2}$.

La alternativa más intuitiva habría sido minimizar la suma de valores absolutos $\sum_i |x_i - \mu|$ — la llamada **desviación media absoluta** — que tiene interpretación más directa pero no es diferenciable en $x = 0$ y no tiene solución analítica cerrada. El cuadrado ganó por sus propiedades matemáticas, no por intuición.

El costo de elevar al cuadrado es **dimensional**: si X mide demanda en unidades de producto, $\text{Var}(X)$ está en unidades^2, lo que hace imposible comparar la dispersión directamente con el valor esperado. La **desviación estándar** $\sigma_X = \sqrt{\text{Var}(X)}$

existe precisamente para resolver eso — devuelve la dispersión a las mismas unidades que X, permitiendo afirmaciones del tipo *«el valor típico de X se aleja de μ aproximadamente σ_X unidades»*. En la práctica, la varianza se usa en demostraciones y cálculos por su mejor comportamiento algebraico, mientras que la desviación estándar se usa para interpretar y comunicar resultados.

El paralelismo con la física se extiende a la varianza. En mecánica clásica, el **momento de inercia** de un sistema de partículas respecto a un eje que pasa por el centro de masa es:

$$I = \sum_i m_i (x_i - \bar{x})^2$$

Bajo normalización de las masas, esto es exactamente:

$$I = \sum_i (x_i - \bar{x})^2 \, p_i = \mathrm{Var}(X)$$

La varianza mide lo mismo que el momento de inercia: qué tan *lejos* están las masas — o las probabilidades — del centro. Un sistema con masas muy dispersas tiene momento de inercia grande; una distribución con valores muy dispersos alrededor de μ tiene varianza grande. La figura 2.5 ilustra esta equivalencia.

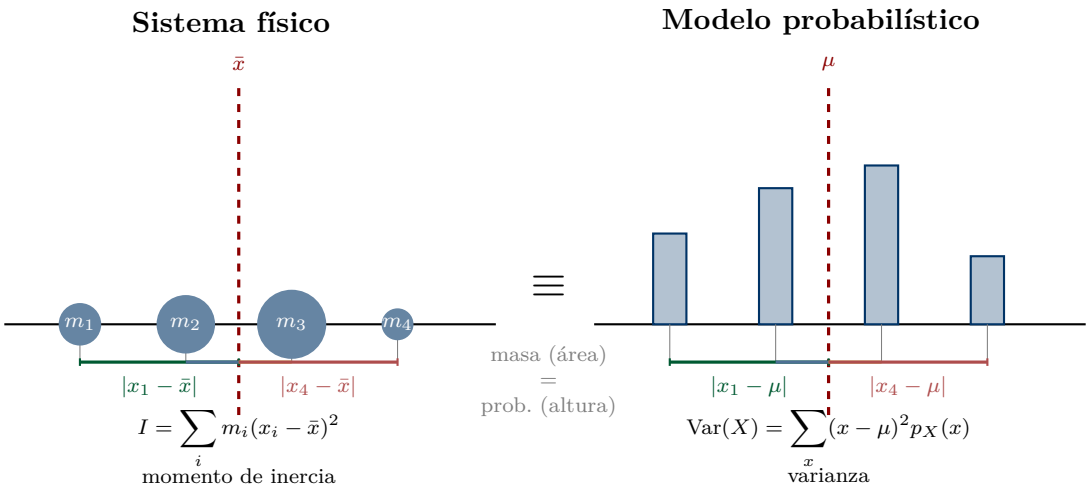


Figura 2.5: La varianza como momento de inercia. Los segmentos de color bajo el eje muestran la distancia $|x_i - \bar{x}|$ de cada valor al centro. La varianza pondera el *cuadrado* de esas distancias por la masa (o probabilidad) correspondiente.

Observación. *La varianza promedia el cuadrado de las desviaciones respecto a μ, no las desviaciones directas. Esto tiene dos razones: primero, las desviaciones positivas y negativas no se cancelan; segundo, las desviaciones grandes pesan desproporcionadamente más, lo que hace a la varianza sensible a valores extremos. La desviación estándar σ_X devuelve la dispersión a las unidades originales de X.*

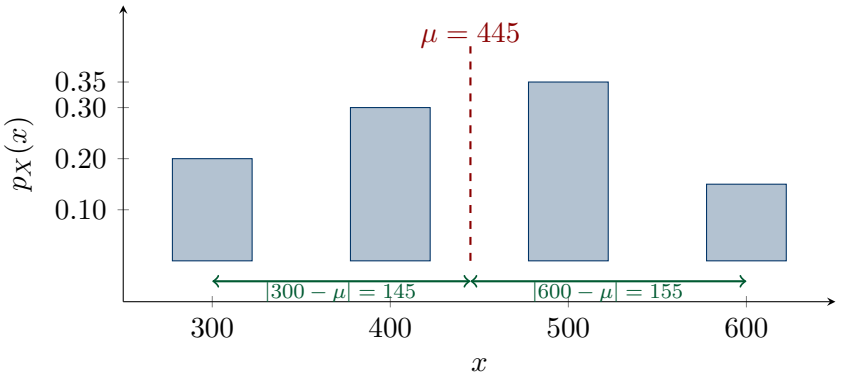


Figura 2.6: La varianza mide la dispersión de X alrededor de $\mu = E(X) = 445$. Las flechas ilustran las desviaciones $|x - \mu|$ para los valores extremos del recorrido.

Proposición 2.6 — Fórmula alternativa de la varianza

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

Demostración. Sea $\mu = E(X)$. Expandimos el cuadrado en la definición:

$$\text{Var}(X) = \sum_{x \in \text{Rec}(X)} (x - \mu)^2 \, p_X(x) = \sum_x (x^2 - 2\mu x + \mu^2) \, p_X(x)$$

Distribuimos la suma:

$$= \sum_x x^2 \, p_X(x) - 2\mu \sum_x x \, p_X(x) + \mu^2 \sum_x p_X(x)$$

Reconocemos cada término: el primero es $E(X^2)$ por la Proposición 2.4 con $h(x) = x^2$; el segundo usa $\sum x \, p_X(x) = \mu$; el tercero usa $\sum p_X(x) = 1$:

$$= E(X^2) - 2\mu \cdot \mu + \mu^2 \cdot 1 = E(X^2) - 2\mu^2 + \mu^2 = E(X^2) - \mu^2 = E(X^2) - (E(X))^2$$

■

Observación. *La fórmula alternativa es la que se usa en la práctica: calcular $E(X^2) - (E(X))^2$ requiere solo dos sumas, mientras que la definición directa requiere calcular $(x - \mu)^2$ para cada valor del recorrido — más laborioso cuando el recorrido es grande.*

Proposición 2.7 — Propiedades de la varianza

Sean a y b constantes. Entonces:

i) $\text{Var}(X) \geq 0$

ii) $\text{Var}(a) = 0$

iii) $\mathrm{Var}(aX+b) = a^2\,\mathrm{Var}(X) \quad$ y $\quad \sigma_{aX+b} = |a|\,\sigma_X$

Demostración. **i)** Cada término $(x-\mu)^2 p_X(x) \geq 0$, luego la suma también. □

ii) Si a es constante, $E(a) = a$ y $(a - E(a))^2 = 0$ para todo resultado, luego $\mathrm{Var}(a) = 0$. □

iii) Por la linealidad del valor esperado (Proposición 2.5), $E(aX+b) = aE(X) + b = a\mu + b$. Aplicando la fórmula alternativa:

$$\mathrm{Var}(aX+b) = E\Big[(aX+b)^2\Big] - (aE(X)+b)^2$$

$$= E\Big[a^2X^2 + 2abX + b^2\Big] - (a^2\mu^2 + 2ab\mu + b^2)$$

$$= a^2E(X^2) + 2ab\mu + b^2 - a^2\mu^2 - 2ab\mu - b^2 = a^2\Big(E(X^2) - \mu^2\Big) = a^2\,\mathrm{Var}(X)$$

La desviación estándar sigue como $\sigma_{aX+b} = \sqrt{a^2\,\mathrm{Var}(X)} = |a|\,\sigma_X$. ■

Observación. *La propiedad iii revela algo importante: sumar una constante b a X* ***no cambia la varianza*** *— desplaza la distribución pero no altera su dispersión. Solo la multiplicación por a escala la varianza, y lo hace de manera cuadrática.*

2.6 Distribuciones importantes

Hasta ahora hemos definido la variable aleatoria discreta en su forma más general: una función $X : \Omega \to \mathbb{R}$ equipada con una función de masa p_X arbitraria. Sin embargo, en la práctica aparecen ciertas **estructuras de experimento** que se repiten una y otra vez —y cada estructura genera siempre la misma forma de distribución.

2.6.1 Distribución de Bernoulli

Definición 2.8 — Experimento de Bernoulli

Sea $(\Omega, \mathcal{A}, P)$ un espacio de probabilidad. Un **experimento de Bernoulli** es aquel en que el resultado de interés queda determinado por un evento $A \in \mathcal{A}$, llamado **éxito**, con $P(A) = p \in (0,1)$. Su complemento A^c se denomina **fracaso** y tiene probabilidad $1-p$.

El espacio muestral Ω puede tener cualquier cardinalidad —lo que define al experimento como de Bernoulli es la **partición binaria** $\{A,\, A^c\}$ del espacio,

no la estructura de Ω. Por ejemplo, al lanzar un dado de seis caras y definir $A = \{\text{sale par}\}$, el espacio muestral tiene seis elementos, pero el experimento es de Bernoulli con $p = 1/2$.

Definición 2.9 — Variable aleatoria Bernoulli

Sea $(\Omega, \mathcal{A}, P)$ el espacio de probabilidad de un experimento de Bernoulli con evento de éxito A y probabilidad $p = P(A)$. La **variable aleatoria Bernoulli** asociada a A es la **función indicadora** de A:

$$X(\omega) = \mathbf{1}_A(\omega) \;=\; \begin{cases} 1 & \text{si } \omega \in A, \\ 0 & \text{si } \omega \notin A. \end{cases}$$

Se escribe $X \sim \text{Bernoulli}(p)$.

Proposición 2.8 — Función de masa Bernoulli

Si $X \sim \text{Bernoulli}(p)$, entonces

$$p_X(x) = p^x(1-p)^{1-x}, \qquad x \in \{0, 1\}.$$

Demostración. Directamente de la definición de X y de $P(A) = p$:

$$p_X(1) = P(X = 1) = P(A) = p, \qquad p_X(0) = P(X = 0) = P(A^c) = 1 - p,$$

que se unifica en $p^x(1-p)^{1-x}$ para $x \in \{0, 1\}$. ■

Observación. *La **función indicadora** $\mathbf{1}_A : \Omega \to \{0, 1\}$ es un objeto general de la matemática: dado cualquier conjunto $A \subseteq \Omega$, vale 1 exactamente donde ocurre el evento y 0 en el resto. La variable aleatoria Bernoulli no se* parece *a una función indicadora — es literalmente la misma cosa, vista ahora sobre un espacio de probabilidad. En análisis aparece con el nombre de función característica de un conjunto y se denota χ_A; en probabilidad el nombre estándar es el que usamos aquí.*

Observación. *La expresión $p^x(1-p)^{1-x}$ es una fórmula compacta que unifica ambos casos: si $x = 1$, entrega $p^1(1-p)^0 = p$; si $x = 0$, entrega $p^0(1-p)^1 = 1 - p$. Es habitual denotar $q := 1 - p$.*

Proposición 2.9 — Momentos de la distribución Bernoulli

Si $X \sim \text{Bernoulli}(p)$ con $p \in (0, 1)$, entonces

$$E(X) = p \qquad \text{y} \qquad \text{Var}(X) = p(1-p).$$

Demostración. **Valor esperado.** Aplicando la definición directamente:

$$E(X) = 0 \cdot p_X(0) + 1 \cdot p_X(1) = 0(1-p) + 1 \cdot p = p.$$

Varianza. Usamos la fórmula alternativa $\mathrm{Var}(X) = E(X^2) - (E(X))^2$. Como X solo toma valores en $\{0, 1\}$, se tiene $x^2 = x$ para todo x en el recorrido de X, luego $E(X^2) = E(X) = p$. Por lo tanto:

$$\mathrm{Var}(X) = p - p^2 = p(1-p).$$

■

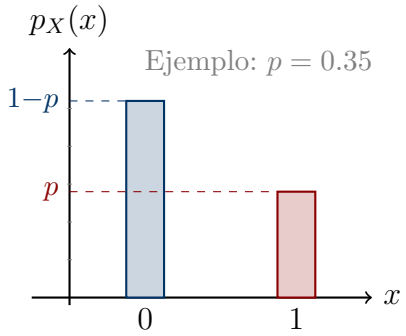


Figura 2.7: Función de masa de $X \sim \text{Bernoulli}(0.35)$. La probabilidad de fracaso es $1 - p = 0.65$ y la de éxito es $p = 0.35$.

La distribución Bernoulli modela un único ensayo. La pregunta natural que sigue es: ¿qué ocurre si repetimos el experimento n veces? Para que esa repetición tenga sentido probabilístico se necesita precisar las condiciones bajo las cuales opera.

Definición 2.10 — Variables aleatorias i.i.d.

Una colección de variables aleatorias $X_1, X_2, \ldots, X_n$ se dice **independientes e idénticamente distribuidas** (i.i.d.) si satisface dos condiciones:

i) Independencia: para todo $(x_1, x_2, \ldots, x_n)$,

$$P(X_1 = x_1,\ X_2 = x_2,\ \ldots,\ X_n = x_n) = \prod_{i=1}^{n} P(X_i = x_i).$$

ii) Identidad de distribución: todas las X_i tienen la misma función de masa, es decir, $p_{X_i} = p_{X_j}$ para todo $i \neq j$.

Observación. *El concepto i.i.d. es uno de los pilares de la estadística: la mayor parte de los resultados clásicos — incluyendo el Teorema del Límite Central —*

asumen que las observaciones de una muestra son i.i.d. La condición de independencia formaliza la intuición de que el resultado de un ensayo no afecta a los demás; la de identidad de distribución formaliza que todos los ensayos operan bajo las mismas condiciones.

Definición 2.11 — Proceso de Bernoulli

Un **proceso de Bernoulli** con n ensayos y probabilidad de éxito $p \in (0,1)$ es una colección de variables aleatorias i.i.d. $X_1, X_2, \ldots, X_n$ con

$$X_i \sim \text{Bernoulli}(p) \qquad \text{para todo } i = 1, 2, \ldots, n.$$

Observación. *Las tres condiciones que se enuncian habitualmente — ensayos binarios, independencia y probabilidad constante — están todas contenidas en esta definición: la distribución Bernoulli garantiza la binaridad, la i.i.d. garantiza simultáneamente la independencia y la constancia de p.*

2.6.2 Distribución Binomial

Definición 2.12 — Distribución Binomial

Sea $X_1, X_2, \ldots, X_n$ un proceso de Bernoulli con probabilidad de éxito $p \in (0,1)$ (Definición 2.11). La **variable aleatoria Binomial** con parámetros n y p es la suma

$$X = \sum_{i=1}^{n} X_i,$$

que cuenta el número de éxitos en los n ensayos. Se escribe $X \sim \text{Binomial}(n, p)$.

Proposición 2.10 — Función de masa Binomial

Si $X \sim \text{Binomial}(n, p)$, entonces

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x}, \qquad x = 0, 1, \ldots, n.$$

Demostración. Sea $x \in \{0, 1, \ldots, n\}$. El evento $\{X = x\}$ ocurre cuando exactamente x de los n ensayos resultan en éxito. Consideremos primero una secuencia específica con éxitos en las posiciones $i_1, \ldots, i_x$ y fracasos en las restantes $j_1, \ldots, j_{n-x}$. Por la independencia de las X_i:

$$P\Big(X_{i_1} = 1, \ldots, X_{i_x} = 1,\ X_{j_1} = 0, \ldots, X_{j_{n-x}} = 0\Big) = p^x (1-p)^{n-x}.$$

Esta probabilidad es la misma para *toda* secuencia con exactamente x éxitos, independientemente de en qué posiciones ocurran. El número de secuencias distintas con x éxitos en n posiciones es $\binom{n}{x}$, y los eventos correspondientes son mutuamente excluyentes. Por lo tanto:

$$p_X(x) = P(X = x) = \binom{n}{x} p^x (1-p)^{n-x}.$$

■

El nombre *distribución binomial* no es arbitrario. Para que p_X sea una función de masa válida debe cumplirse que $\sum_{x=0}^{n} p_X(x) = 1$, y la verificación revela la conexión:

$$\sum_{x=0}^{n} \binom{n}{x} p^x (1-p)^{n-x} = \Big(p + (1-p)\Big)^n = 1.$$

El paso central es el **teorema del binomio**, que establece que para cualesquiera $a, b \in \mathbb{R}$ y $n \in \mathbb{N}$,

$$(a+b)^n = \sum_{x=0}^{n} \binom{n}{x} a^x \, b^{n-x}.$$

Es decir, los coeficientes $\binom{n}{x}$ que aparecen en la función de masa son exactamente los coeficientes que surgen al expandir un binomio elevado a la n — de ahí el nombre. La distribución binomial no hace más que repartir la unidad $(p + (1-p))^n = 1$ entre todos los posibles conteos de éxitos.

Proposición 2.11 — Momentos de la distribución Binomial

Si $X \sim \text{Binomial}(n, p)$ con $p \in (0, 1)$, entonces

$$E(X) = np \qquad \text{y} \qquad \text{Var}(X) = np(1-p).$$

Demostración. Escribimos $X = X_1 + \cdots + X_n$ con $X_i \sim \text{Bernoulli}(p)$ i.i.d. (Definición 2.12).

Valor esperado. Por linealidad del valor esperado (Proposición 2.5):

$$E(X) = \sum_{i=1}^{n} E(X_i) = \sum_{i=1}^{n} p = np.$$

Varianza. La independencia de las X_i implica que no hay términos cruzados en la varianza de la suma, de modo que

$$\text{Var}(X) = \sum_{i=1}^{n} \text{Var}(X_i) = \sum_{i=1}^{n} p(1-p) = np(1-p).$$

■

Observación. *La aditividad de la varianza bajo independencia — usada en la demostración anterior — es un resultado que se justificará formalmente en el Tema 3 al introducir el concepto de covarianza. Por ahora basta saber que cuando las variables son independientes, los términos cruzados son cero y la varianza de la suma se reduce a la suma de las varianzas.*

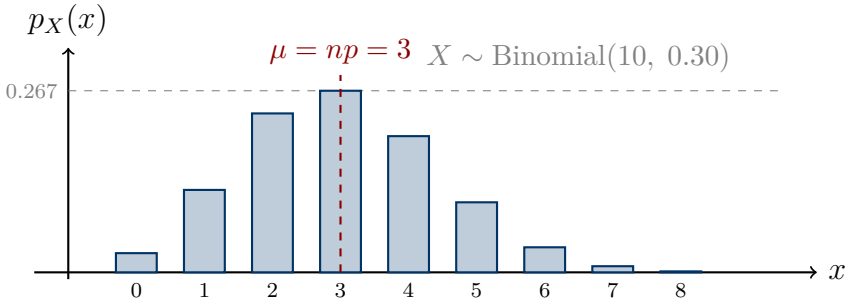


Figura 2.8: Función de masa de $X \sim \text{Binomial}(10, 0.30)$. La distribución es asimétrica hacia la derecha para $p < 0.5$, con moda en $x = 3$ y media $E(X) = np = 3$.

Vale la pena contrastar ambas distribuciones: Bernoulli responde *¿ocurrió el evento?* en un único ensayo — la variable solo puede valer 0 o 1. Binomial responde *¿cuántas veces ocurrió?* en n ensayos — la variable toma valores en $\{0, 1, \ldots, n\}$. La relación entre ambas es exacta: $\text{Bernoulli}(p) = \text{Binomial}(1, p)$.

2.6.3 Distribución de Poisson

La distribución Binomial requiere que el número de ensayos n sea finito y fijo. Sin embargo, hay fenómenos donde los eventos pueden ocurrir en cualquier punto de un intervalo continuo — el tiempo, el espacio, una superficie — y no tiene sentido hablar de un n fijo. ¿Cuántos autos pasan por una intersección en una hora? ¿Cuántos mensajes llegan a un servidor en un minuto? ¿Cuántas imperfecciones hay en un metro de cable?

La idea para modelar este tipo de fenómenos es la siguiente: dividamos el intervalo en n subintervalos tan pequeños que en cada uno pueda ocurrir a lo más un evento, con probabilidad $p = \lambda/n$, donde $\lambda > 0$ es la tasa promedio de ocurrencia. Esto define un proceso de Bernoulli con n ensayos y probabilidad λ/n, de modo que el número de eventos $X_n \sim \text{Binomial}(n, \lambda/n)$. La distribución de Poisson emerge al tomar el límite $n \to \infty$ — subintervalos infinitesimales.

Proposición 2.12 — Límite de la Binomial

Sea $k \in \mathbb{N}_0$ fijo y $\lambda > 0$. Entonces

$$\lim_{n\to\infty} \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1-\frac{\lambda}{n}\right)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}.$$

Demostración. Separamos el término en tres factores:

$$\binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1-\frac{\lambda}{n}\right)^{n-k} = \frac{\lambda^k}{k!} \cdot \underbrace{\frac{n(n-1)\cdots(n-k+1)}{n^k}}_{(A)} \cdot \underbrace{\left(1-\frac{\lambda}{n}\right)^n}_{(B)} \cdot \underbrace{\left(1-\frac{\lambda}{n}\right)^{-k}}_{(C)}.$$

Analizamos el límite de cada uno.

Factor (A). Reescribiendo:

$$\frac{n(n-1)\cdots(n-k+1)}{n^k} = \prod_{j=0}^{k-1}\left(1-\frac{j}{n}\right) \;\to\; 1 \quad \text{cuando } n \to \infty.$$

Factor (C). Como $\lambda/n \to 0$, se tiene $(1-\lambda/n)^{-k} \to 1$.

Factor (B). Tomamos logaritmo y reescribimos la indeterminación $\infty \cdot 0$ como $0/0$:

$$\ln\left(1-\frac{\lambda}{n}\right)^n = n\ln\left(1-\frac{\lambda}{n}\right) = \frac{\ln\left(1-\frac{\lambda}{n}\right)}{1/n}.$$

Aplicando la regla de L'Hôpital (tratando n como variable continua):

$$\lim_{n\to\infty} \frac{\ln(1-\lambda/n)}{1/n} = \lim_{n\to\infty} \frac{\frac{\lambda/n^2}{1-\lambda/n}}{-1/n^2} = \lim_{n\to\infty} \frac{-\lambda}{1-\lambda/n} = -\lambda.$$

Por continuidad de la exponencial: $(1-\lambda/n)^n \to e^{-\lambda}$.

Combinando los tres factores:

$$\lim_{n\to\infty} \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1-\frac{\lambda}{n}\right)^{n-k} = \frac{\lambda^k}{k!} \cdot 1 \cdot e^{-\lambda} \cdot 1 = \frac{\lambda^k e^{-\lambda}}{k!}.$$

■

La proposición anterior muestra que al tomar subintervalos infinitesimales, la probabilidad de observar exactamente k eventos converge a $\lambda^k e^{-\lambda}/k!$. Esto motiva la siguiente definición.

Definición 2.13 — Distribución de Poisson

Una variable aleatoria discreta X tiene **distribución de Poisson** con parámetro $\lambda > 0$ si su función de masa es

$$p_X(k) = \frac{\lambda^k e^{-\lambda}}{k!}, \qquad k = 0, 1, 2, \ldots$$

Se escribe $X \sim \text{Poisson}(\lambda)$.

Observación. *La verificación de que p_X es una función de masa válida es inmediata a partir de la serie de Taylor de e^x:*

$$\sum_{k=0}^{\infty} \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \cdot e^{\lambda} = 1.$$

La serie de Taylor $e^x = \sum_{k=0}^{\infty} x^k/k!$ es el análogo continuo del teorema del binomio: así como la Binomial se apoya en $(p+q)^n = 1$, la Poisson se apoya en $e^{-\lambda} \cdot e^{\lambda} = 1$.

Proposición 2.13 — Momentos de la distribución de Poisson

Si $X \sim \text{Poisson}(\lambda)$ con $\lambda > 0$, entonces

$$E(X) = \lambda \qquad \text{y} \qquad \text{Var}(X) = \lambda.$$

Demostración. **Valor esperado.** El término $k = 0$ no contribuye, luego:

$$E(X) = \sum_{k=1}^{\infty} k \, \frac{e^{-\lambda}\lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}.$$

Sustituyendo $j = k - 1$:

$$= e^{-\lambda} \cdot \lambda \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = e^{-\lambda} \cdot \lambda \cdot e^{\lambda} = \lambda.$$

Varianza. Usamos $\text{Var}(X) = E(X^2) - (E(X))^2$ y escribimos $E(X^2) = E(X(X-1)) + E(X)$. Para el primer término, los casos $k = 0$ y $k = 1$ no contribuyen:

$$E(X(X-1)) = \sum_{k=2}^{\infty} k(k-1) \, \frac{e^{-\lambda}\lambda^k}{k!} = e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^k}{(k-2)!}.$$

Sustituyendo $j = k - 2$:

$$= e^{-\lambda} \cdot \lambda^2 \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda^2.$$

Por lo tanto $E(X^2) = \lambda^2 + \lambda$, y:

$$\text{Var}(X) = (\lambda^2 + \lambda) - \lambda^2 = \lambda.$$

■

Observación. *La igualdad $E(X) = \text{Var}(X) = \lambda$ es una propiedad característica de la Poisson: si en datos de conteo se observa que la media y la varianza muestral son aproximadamente iguales, la Poisson es un modelo candidato razonable. El parámetro λ tiene además una interpretación directa: es la tasa promedio de ocurrencia en el intervalo de referencia. Si los eventos ocurren a tasa λ por hora, en un intervalo de t horas se modela con* Poisson(λt).

Vale la pena contrastar las tres distribuciones del tema. Bernoulli responde *¿ocurrió el evento?* en un único ensayo. Binomial responde *¿cuántas veces ocurrió?* en n ensayos fijos. Poisson responde *¿cuántos eventos ocurrieron?* en un intervalo continuo, sin n fijo, solo con una tasa λ estable. La regla práctica: si hay un n contable y un p identificable, Binomial; si los eventos se distribuyen continuamente en el tiempo o el espacio con tasa conocida, Poisson.

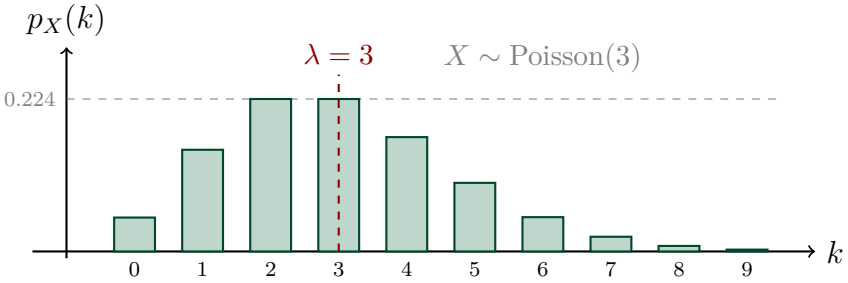


Figura 2.9: Función de masa de $X \sim \text{Poisson}(3)$. Media y varianza son ambas iguales a $\lambda = 3$. La moda se ubica en $k = 2$ y $k = 3$ simultáneamente, ya que λ no es entero más uno.

Observación. *La distribución de Poisson es **discreta**: los valores que toma X son $0, 1, 2, \ldots$, que son contables. Lo que es continuo no es la variable, sino el* soporte *donde ocurren los eventos — el tiempo, el espacio, una superficie. La variable cuenta cuántos eventos ocurrieron ahí, y ese conteo siempre es un número entero. En el ejemplo de mensajes a un servidor: el número de mensajes recibidos en una hora puede ser $0, 1, 2, 3, \ldots$ — nunca 2.7. Lo continuo es el intervalo de tiempo en que cada mensaje puede llegar, no la cantidad de mensajes.*

Tema 3

Variable aleatoria continua

3.1 De lo discreto a lo continuo

En el Tema 2 modelamos fenómenos cuyos resultados son contables: número de éxitos, número de mensajes, número de fallas. La herramienta central fue la función de masa p_X, que asigna probabilidad a cada valor individual del recorrido. Pero hay fenómenos que no encajan en ese marco: el tiempo de espera en una cola, la temperatura de una ciudad, la altura de una persona. En estos casos el recorrido de X no es un conjunto contable — es un intervalo continuo de la recta real, y la probabilidad de observar cualquier valor *exacto* es cero.

Para entender por qué, y cómo modelar estos fenómenos, conviene partir de algo familiar: el histograma.

3.1.1 Del histograma a la densidad

Supongamos que medimos una variable continua — digamos, el tiempo de atención en ventanilla en segundos — sobre una muestra de n observaciones. Dividimos el rango de los datos en k intervalos $[a_0, a_1), [a_1, a_2), \ldots, [a_{k-1}, a_k)$ de ancho $\Delta x = a_{i+1} - a_i$, y construimos un histograma. La altura de cada barra puede definirse de dos maneras:

- **Histograma de frecuencias:** la altura es el conteo de observaciones en el intervalo. El área no tiene interpretación probabilística directa.
- **Histograma de densidad:** la altura d_i se define como la frecuencia relativa fr_i dividida por el ancho del intervalo:

$$d_i = \frac{fr_i}{\Delta x}.$$

De este modo, el **área** de cada barra es igual a la frecuencia relativa:

$$\text{área}_i = d_i \cdot \Delta x = fr_i,$$

y la suma de todas las áreas es 1. La probabilidad de que X caiga en el intervalo $[a_{i-1}, a_i)$ se aproxima por el área de la barra correspondiente.

El histograma de densidad es el punto de partida. Ahora preguntamos: ¿qué ocurre si refinamos la partición indefinidamente, haciendo $\Delta x \to 0$?

3.1.2 El límite: de la suma a la integral

Con una partición de k intervalos de ancho Δx, la probabilidad de que X caiga en $[a, b]$ se aproxima por la suma de las áreas de las barras contenidas en ese intervalo:

$$P(a \leq X \leq b) \approx \sum_i d_i \cdot \Delta x.$$

Esta es una suma de Riemann. Al hacer $\Delta x \to 0$ — es decir, al refinar la partición hasta tener intervalos infinitesimales — las alturas d_i convergen a una función continua $f(x)$ y la suma converge a una integral:

$$P(a \leq X \leq b) = \lim_{\Delta x \to 0} \sum_i d_i \cdot \Delta x = \int_a^b f(x)\, dx.$$

La función $f(x)$ que emerge en este límite es la **función de densidad de probabilidad** de X. Ya no asigna probabilidad a valores individuales — asigna *densidad de probabilidad* a cada punto, de modo que la probabilidad de un intervalo es el área bajo la curva f en ese intervalo.

Observación. *Una consecuencia inmediata e importante: para una variable aleatoria continua,*

$$P(X = x) = \int_x^x f(t)\, dt = 0$$

para todo $x \in \mathbb{R}$. La probabilidad de observar cualquier valor exacto *es cero. Esto no significa que el evento sea imposible — significa que en un espacio continuo, la probabilidad se concentra en intervalos, no en puntos. En consecuencia, para una v.a. continua es irrelevante si los extremos del intervalo están incluidos o no:*

$$P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b).$$

Este resultado no tiene análogo en el mundo discreto y suele sorprender la primera vez que se encuentra.

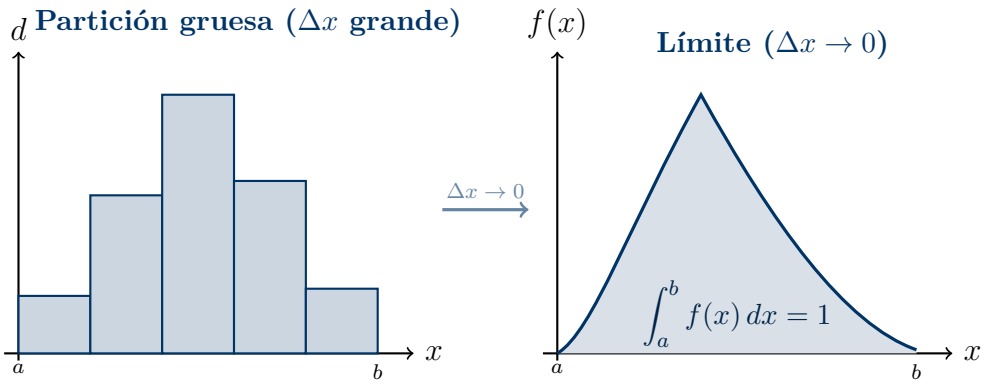


Figura 3.1: Al refinar la partición del histograma de densidad ($\Delta x \to 0$), las alturas de las barras convergen a una función continua $f(x)$. La probabilidad de un intervalo pasa de ser una suma de áreas de barras a ser el área bajo la curva.

Definición 3.1 — Variable aleatoria continua

Una variable aleatoria X es **continua** si existe una función $f : \mathbb{R} \to [0, \infty)$ tal que para todo intervalo $[a, b]$:

$$P(a \leq X \leq b) = \int_a^b f(x)\, dx.$$

3.2 Función de densidad de probabilidad

El argumento del histograma nos dejó con una función $f(x)$ tal que la probabilidad de un intervalo es el área bajo f en ese intervalo. Ahora formalizamos qué condiciones debe satisfacer f para ser una función de densidad válida — el análogo continuo de los axiomas de la función de masa.

Definición 3.2 — Función de densidad de probabilidad

Sea X una variable aleatoria continua. Una función $f : \mathbb{R} \to \mathbb{R}$ es una **función de densidad de probabilidad** (fdp) de X si satisface:

i) $f(x) \geq 0$ para todo $x \in \mathbb{R}$.

ii) $\displaystyle\int_{-\infty}^{\infty} f(x)\, dx = 1.$

iii) Para todo $a \leq b$:

$$P(a \leq X \leq b) = \int_a^b f(x)\, dx.$$

Observación. *El paralelo con la función de masa discreta es exacto: la condición **i** es la no negatividad ($p_X(x) \geq 0$), la condición **ii** es la normalización ($\sum_x p_X(x) =$*

*1), y la condición **iii** es el cálculo de probabilidades (suma → integral). La única diferencia estructural es que la suma se reemplaza por la integral en todo lugar.*

*Nótese además que $f(x)$ **no es una probabilidad** — es una* densidad. *Puede tomar valores mayores que 1; lo que debe ser menor o igual a 1 es el área bajo f en cualquier intervalo, no el valor de f en un punto.*

3.3 Función de distribución acumulada

Definición 3.3 — Función de distribución acumulada (continua)

Sea X una variable aleatoria continua con fdp f. La **función de distribución acumulada** de X es

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\,dt, \qquad x \in \mathbb{R}.$$

Proposición 3.1 — Propiedades de la FDA continua

Sea X una variable aleatoria continua con fdp f y FDA F. Entonces:

i) F es no decreciente: si $x_1 < x_2$ entonces $F(x_1) \leq F(x_2)$.

ii) $\lim_{x\to-\infty} F(x) = 0$.

iii) $\lim_{x\to\infty} F(x) = 1$.

iv) Para todo $a \leq b$: $P(a \leq X \leq b) = F(b) - F(a)$.

Demostración. **i)** Si $x_1 < x_2$, entonces

$$F(x_2) - F(x_1) = \int_{-\infty}^{x_2} f(t)\,dt - \int_{-\infty}^{x_1} f(t)\,dt = \int_{x_1}^{x_2} f(t)\,dt \geq 0,$$

donde la última desigualdad se sigue de que $f(t) \geq 0$ para todo t (condición **i** de la Definición 3.2).

ii) Por la condición **ii** de la Definición 3.2, $\int_{-\infty}^{\infty} f(t)\,dt = 1$, lo que implica en particular que f es integrable en $\mathbb{R}$. Para una función integrable, la integral sobre un intervalo $(-\infty, x]$ tiende a 0 cuando $x \to -\infty$:

$$\lim_{x\to-\infty} F(x) = \lim_{x\to-\infty} \int_{-\infty}^{x} f(t)\,dt = 0.$$

iii) Directamente de la condición **ii** de la Definición 3.2:

$$\lim_{x\to\infty} F(x) = \lim_{x\to\infty} \int_{-\infty}^{x} f(t)\,dt = \int_{-\infty}^{\infty} f(t)\,dt = 1.$$

iv) Por aditividad de la integral:

$$\int_{-\infty}^{b} f(t)\,dt = \int_{-\infty}^{a} f(t)\,dt + \int_{a}^{b} f(t)\,dt,$$

de modo que

$$P(a \le X \le b) = \int_{a}^{b} f(t)\,dt = F(b) - F(a).$$

■

La diferencia central con el caso discreto es que ahora F es continua y diferenciable, lo que permite recuperar la densidad a partir de la FDA vía el Teorema Fundamental del Cálculo.

Proposición 3.2 — Relación entre F y f

Sea X una variable aleatoria continua con fdp f y FDA F. En todo punto donde f es continua,

$$F'(x) = f(x).$$

Proposición 3.3 — Relación entre F y f

Sea X una variable aleatoria continua con fdp f y FDA F. En todo punto donde f es continua,

$$F'(x) = f(x).$$

Demostración. Recordamos primero el **Teorema Fundamental del Cálculo** (TFC): si g es una función continua en $[a, b]$ y se define

$$G(x) = \int_{a}^{x} g(t)\,dt, \qquad x \in [a, b],$$

entonces G es diferenciable en (a, b) y $G'(x) = g(x)$. Es decir, la derivada de una integral con límite superior variable recupera el integrando evaluado en ese límite.

Aplicamos este resultado a nuestra situación. Por definición,

$$F(x) = \int_{-\infty}^{x} f(t)\,dt.$$

En todo punto donde f es continua, el TFC garantiza que F es diferenciable y que

$$F'(x) = f(x).$$

■

Observación. *Esta proposición tiene una consecuencia práctica importante: si conocemos la FDA F, podemos recuperar la fdp simplemente derivando. Y*

recíprocamente, si conocemos la fdp f, podemos obtener la FDA integrando. Las dos funciones contienen la misma información sobre X — solo difieren en la forma de presentarla.

Esta proposición es la razón por la que f se llama *densidad*: así como la densidad física de un objeto es la derivada de su masa acumulada respecto a la posición, la fdp es la derivada de la probabilidad acumulada respecto a x. La FDA acumula; la fdp describe cómo se distribuye esa acumulación.

3.4 Valor esperado y varianza

Los conceptos de valor esperado y varianza se trasladan al caso continuo reemplazando la suma por la integral — la misma sustitución que hicimos en la fdp.

En el caso discreto, el valor esperado era una suma ponderada $\sum_x x\, p_X(x)$: cada valor posible se pesa por su probabilidad. En el caso continuo, la probabilidad de que X tome valores en un entorno infinitesimal de x es $f(x)\,dx$, de modo que la suma se convierte naturalmente en una integral. La definición es la única extensión consistente del caso discreto.

Definición 3.4 — Valor esperado continuo

Sea X una variable aleatoria continua con fdp f. El **valor esperado** de X es

$$E(X) = \int_{-\infty}^{\infty} x\, f(x)\, dx,$$

siempre que la integral converja absolutamente.

De manera análoga, la varianza se extiende al caso continuo reemplazando la suma por la integral. La interpretación es idéntica a la del caso discreto: mide la dispersión promedio de X alrededor de su media, ponderada ahora por la densidad en lugar de por la función de masa.

Definición 3.5 — Varianza continua

Sea X una variable aleatoria continua con fdp f y $\mu = E(X)$. La **varianza** de X es

$$\mathrm{Var}(X) = E\big[(X-\mu)^2\big] = \int_{-\infty}^{\infty} (x-\mu)^2\, f(x)\, dx,$$

y la **desviación estándar** es $\sigma_X = \sqrt{\mathrm{Var}(X)}$.

Observación. *La fórmula alternativa* $\mathrm{Var}(X) = E(X^2) - (E(X))^2$ *se mantiene válida en el caso continuo, con la misma demostración algebraica que en el caso*

discreto (Proposición 2.6). Las propiedades de linealidad del valor esperado y las propiedades de la varianza también se transfieren sin cambio.

3.5 Distribución Uniforme continua

La distribución uniforme continua modela una variable aleatoria que puede tomar cualquier valor en un intervalo $[a, b]$ con la misma probabilidad relativa. Esto impone una exigencia concreta sobre la fdp: debe ser **constante** en $[a, b]$, es decir $f(x) = c$ para alguna constante $c > 0$, y cero fuera del intervalo. La condición de normalización determina c unívocamente:

$$\int_{-\infty}^{\infty} f(x)\,dx = \int_a^b c\,dx = c(b-a) = 1 \implies c = \frac{1}{b-a}.$$

La fdp queda así completamente determinada por la sola exigencia de equiprobabilidad.

Definición 3.6 — Distribución Uniforme continua

Una variable aleatoria X tiene **distribución uniforme continua** en el intervalo $[a, b]$, con $a < b$, si su función de densidad de probabilidad es

$$f(x) = \begin{cases} \dfrac{1}{b-a} & \text{si } a \le x \le b, \\ 0 & \text{en otro caso.} \end{cases}$$

Se escribe $X \sim U(a, b)$.

Proposición 3.4 — FDA, valor esperado y varianza de la Uniforme

Si $X \sim U(a, b)$, entonces:

i) La función de distribución acumulada es

$$F(x) = \begin{cases} 0 & \text{si } x < a, \\ \dfrac{x-a}{b-a} & \text{si } a \le x < b, \\ 1 & \text{si } x \ge b. \end{cases}$$

ii) $E(X) = \dfrac{a+b}{2}$.

iii) $\mathrm{Var}(X) = \dfrac{(b-a)^2}{12}$.

Demostración. **i)** Para $x < a$: $F(x) = \int_{-\infty}^{x} 0\,dt = 0$.

Para $a \le x < b$:

$$F(x) = \int_{-\infty}^{x} f(t)\,dt = \int_{a}^{x} \frac{1}{b-a}\,dt = \frac{x-a}{b-a}.$$

Para $x \ge b$: $F(x) = \int_{-\infty}^{\infty} f(t)\,dt = 1$.

ii) Aplicando la definición de valor esperado continuo:

$$E(X) = \int_{-\infty}^{\infty} x\,f(x)\,dx = \int_{a}^{b} \frac{x}{b-a}\,dx = \frac{1}{b-a}\cdot\frac{x^2}{2}\bigg|_{a}^{b} = \frac{b^2-a^2}{2(b-a)} = \frac{(b+a)(b-a)}{2(b-a)} = \frac{a+b}{2}.$$

iii) Usamos la fórmula alternativa $\mathrm{Var}(X) = E(X^2) - (E(X))^2$. Calculamos $E(X^2)$:

$$E(X^2) = \int_{a}^{b} \frac{x^2}{b-a}\,dx = \frac{1}{b-a}\cdot\frac{x^3}{3}\bigg|_{a}^{b} = \frac{b^3-a^3}{3(b-a)} = \frac{(b^2+ab+a^2)(b-a)}{3(b-a)} = \frac{a^2+ab+b^2}{3}.$$

Por lo tanto:

$$\mathrm{Var}(X) = \frac{a^2+ab+b^2}{3} - \left(\frac{a+b}{2}\right)^2 = \frac{a^2+ab+b^2}{3} - \frac{a^2+2ab+b^2}{4}.$$

Llevando a denominador común 12:

$$\begin{aligned}
\mathrm{Var}(X) &= \frac{4(a^2+ab+b^2) - 3(a^2+2ab+b^2)}{12} \\
&= \frac{4a^2+4ab+4b^2-3a^2-6ab-3b^2}{12} \\
&= \frac{a^2-2ab+b^2}{12} \\
&= \frac{(b-a)^2}{12}.
\end{aligned}$$

■

Observación. *El valor esperado $E(X) = (a+b)/2$ es el punto medio del intervalo — exactamente lo que la intuición sugiere para una distribución completamente simétrica. La varianza $(b-a)^2/12$ crece con el cuadrado del largo del intervalo: mientras más amplio es $[a,b]$, más dispersa es X.*

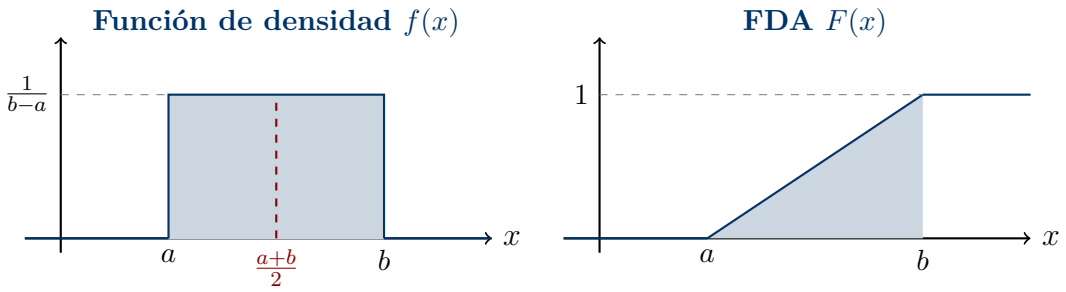


Figura 3.2: Función de densidad y FDA de $X \sim U(a, b)$. La fdp es un rectángulo de altura $1/(b-a)$ y la FDA es una rampa lineal entre a y b. La línea roja marca la media $E(X) = (a+b)/2$.

3.6 Distribución Exponencial

En la distribución de Poisson modelamos el número de eventos que ocurren en un intervalo de tiempo fijo, asumiendo una tasa promedio λ constante. Pero hay una pregunta dual que Poisson no responde directamente: ¿cuánto tiempo transcurre entre un evento y el siguiente? La distribución exponencial es la respuesta — y no por coincidencia usa el mismo parámetro λ.

Derivación de la fdp

Sea X el tiempo de espera hasta el próximo evento en un proceso de Poisson con tasa λ. Queremos encontrar la distribución de X. El punto de partida es calcular $P(X > x)$ — la probabilidad de que el próximo evento ocurra *después* de x unidades de tiempo.

El evento $\{X > x\}$ es equivalente a que no ocurra ningún evento en el intervalo $[0, x]$. Si Y denota el número de eventos en $[0, x]$, entonces $Y \sim \text{Poisson}(\lambda x)$ — la tasa es λ por unidad de tiempo, luego en x unidades la tasa es λx. Por lo tanto:

$$P(X > x) = P(Y = 0) = \frac{(\lambda x)^0 e^{-\lambda x}}{0!} = e^{-\lambda x}.$$

De aquí obtenemos la FDA de X directamente:

$$F(x) = P(X \leq x) = 1 - P(X > x) = 1 - e^{-\lambda x}, \qquad x \geq 0.$$

Aplicando la Proposición 3.3, la fdp se obtiene derivando la FDA:

$$f(x) = F'(x) = \lambda e^{-\lambda x}, \qquad x > 0.$$

La fdp no emerge de una postulación arbitraria — es la consecuencia directa de la estructura del proceso de Poisson subyacente.

Definición 3.7 — Distribución Exponencial

Una variable aleatoria continua X tiene **distribución exponencial** con parámetro $\lambda > 0$ si su función de densidad de probabilidad es

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x > 0, \\ 0 & \text{en otro caso.} \end{cases}$$

Se escribe $X \sim \text{Exp}(\lambda)$.

Observación. *La verificación de que f es una fdp válida es inmediata: $f(x) \geq 0$ para todo x, y*

$$\int_{-\infty}^{\infty} f(x)\,dx = \int_0^{\infty} \lambda e^{-\lambda x}\,dx = \lambda \cdot \left[-\frac{1}{\lambda} e^{-\lambda x}\right]_0^{\infty} = \left[-e^{-\lambda x}\right]_0^{\infty} = 0 - (-1) = 1.$$

Proposición 3.5 — FDA, valor esperado y varianza de la Exponencial

Si $X \sim \text{Exp}(\lambda)$ con $\lambda > 0$, entonces:

i) La función de distribución acumulada es

$$F(x) = \begin{cases} 0 & \text{si } x < 0, \\ 1 - e^{-\lambda x} & \text{si } x \geq 0. \end{cases}$$

ii) $E(X) = \dfrac{1}{\lambda}$.

iii) $\text{Var}(X) = \dfrac{1}{\lambda^2}$.

Demostración. **i)** Ya fue derivada en la sección anterior.

ii) Aplicamos la definición de valor esperado:

$$E(X) = \int_0^{\infty} x \cdot \lambda e^{-\lambda x}\,dx = \lambda \int_0^{\infty} x e^{-\lambda x}\,dx.$$

Integramos por partes con $u = x$, $dv = e^{-\lambda x}\,dx$, luego $du = dx$, $v = -\frac{1}{\lambda} e^{-\lambda x}$:

$$\int_0^{\infty} x e^{-\lambda x}\,dx = \left[-\frac{x}{\lambda} e^{-\lambda x}\right]_0^{\infty} + \int_0^{\infty} \frac{1}{\lambda} e^{-\lambda x}\,dx.$$

El primer término se anula en ambos extremos: en $x = 0$ da 0, y cuando $x \to \infty$,

$xe^{-\lambda x} \to 0$ porque la exponencial domina al polinomio. El segundo término:

$$\int_0^\infty \frac{1}{\lambda} e^{-\lambda x}\, dx = \frac{1}{\lambda}\left[-\frac{1}{\lambda}e^{-\lambda x}\right]_0^\infty = \frac{1}{\lambda^2}.$$

Por lo tanto:

$$E(X) = \lambda \cdot \frac{1}{\lambda^2} = \frac{1}{\lambda}.$$

iii) Usamos la fórmula alternativa $\mathrm{Var}(X) = E(X^2) - (E(X))^2$. Calculamos $E(X^2)$ integrando por partes dos veces con $u = x^2$, $dv = e^{-\lambda x}\, dx$:

$$E(X^2) = \lambda \int_0^\infty x^2 e^{-\lambda x}\, dx = \lambda\left(\left[-\frac{x^2}{\lambda}e^{-\lambda x}\right]_0^\infty + \frac{2}{\lambda}\int_0^\infty xe^{-\lambda x}\, dx\right).$$

El término evaluado se anula por el mismo argumento que antes. El integral restante ya lo calculamos en **ii)**: $\int_0^\infty xe^{-\lambda x}\, dx = 1/\lambda^2$. Entonces:

$$E(X^2) = \lambda \cdot \frac{2}{\lambda} \cdot \frac{1}{\lambda^2} = \frac{2}{\lambda^2}.$$

Por lo tanto:

$$\mathrm{Var}(X) = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}.$$

■

Observación. *El valor esperado $E(X) = 1/\lambda$ tiene una interpretación directa: si los eventos ocurren a tasa λ por unidad de tiempo, el tiempo promedio de espera entre eventos es $1/\lambda$. Esto cierra la conexión con Poisson: si $\lambda = 5$ eventos por hora, el tiempo promedio entre eventos es $1/5$ de hora, es decir, 12 minutos.*

La distribución exponencial tiene una propiedad que la hace única entre las distribuciones continuas y que resulta fundamental en aplicaciones de confiabilidad y teoría de colas.

Proposición 3.6 — Propiedad de falta de memoria

Si $X \sim \mathrm{Exp}(\lambda)$, entonces para todo $s, t > 0$:

$$P(X > s + t \mid X > s) = P(X > t).$$

Demostración. Aplicando la definición de probabilidad condicional y usando que $P(X > x) = e^{-\lambda x}$:

$$P(X > s{+}t \mid X > s) = \frac{P(X > s + t,\ X > s)}{P(X > s)} = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t).$$

■

Observación. *La propiedad de falta de memoria dice que el tiempo de espera restante no depende del tiempo ya esperado. Si X es la vida útil de un componente y el componente ha sobrevivido s horas, la probabilidad de que sobreviva t horas más es exactamente la misma que si fuera nuevo. El componente no* recuerda *cuánto tiempo lleva funcionando — no se desgasta en sentido probabilístico. Esta propiedad caracteriza a la distribución exponencial: es la* ***única*** *distribución continua con falta de memoria.*

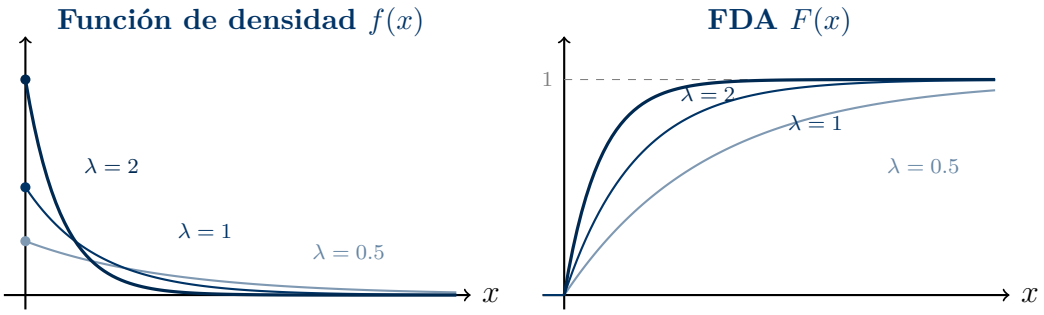


Figura 3.3: Función de densidad y FDA de $X \sim \text{Exp}(\lambda)$ para distintos valores de λ. A mayor λ, la densidad cae más rápidamente y la FDA satura antes — el tiempo de espera promedio $1/\lambda$ es menor.

3.7 Distribución Normal

La distribución Normal es la más importante de toda la estadística. Aparece en fenómenos tan distintos como las alturas de una población, los errores de medición en un experimento físico, o las fluctuaciones de precios en un mercado financiero. Su ubicuidad no es accidental — tiene una justificación matemática profunda que exploraremos en la subsección siguiente. Por ahora la introducimos formalmente.

Definición 3.8 — Distribución Normal

Una variable aleatoria continua X tiene **distribución Normal** con parámetros $\mu \in \mathbb{R}$ y $\sigma^2 > 0$ si su función de densidad de probabilidad es

$$f(x) = \frac{1}{\sqrt{2\pi}\,\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \qquad x \in \mathbb{R}.$$

Se escribe $X \sim N(\mu, \sigma^2)$.

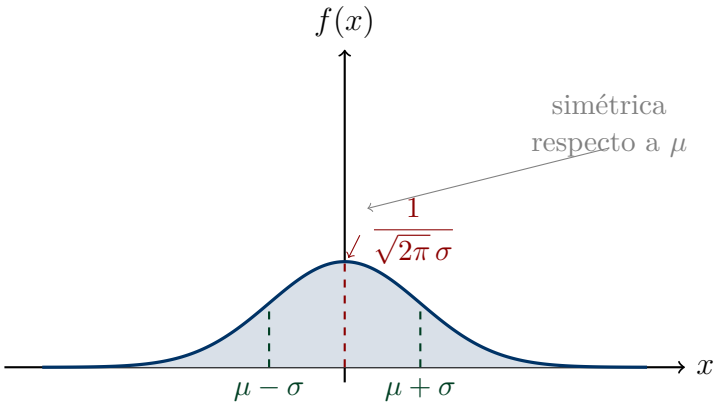


Figura 3.4: Función de densidad de $X \sim N(\mu, \sigma^2)$. La curva es simétrica respecto a μ, alcanza su máximo en $x = \mu$ con altura $1/(\sqrt{2\pi}\,\sigma)$, y tiene puntos de inflexión en $\mu \pm \sigma$.

Observación. *La fdp Normal tiene tres propiedades geométricas que se desprenden directamente de su fórmula:*

i) *Es* ***simétrica*** *respecto a $x = \mu$ — el exponente $(x-\mu)^2$ es el mismo para $\mu + t$ y $\mu - t$.*

ii) *Alcanza su* ***máximo*** *en $x = \mu$, donde $f(\mu) = 1/(\sqrt{2\pi}\,\sigma)$.*

iii) *Las* ***colas*** *decaen a cero cuando $x \to \pm\infty$, más rápidamente cuanto menor es σ.*

El parámetro μ controla la ubicación *de la curva y σ controla su* dispersión*: una σ pequeña produce una campana alta y estrecha; una σ grande produce una campana baja y ancha.*

3.7.1 ¿Por qué $\sqrt{2\pi}$?

La fórmula de la fdp Normal no es arbitraria. Cada uno de sus componentes — la exponencial cuadrática, la constante $\sqrt{2\pi}$ — tiene una justificación matemática precisa. Para entenderla es útil remontarse a su origen histórico.

A mediados del siglo XIX, tres matemáticos llegaron a la misma función por caminos completamente distintos: **Carl Friedrich Gauss** desde la teoría de errores de medición astronómica, **Pierre-Simon Laplace** desde la combinatoria y los límites de distribuciones binomiales, y **James Clerk Maxwell** — el mismo de las ecuaciones del electromagnetismo — desde la física cinética de los gases. Que tres rutas tan distintas converjan a la misma función es la primera señal de que algo profundo está ocurriendo.

El argumento de Maxwell

En 1860, Maxwell quería describir cómo se distribuyen las velocidades de las moléculas de un gas. Postuló dos condiciones que parecen muy razonables:

i) **Isotropía:** la distribución de velocidades en cada dirección (x, y, z) es la misma función f. No hay ninguna dirección privilegiada.

ii) **Independencia direccional:** las velocidades en distintas direcciones son independientes entre sí.

Si $v^2 = v_x^2 + v_y^2 + v_z^2$ es la rapidez total, la probabilidad conjunta debe depender solo de v^2 — no de la dirección. Esto impone la condición funcional:

$$f(v_x) \cdot f(v_y) \cdot f(v_z) = g(v_x^2 + v_y^2 + v_z^2).$$

Tomando logaritmo:

$$\ln f(v_x) + \ln f(v_y) + \ln f(v_z) = \ln g(v_x^2 + v_y^2 + v_z^2).$$

La única familia de funciones que satisface esta ecuación funcional es

$$f(t) = c\, e^{-\alpha t^2}, \qquad \alpha > 0,$$

para alguna constante $c > 0$. La demostración es la siguiente: diferenciando la ecuación funcional respecto a v_x con v_y y v_z fijos, se obtiene que $(\ln f)'(v_x)$ debe ser proporcional a v_x, lo que implica $\ln f(t) = -\alpha t^2 + \text{cte}$, y por lo tanto $f(t) = ce^{-\alpha t^2}$.

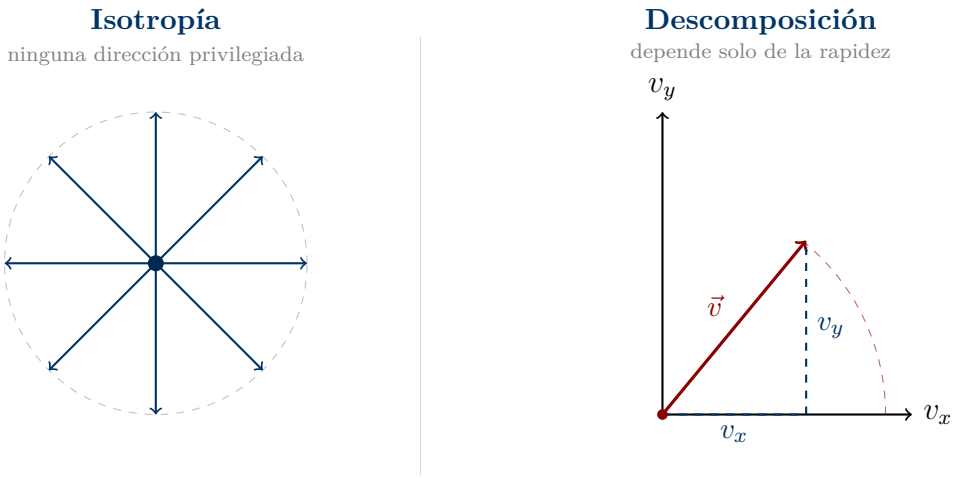


Figura 3.5: El argumento de Maxwell. **Izquierda:** la isotropía exige que la distribución de velocidades sea la misma en todas las direcciones — no hay ninguna dirección privilegiada. **Derecha:** al descomponer la velocidad en componentes v_x y v_y, la condición de que la distribución conjunta dependa solo de la rapidez $v = \sqrt{v_x^2 + v_y^2}$ — es decir, que sea constante sobre cada circunferencia — es la que fuerza la forma gaussiana.

Observación. *Maxwell no buscaba justificar la distribución Normal — buscaba entender el movimiento molecular. Pero las dos condiciones que postuló (isotropía e independencia direccional) son tan naturales que la gaussiana emerge como la* ***única solución posible****. La campana no se elige: se impone.*

La integral gaussiana y el origen de $\sqrt{2\pi}$

El argumento de Maxwell justifica que la fdp tiene la forma $ce^{-\alpha x^2}$. Para que sea una fdp válida debe integrar a 1, lo que requiere calcular:

$$I = \int_{-\infty}^{\infty} e^{-x^2/2}\, dx.$$

Esta integral no tiene antiderivada elemental — no se puede resolver con las técnicas estándar de cálculo. El truco clásico es elevar I al cuadrado y convertir la integral doble resultante a coordenadas polares.

Proposición 3.7 — Integral gaussiana

$$\int_{-\infty}^{\infty} e^{-x^2/2}\, dx = \sqrt{2\pi}.$$

Demostración. Llamemos $I = \int_{-\infty}^{\infty} e^{-x^2/2}\, dx$. Entonces:

$$I^2 = \left(\int_{-\infty}^{\infty} e^{-x^2/2}\, dx\right)\left(\int_{-\infty}^{\infty} e^{-y^2/2}\, dy\right) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} e^{-(x^2+y^2)/2}\, dx\, dy.$$

Pasamos a coordenadas polares: $x = r\cos\theta$, $y = r\sin\theta$, con $r \geq 0$ y $\theta \in [0, 2\pi)$. El jacobiano de la transformación es r, y $x^2 + y^2 = r^2$:

$$I^2 = \int_0^{2\pi} \int_0^{\infty} e^{-r^2/2}\, r\, dr\, d\theta = 2\pi \int_0^{\infty} r\, e^{-r^2/2}\, dr.$$

La integral restante se resuelve con la sustitución $u = r^2/2$, $du = r\, dr$:

$$\int_0^{\infty} r\, e^{-r^2/2}\, dr = \int_0^{\infty} e^{-u}\, du = \left[-e^{-u}\right]_0^{\infty} = 1.$$

Por lo tanto $I^2 = 2\pi$, y como $I > 0$:

$$I = \int_{-\infty}^{\infty} e^{-x^2/2}\, dx = \sqrt{2\pi}.$$

■

La constante $1/\sqrt{2\pi}$ en la fdp Normal es exactamente la constante de normalización que garantiza que f integre a 1 — ni más ni menos. El $\sqrt{2\pi}$ no es un número misterioso: es el área bajo la curva $e^{-x^2/2}$, calculada por el argumento de coordenadas polares.

Proposición 3.8 — Momentos de la distribución Normal

Si $X \sim N(\mu, \sigma^2)$, entonces

$$E(X) = \mu \qquad \text{y} \qquad \text{Var}(X) = \sigma^2.$$

Demostración. Hacemos el cambio de variable $z = (x - \mu)/\sigma$, de modo que $x = \mu + \sigma z$ y $dx = \sigma\, dz$.

Valor esperado.

$$E(X) = \int_{-\infty}^{\infty} x\, \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\, dx = \int_{-\infty}^{\infty} (\mu + \sigma z)\, \frac{1}{\sqrt{2\pi}}\, e^{-z^2/2}\, dz.$$

Separamos en dos integrales:

$$= \mu \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}}\, e^{-z^2/2}\, dz + \sigma \int_{-\infty}^{\infty} z\, \frac{1}{\sqrt{2\pi}}\, e^{-z^2/2}\, dz.$$

La primera integral es 1 por la Proposición 3.7. La segunda es 0 porque el integrando $z\, e^{-z^2/2}$ es una función **impar** — y la integral de una función impar sobre $(-\infty, \infty)$ es cero. Por lo tanto:

$$E(X) = \mu \cdot 1 + \sigma \cdot 0 = \mu.$$

Varianza. Usamos la fórmula alternativa $\text{Var}(X) = E[(X - \mu)^2]$. Con el mismo

cambio de variable:

$$\mathrm{Var}(X) = \int_{-\infty}^{\infty} (x-\mu)^2 \, \frac{1}{\sqrt{2\pi}\,\sigma} \, e^{-\frac{(x-\mu)^2}{2\sigma^2}} \, dx = \sigma^2 \int_{-\infty}^{\infty} z^2 \, \frac{1}{\sqrt{2\pi}} \, e^{-z^2/2} \, dz.$$

Integramos por partes con $u = z$ y $dv = z\, e^{-z^2/2}\, dz$, luego $du = dz$ y $v = -e^{-z^2/2}$:

$$\int_{-\infty}^{\infty} z^2 \, e^{-z^2/2} \, dz = \Big[-z\, e^{-z^2/2}\Big]_{-\infty}^{\infty} + \int_{-\infty}^{\infty} e^{-z^2/2} \, dz.$$

El término evaluado se anula en ambos extremos porque $z\, e^{-z^2/2} \to 0$ cuando $z \to \pm\infty$. La integral restante es $\sqrt{2\pi}$ por la Proposición 3.7. Por lo tanto:

$$\mathrm{Var}(X) = \frac{\sigma^2}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = \sigma^2.$$

■

Observación. *El argumento de Maxwell y la integral gaussiana explican la* ***forma*** *de la fdp Normal — por qué el exponente es cuadrático y de dónde viene* $\sqrt{2\pi}$*. Pero no responden la pregunta más importante: ¿por qué la Normal aparece en fenómenos tan distintos como alturas, errores de medición y precios financieros? La respuesta no está en la física de los gases sino en un resultado matemático profundo que estudiaremos a continuación: el* ***Teorema del Límite Central****, que establece que la suma de un gran número de variables aleatorias independientes converge a una distribución Normal, independientemente de la distribución original de cada una. Esa es la verdadera razón de la ubicuidad de la Normal.*

3.7.2 La distribución Normal estándar

La fdp Normal depende de dos parámetros: μ y σ^2. Para calcular probabilidades habría que integrar numéricamente para cada par (μ, σ^2) distinto. La solución es trabajar con un caso de referencia y mostrar que toda Normal general puede reducirse a él. Definimos ese caso de referencia y demostramos la reducción inmediatamente después.

La **distribución Normal estándar** es el caso particular $\mu = 0$ y $\sigma^2 = 1$ de la Definición 3.8. Sustituyendo directamente:

$$f(x)\Big|_{\mu=0,\,\sigma^2=1} = \frac{1}{\sqrt{2\pi}} \, e^{-z^2/2} =: \phi(z).$$

Definición 3.9 — Distribución Normal estándar

Una variable aleatoria $Z \sim N(0,1)$ tiene **distribución Normal estándar**, con fdp $\phi(z) = \frac{1}{\sqrt{2\pi}}\, e^{-z^2/2}$ y FDA

$$\Phi(z) = P(Z \le z) = \int_{-\infty}^{z} \phi(t)\, dt, \qquad z \in \mathbb{R}.$$

La función Φ no admite forma cerrada y debe tabularse o calcularse numéricamente.

Proposición 3.9 — Simetría de la Normal estándar

Para todo $z \in \mathbb{R}$:

$$\Phi(-z) = 1 - \Phi(z).$$

Demostración. Como ϕ es simétrica respecto a cero — $\phi(-z) = \phi(z)$ para todo z — se tiene:

$$\Phi(-z) = \int_{-\infty}^{-z} \phi(t)\, dt = \int_{z}^{\infty} \phi(t)\, dt = 1 - \int_{-\infty}^{z} \phi(t)\, dt = 1 - \Phi(z).$$

■

Observación. *Esta proposición es la herramienta práctica más usada al trabajar con la tabla de la Normal estándar: permite calcular probabilidades en la cola izquierda a partir de la cola derecha, y viceversa. Por ejemplo,* $P(Z \le -1.96) = 1 - P(Z \le 1.96) = 1 - \Phi(1.96)$.

Proposición 3.10 — Estandarización

Si $X \sim N(\mu, \sigma^2)$, entonces

$$Z = \frac{X - \mu}{\sigma} \sim N(0,1).$$

Demostración. Calculamos la FDA de Z. Para $z \in \mathbb{R}$:

$$P(Z \le z) = P\left(\frac{X-\mu}{\sigma} \le z\right) = P(X \le \mu + \sigma z) = \int_{-\infty}^{\mu+\sigma z} \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\, dx.$$

Sustituimos $t = (x-\mu)/\sigma$, $dt = dx/\sigma$:

$$= \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\, dt = \Phi(z).$$

Como la FDA de Z es Φ, se concluye que $Z \sim N(0,1)$. ■

Observación. *La estandarización tiene una interpretación directa: Z mide cuántas desviaciones estándar se aleja X de su media. Es la transformación que hace que todas las Normales sean comparables entre sí y que una sola tabla — la de Φ — sea suficiente para calcular cualquier probabilidad Normal. Para calcular $P(X \leq x)$ con $X \sim N(\mu, \sigma^2)$:*

$$P(X \leq x) = P\left(Z \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

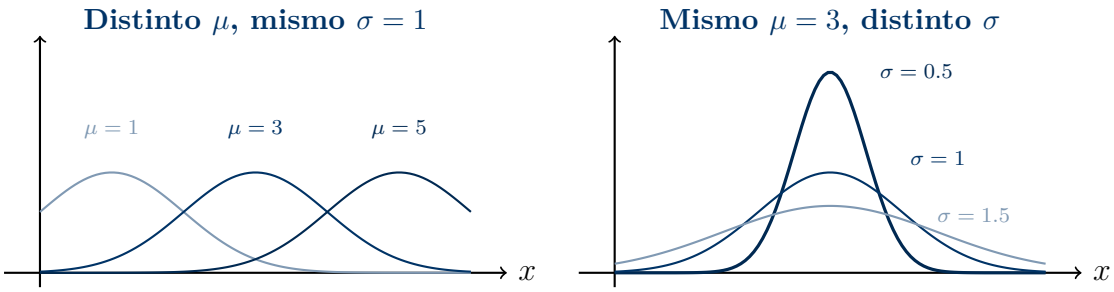


Figura 3.6: Izquierda: distintas medias μ con $\sigma = 1$ — μ desplaza la curva sin cambiar su forma. Derecha: misma media $\mu = 3$ con distintas σ — σ controla el ancho y la altura de la campana.

En la práctica, el objetivo es calcular probabilidades del tipo $P(a \leq X \leq b)$ para $X \sim N(\mu, \sigma^2)$. La Proposición 3.10 reduce este problema a uno sobre la Normal estándar:

$$P(a \leq X \leq b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right).$$

El problema entonces es evaluar $\Phi(z)$ — y aquí aparece la dificultad: la integral $\int_{-\infty}^{z} \phi(t)\, dt$ no tiene forma cerrada, es decir, no puede expresarse en términos de funciones elementales. Por eso se recurre a **tablas numéricas** que precalculan $\Phi(z)$ para una grilla de valores de z, o a software estadístico. El procedimiento concreto para calcular cualquier probabilidad Normal es:

1. **Estandarizar** los límites: $z_a = (a-\mu)/\sigma$ y $z_b = (b-\mu)/\sigma$.
2. **Buscar** $\Phi(z_a)$ y $\Phi(z_b)$ en la tabla o software.
3. **Restar:** $P(a \leq X \leq b) = \Phi(z_b) - \Phi(z_a)$.

La propiedad de simetría $\Phi(-z) = 1 - \Phi(z)$ (Proposición 3.9) es útil cuando la tabla solo cubre valores positivos de z: basta con cambiar el signo y complementar a 1.

Tema 4

Muestreo y distribución de muestreo

4.1 Población, muestra y parámetro

En los capítulos anteriores trabajamos con variables aleatorias cuya distribución era completamente conocida: sabíamos que $X \sim N(\mu, \sigma^2)$ con valores específicos de μ y σ^2, y calculábamos probabilidades a partir de eso. En la práctica, sin embargo, ocurre algo distinto: a menudo tenemos razones para creer que una variable sigue cierto *tipo* de distribución — una Normal, una Poisson, una Exponencial — pero **no conocemos los parámetros específicos** que la determinan. Sabemos que las alturas de una población se distribuyen normalmente, pero no sabemos cuáles son μ y σ^2. Sabemos que las llegadas a un servidor siguen un proceso de Poisson, pero no conocemos λ.

El problema central de la inferencia estadística es precisamente este: dado que conocemos la *familia* de distribuciones a la que pertenece la variable de interés, ¿cómo estimamos el parámetro desconocido que la identifica dentro de esa familia? La herramienta es la **muestra** — un conjunto de observaciones generadas por la distribución real — y el objetivo es usar esas observaciones para aprender algo sobre el parámetro desconocido. Este capítulo formaliza ese proceso.

Definición 4.1 — Familia indexada

Sea Θ un conjunto no vacío. Una **familia indexada** por Θ es una función

$$\theta \mapsto P_\theta$$

que asigna a cada elemento $\theta \in \Theta$ un objeto P_θ de alguna colección. El conjunto Θ se denomina **conjunto de índices** y cada θ es un **índice**.

Observación. *La indexación no es más que una función con notación distinta. En lugar de escribir $f(\theta)$ para el objeto asociado a θ, escribimos P_θ — el índice*

aparece como subíndice en lugar de argumento. La razón es puramente notacional: cuando los objetos son distribuciones de probabilidad, P_θ es más natural que $P(\theta)$, que podría confundirse con la probabilidad de un evento θ.

En el caso de una familia paramétrica, los objetos indexados son distribuciones de probabilidad y el conjunto de índices Θ es el espacio paramétrico. Decir que $\mathcal{F} = \{P_\theta : \theta \in \Theta\}$ está indexada por Θ significa simplemente que existe una función biunívoca entre Θ y las distribuciones de $\mathcal{F}$ — cada θ determina unívocamente una distribución y cada distribución corresponde a exactamente un θ.

Definición 4.2 — Familia paramétrica

Sea $\Theta \subseteq \mathbb{R}^k$ un conjunto llamado **espacio paramétrico**. Una **familia paramétrica** es una colección de distribuciones de probabilidad indexada por Θ:

$$\mathcal{F} = \{P_\theta : \theta \in \Theta\},$$

donde cada $\theta \in \Theta$ determina unívocamente una distribución P_θ.

Definición 4.3 — Población

Dada una familia paramétrica $\mathcal{F} = \{P_\theta : \theta \in \Theta\}$, la **población** es la distribución $P_{\theta_0} \in \mathcal{F}$ que gobierna la variable de interés, donde $\theta_0 \in \Theta$ es el **verdadero valor del parámetro** — fijo pero desconocido.

Definición 4.4 — Parámetro

El **parámetro** es el valor $\theta_0 \in \Theta$ que indexa la población real P_{θ_0}. Los parámetros más comunes son escalares como la media μ o la tasa λ, o vectores como (μ, σ^2) en el caso Normal.

Observación. *La distinción entre familia y población es fundamental. La* familia *$\mathcal{F}$ es el conocimiento previo que traemos al problema — el tipo de distribución que creemos describe el fenómeno. La* población *P_{θ_0} es la distribución específica dentro de esa familia que realmente opera en el mundo, pero cuyo parámetro θ_0 desconocemos. El objetivo de la inferencia estadística es estimar θ_0 a partir de datos observados.*

Definición 4.5 — Muestra

Una **muestra** de tamaño n es un conjunto de observaciones $\{x_1, x_2, \ldots, x_n\}$ generadas por la población P_{θ_0}.

En términos simples:

- La **población** es el fenómeno completo que queremos estudiar — la distribución real que gobierna la variable de interés. Existe, es fija, pero no la conocemos completamente.

- El **parámetro** es el número (o números) que describen esa población. Conocer el parámetro equivale a conocer la población: si supiéramos que las alturas siguen $N(170, 49)$, sabríamos todo lo que hay que saber sobre su distribución. El problema es que θ_0 es desconocido.

- La **muestra** es el subconjunto de observaciones que podemos obtener. Es nuestra única ventana hacia la población — a partir de ella intentamos inferir θ_0.

El objetivo de la inferencia estadística es usar la muestra para aprender sobre el parámetro, sabiendo que nunca tendremos acceso directo a la población completa.

4.2 Muestra aleatoria

Para que las conclusiones extraídas de una muestra sean válidas, la selección de sus elementos no puede ser arbitraria. La forma más rigurosa de garantizar esto es modelar cada observación como una variable aleatoria independiente con la misma distribución poblacional.

Definición 4.6 — Muestra aleatoria

Las variables aleatorias $X_1, X_2, \ldots, X_n$ constituyen una **muestra aleatoria** de tamaño n de la población P_{θ_0} si son independientes e idénticamente distribuidas (i.i.d.) con distribución P_{θ_0}.

Observación. *Esta definición es exactamente la misma que la de variables i.i.d. introducida en la Definición 2.10. La muestra aleatoria no es un concepto nuevo — es el mismo objeto matemático aplicado ahora a un contexto de inferencia. Cada X_i representa el resultado de observar un elemento de la población seleccionado al azar; la independencia garantiza que ninguna observación influye sobre las demás, y la identidad de distribución garantiza que todas provienen de la misma población P_{θ_0}.*

Esta definición supone implícitamente que la población es suficientemente grande para que la extracción de cada elemento no altere la distribución de los restantes — es decir, se asume muestreo con reposición o una población infinita.

4.3 Estadístico y estimador

A partir de una muestra aleatoria $X_1, \ldots, X_n$ podemos calcular distintas funciones de los datos. Cada una de esas funciones es un **estadístico**.

Definición 4.7 — Estadístico

Un **estadístico** es cualquier función

$$T = g(X_1, X_2, \ldots, X_n)$$

de las observaciones de una muestra aleatoria que no depende de parámetros desconocidos. Un estadístico es en sí mismo una variable aleatoria — su valor varía de muestra en muestra.

Observación. *La condición de que el estadístico no dependa de parámetros desconocidos es esencial: si T dependiera de θ_0, no podríamos calcularlo sin conocer precisamente lo que queremos estimar. Un estadístico debe ser computable directamente a partir de los datos observados.*

Que un estadístico sea una variable aleatoria es fundamental: no tiene un valor fijo, sino una distribución propia — la ***distribución muestral*** *— que depende de la distribución de la población P_{θ_0}. Estudiar esa distribución es lo que permite hacer inferencia sobre θ_0.*

Cuando un estadístico se usa específicamente para aproximar un parámetro desconocido, se denomina **estimador**.

Definición 4.8 — Estimador y estimación puntual

Un **estimador puntual** de θ_0 es un estadístico $\hat{\theta} = g(X_1, \ldots, X_n)$ usado para aproximar θ_0. Una vez observada la muestra $(x_1, \ldots, x_n)$, el valor numérico $\hat{\theta}(x_1, \ldots, x_n)$ se denomina **estimación puntual** de θ_0.

Observación. *La distinción entre estimador y estimación es análoga a la distinción entre variable aleatoria y realización: el estimador $\hat{\theta}$ es la* regla*, expresada antes de observar los datos; la estimación es el* número *que resulta de aplicar esa regla a los datos observados. Por ejemplo, la media muestral*

$$\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$$

es un estimador de μ; el valor $\bar{x} = 28.75$ calculado de una muestra particular es una estimación.

4.4 Propiedades de los estimadores puntuales

Un parámetro θ_0 puede tener muchos estimadores distintos. ¿Cómo elegir entre ellos? La respuesta no es arbitraria — existen criterios matemáticos precisos que permiten evaluar la calidad de un estimador. Estudiaremos tres: **insesgadez**, **eficiencia** y **consistencia**. Cada uno responde una pregunta distinta sobre el comportamiento del estimador.

4.4.1 Insesgadez

La primera pregunta que podemos hacerle a un estimador es la más básica: ¿apunta en la dirección correcta? Un estimador que sistemáticamente sobreestima o subestima θ_0 tiene un error estructural que no desaparece sin importar cuántos datos tengamos. La insesgadez formaliza la ausencia de ese error sistemático.

Definición 4.9 — Estimador insesgado

Un estimador $\hat{\theta}$ de θ_0 es **insesgado** si

$$E_{\theta_0}(\hat{\theta}) = \theta_0 \qquad \text{para todo } \theta_0 \in \Theta.$$

La cantidad

$$B(\hat{\theta}) = E_{\theta_0}(\hat{\theta}) - \theta_0$$

se denomina **sesgo** del estimador. Si $B(\hat{\theta}) = 0$, el estimador es insesgado.

Observación. *La notación E_{θ_0} enfatiza que el valor esperado se calcula bajo la distribución P_{θ_0} — asumiendo que el verdadero parámetro es θ_0. La condición debe valer para* todo $\theta_0 \in \Theta$*: un estimador insesgado apunta al parámetro correcto sin importar cuál sea ese parámetro.*

La insesgadez no garantiza que una estimación particular sea exacta — solo garantiza que el estimador no tiene un error sistemático. En cualquier muestra concreta, $\hat{\theta}$ puede diferir de θ_0; lo que la insesgadez asegura es que esas diferencias se cancelan en promedio.

Observación. *El **principio de estimación insesgada** establece que, ante varios estimadores de θ_0, se prefiere uno insesgado. Si todos son insesgados, se aplica el criterio de eficiencia que se describe a continuación.*

4.4.2 Eficiencia

Dos estimadores pueden ser ambos insesgados — ambos apuntan en la dirección correcta en promedio — y aun así diferir en cuán dispersas son sus estimaciones

alrededor de θ_0. El que produce estimaciones más concentradas cerca del parámetro verdadero es preferible. La eficiencia formaliza esta comparación.

Definición 4.10 — Eficiencia relativa

Sean $\hat{\theta}_1$ y $\hat{\theta}_2$ dos estimadores insesgados de θ_0. Se dice que $\hat{\theta}_1$ es **más eficiente** que $\hat{\theta}_2$ si

$$\mathrm{Var}_{\theta_0}(\hat{\theta}_1) \mathrm{Var}_{\theta_0}(\hat{\theta}_2) \qquad \text{para todo } \theta_0 \in \Theta.$$

Observación. *La raíz cuadrada de la varianza del estimador,*

$$\mathrm{SE}(\hat{\theta}) = \sqrt{\mathrm{Var}_{\theta_0}(\hat{\theta})},$$

se denomina ***error estándar*** *del estimador y es la medida práctica más usada de su precisión. Un estimador con menor error estándar produce estimaciones más estables y más cercanas a θ_0 de muestra en muestra.*

Por ahora comparamos estimadores de a pares. En la Sección 4.6 veremos que el Teorema de Cramér-Rao establece una cota absoluta — la menor varianza que puede tener cualquier estimador insesgado — lo que permitirá hablar de eficiencia en un sentido más fuerte que la mera comparación entre dos estimadores.

La figura de los tiradores ilustra la diferencia entre insesgadez y eficiencia. El centro de la diana representa θ_0; cada disparo representa una estimación obtenida de una muestra distinta.

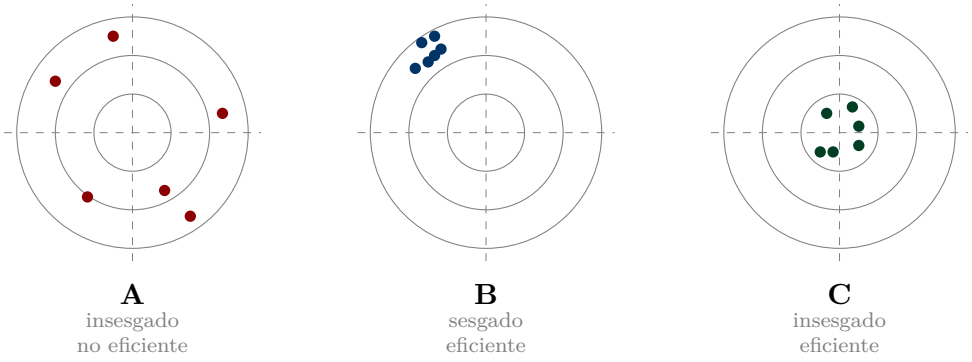


Figura 4.1: Analogía entre estimadores y tiradores. El centro de la diana representa θ_0. Cada punto es una estimación obtenida de una muestra distinta. El estimador A es insesgado pero no eficiente: las estimaciones se centran en θ_0 pero son muy dispersas. El estimador B es eficiente pero sesgado: las estimaciones son muy concentradas pero apuntan sistemáticamente al lugar equivocado. El estimador C es insesgado **y** eficiente: el ideal.

4.4.3 Consistencia

Los criterios de insesgadez y eficiencia evalúan el estimador para un tamaño de muestra n fijo. La consistencia evalúa su comportamiento cuando n crece: ¿mejora el estimador a medida que tenemos más datos?

Definición 4.11 — Estimador consistente

Un estimador $\hat{\theta}_n$ de θ_0 es **consistente** si converge en probabilidad a θ_0 cuando $n \to \infty$: para todo $\varepsilon > 0$ y todo $\theta_0 \in \Theta$,

$$\lim_{n\to\infty} P_{\theta_0}\Big(|\hat{\theta}_n - \theta_0| > \varepsilon\Big) = 0.$$

Observación. *La consistencia es una propiedad asintótica: garantiza que con suficientes datos el estimador puede aproximar θ_0 con tanta precisión como se desee. Es una condición mínima deseable — un estimador que no mejora con más datos es de poco valor práctico.*

Un criterio suficiente para la consistencia, y el más utilizado en la práctica, es que el sesgo y la varianza del estimador converjan ambos a cero cuando $n \to \infty$:

$$B(\hat{\theta}_n) \to 0 \qquad y \qquad \mathrm{Var}_{\theta_0}(\hat{\theta}_n) \to 0 \qquad cuando\ n \to \infty.$$

*Este criterio suficiente se justifica formalmente mediante la **desigualdad de Chebyshev**:*

$$P_{\theta_0}(|\hat{\theta}_n - \theta_0| > \varepsilon) \leq \frac{E_{\theta_0}[(\hat{\theta}_n - \theta_0)^2]}{\varepsilon^2} = \frac{\mathrm{Var}_{\theta_0}(\hat{\theta}_n) + B(\hat{\theta}_n)^2}{\varepsilon^2}.$$

Si sesgo y varianza convergen a cero, el lado derecho converge a cero para todo $\varepsilon > 0$, lo que establece la consistencia.

4.5 Función de verosimilitud e información de Fisher

En la sección anterior definimos la eficiencia como la comparación de varianzas entre estimadores insesgados. Pero esa definición es relativa — solo dice que $\hat{\theta}_1$ es mejor que $\hat{\theta}_2$, sin responder si existe un límite absoluto a cuán preciso puede ser cualquier estimador insesgado. Las preguntas que quedan abiertas son tres:

- ¿Existe una varianza mínima que ningún estimador insesgado puede superar?
- Si existe, ¿de qué depende ese límite?

- ¿Hay algún estimador que lo alcance?

La respuesta a las tres viene del Teorema de Cramér-Rao, que estudiaremos en la sección siguiente. Pero para llegar ahí necesitamos primero un concepto nuevo: cuánta **información** contienen los datos sobre el parámetro θ_0. La intuición es directa: si los datos son muy informativos sobre θ_0, es posible construir estimadores muy precisos. Si los datos contienen poca información, ningún estimador podrá ser preciso — hay un límite impuesto por los propios datos. Formalizar esa intuición requiere primero introducir la **función de verosimilitud**.

4.5.1 Función de verosimilitud

Dada una muestra observada $x_1, x_2, \ldots, x_n$, distintos valores de θ hacen que esa muestra sea más o menos probable. La pregunta natural es: ¿cuán probable era observar exactamente estos datos bajo cada posible valor de θ? La respuesta viene directamente de la definición de muestra aleatoria (Definición 4.6): como las observaciones son i.i.d., la probabilidad conjunta de observar $x_1, x_2, \ldots, x_n$ bajo P_θ es

$$P_\theta(X_1 = x_1, \ldots, X_n = x_n) = \prod_{i=1}^{n} p_\theta(x_i).$$

Esta cantidad, vista como función de θ con los datos fijos, es la **función de verosimilitud** — y es lo que define cuán compatible es cada valor de θ con los datos observados.

Definición 4.12 — Función de verosimilitud

Sea $X_1, X_2, \ldots, X_n$ una muestra aleatoria de P_θ con función de masa o densidad p_θ. La **función de verosimilitud** es la función $L : \Theta \to \mathbb{R}$ definida por

$$L(\theta) = L(\theta;\, x_1, \ldots, x_n) = \prod_{i=1}^{n} p_\theta(x_i), \qquad \theta \in \Theta.$$

Observación. *Hay una distinción crucial entre $p_\theta(x)$ y $L(\theta)$:*

- *$p_\theta(x)$ es una función de x con θ fijo — describe la distribución de los datos dado el parámetro.*
- *$L(\theta)$ es una función de θ con los datos $x_1, \ldots, x_n$ fijos — describe cuán compatible es cada valor de θ con los datos observados.*

La verosimilitud no es una función de densidad sobre Θ — no integra necesariamente a 1. Es simplemente una medida relativa de compatibilidad entre parámetros y datos.

El producto $\prod_{i=1}^{n} p_\theta(x_i)$ se justifica por la independencia de la muestra aleatoria: la probabilidad conjunta de observar $x_1, \ldots, x_n$ es el producto de las probabilidades individuales.

4.5.2 Log-verosimilitud y función score

Trabajar con el producto $\prod_{i=1}^{n} p_\theta(x_i)$ es algebraicamente incómodo, especialmente al diferenciar. La solución estándar es tomar logaritmo — lo que convierte el producto en una suma y preserva el orden de los máximos porque el logaritmo es una función estrictamente creciente.

Definición 4.13 — Log-verosimilitud y función score

La **log-verosimilitud** es

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^{n} \ln p_\theta(x_i).$$

La **función score** es la derivada de la log-verosimilitud respecto a θ:

$$s(\theta) = \frac{\partial}{\partial \theta} \ell(\theta) = \sum_{i=1}^{n} \frac{\partial}{\partial \theta} \ln p_\theta(x_i).$$

Observación. *La función score mide cuán sensible es la log-verosimilitud al parámetro θ. Si $s(\theta_0) = 0$, la log-verosimilitud alcanza un punto estacionario en θ_0 — intuitivamente, los datos son compatibles con θ_0 y no "empujan" hacia ningún otro valor. Esta propiedad es la base del estimador de máxima verosimilitud, que estudiaremos en cursos posteriores.*

Antes de definir la información de Fisher necesitamos un resultado fundamental sobre el score: que su valor esperado bajo P_{θ_0} es cero.

Proposición 4.1 — Media cero del score

Bajo condiciones de regularidad sobre p_θ,

$$E_{\theta_0}[s(\theta_0)] = 0.$$

Demostración. Como p_θ es una función de densidad, integra a 1 para todo θ:

$$\int_{-\infty}^{\infty} p_\theta(x)\, dx = 1.$$

Diferenciando ambos lados respecto a θ e intercambiando derivada e integral

(condición de regularidad):

$$\int_{-\infty}^{\infty} \frac{\partial}{\partial\theta} p_\theta(x)\, dx = 0.$$

Usando la identidad $\frac{\partial}{\partial\theta} \ln p_\theta(x) = \frac{1}{p_\theta(x)} \frac{\partial}{\partial\theta} p_\theta(x)$:

$$\int_{-\infty}^{\infty} \frac{\partial}{\partial\theta} \ln p_\theta(x) \cdot p_\theta(x)\, dx = 0.$$

El lado izquierdo es exactamente $E_{\theta_0}[s(\theta_0)]$ para una muestra de tamaño $n = 1$. Para una muestra de tamaño n general, por linealidad del valor esperado:

$$E_{\theta_0}[s(\theta_0)] = \sum_{i=1}^{n} E_{\theta_0}\left[\frac{\partial}{\partial\theta} \ln p_\theta(X_i)\right] = 0.$$

■

Observación. *Las **condiciones de regularidad** mencionadas en la proposición son condiciones técnicas sobre p_θ que permiten intercambiar el orden de derivación e integración. La más importante es que el soporte de p_θ — el conjunto de x donde $p_\theta(x) > 0$ — no dependa de θ. Todas las familias paramétricas clásicas (Normal, Poisson, Exponencial, Binomial) satisfacen estas condiciones.*

4.5.3 Información de Fisher

Tenemos el score $s(\theta)$ — una variable aleatoria con media cero. Su varianza mide cuánto fluctua el score alrededor de cero, lo que a su vez mide cuán sensible es la distribución al parámetro. Esa varianza es la **información de Fisher**.

Definición 4.14 — Información de Fisher

La **información de Fisher** sobre θ_0 contenida en una observación X es

$$\mathcal{I}(\theta_0) = \mathrm{Var}_{\theta_0}(s(\theta_0)) = E_{\theta_0}\left[\left(\frac{\partial}{\partial\theta} \ln p_{\theta_0}(X)\right)^2\right],$$

donde la segunda igualdad usa que $E_{\theta_0}[s(\theta_0)] = 0$ (Proposición 4.1).

Observación. *La información de Fisher tiene una forma alternativa útil bajo condiciones de regularidad:*

$$\mathcal{I}(\theta_0) = -E_{\theta_0}\left[\frac{\partial^2}{\partial\theta^2} \ln p_{\theta_0}(X)\right].$$

Esta expresión — la curvatura esperada negativa de la log-verosimilitud — es frecuentemente más fácil de calcular que la forma cuadrática. Interpretación: si la log-verosimilitud tiene una curvatura muy pronunciada alrededor de θ_0, los datos son muy informativos sobre θ_0. Si la curvatura es suave, los datos dicen poco.

Esto lo podemos ilustrar mejor con un ejemplo:

Ejemplo 4.1 — Información de Fisher para Bernoulli

Sea $X \sim \text{Bernoulli}(p)$ con $p \in (0,1)$. Calculamos $\mathcal{I}(p)$.
La función de masa es $p_p(x) = p^x(1-p)^{1-x}$ para $x \in \{0,1\}$. La log-verosimilitud para una observación es:

$$\ln p_p(x) = x \ln p + (1-x)\ln(1-p).$$

La función score es:

$$\frac{\partial}{\partial p} \ln p_p(x) = \frac{x}{p} - \frac{1-x}{1-p} = \frac{x-p}{p(1-p)}.$$

La información de Fisher es la varianza del score:

$$\mathcal{I}(p) = E_p\left[\left(\frac{X-p}{p(1-p)}\right)^2\right] = \frac{1}{p^2(1-p)^2} E_p[(X-p)^2] = \frac{\text{Var}_p(X)}{p^2(1-p)^2}.$$

Como $\text{Var}_p(X) = p(1-p)$ para una Bernoulli (Proposición 2.9):

$$\mathcal{I}(p) = \frac{p(1-p)}{p^2(1-p)^2} = \frac{1}{p(1-p)}.$$

Observación. *El resultado $\mathcal{I}(p) = 1/(p(1-p))$ tiene una interpretación intuitiva clara. Cuando p está cerca de 0 o de 1, la función $1/(p(1-p))$ es muy grande — los datos son muy informativos sobre p, porque casi siempre sale el mismo resultado y cualquier desviación es muy reveladora. Cuando $p = 0.5$, la información es mínima — los resultados son máximamente impredecibles y cada observación dice poco sobre el valor exacto de p.*

La cota de Cramér-Rao para una muestra de tamaño n es:

$$\text{Var}_p(\hat{p}) \geq \frac{1}{n\,\mathcal{I}(p)} = \frac{p(1-p)}{n}.$$

Notemos que esta cota es exactamente la varianza de la media muestral $\bar{X}$ — lo que anticipa que $\bar{X}$ es un estimador eficiente de p en el sentido de Cramér-Rao.

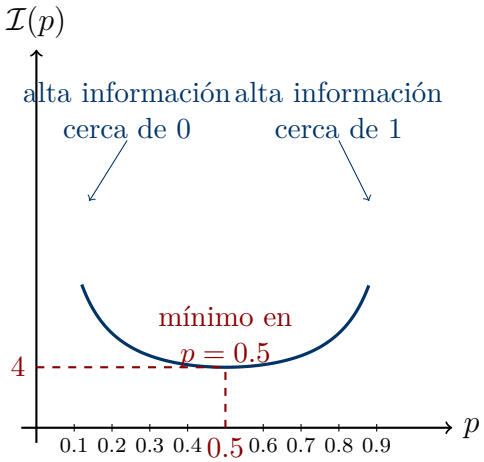


Figura 4.2: Información de Fisher $\mathcal{I}(p) = 1/(p(1-p))$ para $X \sim \text{Bernoulli}(p)$. La información es máxima cerca de los extremos $p = 0$ y $p = 1$ — donde los datos son más reveladores sobre p — y mínima en $p = 0.5$, donde la variable es máxximamente impredecible.

Observación. *Para una muestra aleatoria de tamaño n, la información de Fisher total es*

$$\mathcal{I}_n(\theta_0) = n\,\mathcal{I}(\theta_0).$$

Es decir, la información se acumula linealmente con el tamaño muestral — duplicar la muestra duplica la información disponible sobre θ_0. Esta propiedad es consecuencia directa de la independencia de las observaciones.

4.6 Teorema de Cramér-Rao

Tenemos ahora todas las herramientas necesarias para responder las preguntas que dejamos abiertas al final de la Sección 4.4: ¿existe una cota absoluta para la varianza de cualquier estimador insesgado? ¿De qué depende? El Teorema de Cramér-Rao responde ambas con precisión.

Antes de enunciarlo, recordamos un resultado clásico que usaremos en la demostración.

Observación. *La **desigualdad de Cauchy-Schwarz** establece que para dos variables aleatorias U y V con varianza finita:*

$$\text{Cov}(U, V)^2 \leq \text{Var}(U) \cdot \text{Var}(V).$$

Es la versión probabilística de un resultado general que vale en cualquier espacio con producto interno — el mismo que se aplica en $\mathbb{R}^n$ para vectores. Aquí el producto

interno entre dos variables aleatorias U y V es $E(UV)$, y la desigualdad dice que la covarianza no puede superar el producto de las desviaciones estándar.

Teorema 4.1 — Teorema de Cramér-Rao

Sea $X_1, \ldots, X_n$ una muestra aleatoria de P_{θ_0} y sea $\hat{\theta}$ un estimador insesgado de θ_0. Bajo condiciones de regularidad,

$$\mathrm{Var}_{\theta_0}(\hat{\theta}) \geq \frac{1}{n\,\mathcal{I}(\theta_0)}.$$

La cantidad $1/(n\,\mathcal{I}(\theta_0))$ se denomina **cota de Cramér-Rao**.

Demostración. La demostración tiene tres pasos.

Paso 1 — Una identidad clave. Mostraremos que

$$\mathrm{Cov}_{\theta_0}(\hat{\theta},\, s(\theta_0)) = 1.$$

Como $\hat{\theta}$ es insesgado, $E_{\theta_0}(\hat{\theta}) = \theta_0$ para todo $\theta_0 \in \Theta$. Diferenciando respecto a θ_0 e intercambiando derivada e integral (condiciones de regularidad):

$$\frac{\partial}{\partial \theta_0} \int \hat{\theta}(x_1, \ldots, x_n) \prod_{i=1}^{n} p_{\theta_0}(x_i)\, dx_i = 1.$$

Aplicando la regla de la cadena al integrando y usando que $\frac{\partial}{\partial \theta_0} \ln L(\theta_0) = s(\theta_0)$:

$$\int \hat{\theta}(x_1, \ldots, x_n) \cdot s(\theta_0) \cdot \prod_{i=1}^{n} p_{\theta_0}(x_i)\, dx_i = 1,$$

es decir, $E_{\theta_0}[\hat{\theta} \cdot s(\theta_0)] = 1$. Como $E_{\theta_0}[s(\theta_0)] = 0$ por la Proposición 4.1:

$$\mathrm{Cov}_{\theta_0}(\hat{\theta},\, s(\theta_0)) = E_{\theta_0}[\hat{\theta} \cdot s(\theta_0)] - E_{\theta_0}[\hat{\theta}] \cdot E_{\theta_0}[s(\theta_0)] = 1 - \theta_0 \cdot 0 = 1.$$

Paso 2 — Desigualdad de Cauchy-Schwarz. Aplicando la desigualdad de Cauchy-Schwarz a $\hat{\theta}$ y $s(\theta_0)$:

$$\mathrm{Cov}_{\theta_0}(\hat{\theta},\, s(\theta_0))^2 \leq \mathrm{Var}_{\theta_0}(\hat{\theta}) \cdot \mathrm{Var}_{\theta_0}(s(\theta_0)).$$

Paso 3 — Combinar. Sustituyendo el Paso 1 en el lado izquierdo y la definición de información de Fisher $\mathcal{I}_n(\theta_0) = n\,\mathcal{I}(\theta_0) = \mathrm{Var}_{\theta_0}(s(\theta_0))$ en el lado derecho:

$$1 \leq \mathrm{Var}_{\theta_0}(\hat{\theta}) \cdot n\,\mathcal{I}(\theta_0).$$

Despejando:

$$\mathrm{Var}_{\theta_0}(\hat{\theta}) \geq \frac{1}{n\,\mathcal{I}(\theta_0)}.$$

■

Observación. *El teorema responde las tres preguntas abiertas:*

i) ***¿Existe una cota absoluta?*** *Sí:* $1/(n\,\mathcal{I}(\theta_0))$.

ii) ***¿De qué depende?*** *De la información de Fisher — cuanto más informativa sea la muestra sobre* θ_0*, menor es la cota y más preciso puede ser el estimador. Con más datos (*n *mayor), la cota decrece como* $1/n$.

iii) ***¿Hay un estimador que la alcance?*** *Se dice que un estimador insesgado que alcanza la cota es* ***eficiente*** *en sentido absoluto. No siempre existe, pero cuando existe es el óptimo indiscutible dentro de la clase de estimadores insesgados.*

Observación. *Cramér-Rao justifica retroactivamente por qué la varianza es el criterio correcto para comparar estimadores insesgados: no es una elección arbitraria, sino la consecuencia de que existe una cota natural expresada en términos de varianza. Comparar varianzas no es solo conveniente — es lo único que tiene sentido dado este resultado.*

4.7 Por qué estas propiedades y no otras

Al definir insesgadez, eficiencia y consistencia en la Sección 4.4, las presentamos como criterios razonables para evaluar estimadores. Pero "razonable" no es una justificación matemática. Ahora que tenemos el Teorema de Cramér-Rao, podemos responder con precisión por qué estas tres propiedades y no otras.

4.7.1 Por qué la insesgadez

El Teorema de Cramér-Rao establece una cota inferior para la varianza de cualquier estimador **insesgado**. Esto no es accidental — la demostración usó de manera esencial que $E_{\theta_0}(\hat{\theta}) = \theta_0$: fue precisamente esa condición la que permitió derivar la identidad $\mathrm{Cov}_{\theta_0}(\hat{\theta}, s(\theta_0)) = 1$ en el Paso 1 de la demostración.

Sin insesgadez, esa identidad no vale y la cota desaparece. Esto tiene una consecuencia importante: si permitimos estimadores sesgados, el problema de encontrar el "mejor" estimador se vuelve mal planteado — siempre es posible reducir la varianza introduciendo sesgo, y no hay un límite natural que diga cuándo parar.

La insesgadez no es una propiedad arbitraria. Es la condición que hace que el problema de optimización esté bien planteado: delimita la clase de estimadores dentro de la cual existe un límite absoluto de precisión, y por lo tanto dentro de la cual tiene sentido hablar de un estimador óptimo.

4.7.2 Por qué la eficiencia

Dentro de la clase de estimadores insesgados, Cramér-Rao demuestra que la varianza satisface:

$$\mathrm{Var}_{\theta_0}(\hat{\theta}) \geq \frac{1}{n\,\mathcal{I}(\theta_0)}.$$

Esto significa que la varianza tiene una cota inferior **absoluta** — no relativa a otro estimador, sino fijada por la cantidad de información que los datos contienen sobre θ_0. Comparar varianzas entre estimadores insesgados no es una elección arbitraria: es lo único que tiene sentido dado que existe ese límite natural expresado en términos de varianza.

Más aún, el teorema define implícitamente qué significa ser óptimo en sentido absoluto: un estimador insesgado que alcanza la cota de Cramér-Rao es eficiente en el sentido más fuerte posible — no hay ningún estimador insesgado que pueda superarlo, independientemente de cuán ingenioso sea su diseño.

4.7.3 Por qué la consistencia

La cota de Cramér-Rao es $1/(n\,\mathcal{I}(\theta_0))$ — decrece como $1/n$ cuando el tamaño muestral crece. Esto revela algo fundamental: la precisión máxima alcanzable mejora con más datos, y lo hace a una tasa bien definida. Un buen estimador debería aprovechar esa mejora — su varianza debería decrecer al menos tan rápido como la cota.

La consistencia formaliza exactamente eso: exige que el estimador converja a θ_0 cuando $n \to \infty$. Un estimador inconsistente no aprovecha la información adicional que proveen más datos — su error no desaparece aunque la cota de Cramér-Rao se acerque a cero. Es, en ese sentido, un estimador que desperdicia información.

La consistencia no es una condición arbitraria de "mejora con más datos". Es la condición mínima para que un estimador sea compatible con lo que Cramér-Rao garantiza que es posible lograr.

4.7.4 Las tres propiedades como sistema coherente

Las tres propiedades no son una lista arbitraria de criterios deseables. Son un sistema coherente donde cada una responde una pregunta precisa:

Propiedad	**Pregunta**	**Justificación**
Insesgadez	¿Apunta en la dirección correcta?	Delimita la clase donde existe óptimo
Eficiencia	¿Aprovecha la información?	Cramér-Rao fija el límite absoluto
Consistencia	¿Mejora con más datos?	La cota decrece como $1/n$

Cramér-Rao es el resultado que une las tres: muestra que dentro de la clase de estimadores insesgados existe un límite de precisión determinado por la información de Fisher, que ese límite mejora con más datos, y que un estimador óptimo es aquel que lo alcanza. Insesgadez, eficiencia y consistencia son las tres caras de esa misma idea.

4.8 La media muestral como estimador óptimo

A lo largo de este capítulo hemos construido un marco teórico completo: definimos qué es un estimador, establecimos las propiedades que debe cumplir un buen estimador, y demostramos con Cramér-Rao que existe un límite absoluto de precisión determinado por la información de Fisher. Ahora aplicamos todo ese aparato al estimador más natural e importante de la estadística: la **media muestral**

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Demostraremos que $\bar{X}$ no es solo un estimador conveniente — es el estimador óptimo dentro de la clase insesgada, en el sentido de que alcanza la cota de Cramér-Rao.

Proposición 4.2 — Insesgadez de la media muestral

Sea $X_1, \ldots, X_n$ una muestra aleatoria de una población con media μ. Entonces

$$E(\bar{X}) = \mu.$$

Demostración. Por linealidad del valor esperado (Proposición 2.5):

$$E(\bar{X}) = E\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = \frac{1}{n}\sum_{i=1}^{n} \mu = \frac{1}{n}\cdot n\mu = \mu.$$

■

Observación. *La demostración no asume ninguna distribución específica para la población — solo que $E(X_i) = \mu$. La insesgadez de $\bar{X}$ vale para cualquier familia paramétrica con media finita.*

Proposición 4.3 — Varianza de la media muestral

Sea $X_1, \ldots, X_n$ una muestra aleatoria de una población con varianza σ^2. Entonces

$$\mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Demostración. Por la aditividad de la varianza bajo independencia (válida porque la muestra es i.i.d.):

$$\mathrm{Var}(\bar{X}) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{1}{n^2}\cdot n\sigma^2 = \frac{\sigma^2}{n}.$$

■

Proposición 4.4 — Eficiencia de $\bar{X}$ para la familia Normal

Sea $X_1, \ldots, X_n$ una muestra aleatoria de $N(\mu, \sigma^2)$ con σ^2 conocido. Entonces $\bar{X}$ alcanza la cota de Cramér-Rao y es por lo tanto el estimador insesgado de μ con menor varianza posible.

Demostración. Calculamos la información de Fisher para la familia $N(\mu, \sigma^2)$ con σ^2 conocido y $\theta = \mu$. La log-densidad es:

$$\ln p_\mu(x) = -\frac{1}{2}\ln(2\pi\sigma^2) - \frac{(x-\mu)^2}{2\sigma^2}.$$

La función score es:

$$\frac{\partial}{\partial\mu}\ln p_\mu(x) = \frac{x-\mu}{\sigma^2}.$$

La información de Fisher para una observación:

$$\mathcal{I}(\mu) = E_\mu\left[\left(\frac{X-\mu}{\sigma^2}\right)^2\right] = \frac{1}{\sigma^4}\mathrm{Var}_\mu(X) = \frac{1}{\sigma^4}\cdot\sigma^2 = \frac{1}{\sigma^2}.$$

La cota de Cramér-Rao para una muestra de tamaño n es:

$$\frac{1}{n\,\mathcal{I}(\mu)} = \frac{1}{n\cdot\frac{1}{\sigma^2}} = \frac{\sigma^2}{n}.$$

Por la Proposición 4.3, $\mathrm{Var}(\bar{X}) = \sigma^2/n$. Como la varianza de $\bar{X}$ coincide exactamente con la cota de Cramér-Rao, $\bar{X}$ es el estimador insesgado de μ con menor varianza posible. ■

Proposición 4.5 — Consistencia de la media muestral

Sea $X_1, \ldots, X_n$ una muestra aleatoria de una población con media μ y varianza $\sigma^2\infty$. Entonces $\bar{X}$ es consistente:

$$\lim_{n\to\infty} P\Big(|\bar{X} - \mu| > \varepsilon\Big) = 0 \qquad \text{para todo } \varepsilon > 0.$$

Demostración. Aplicamos la desigualdad de Chebyshev al estimador $\bar{X}$. Como $E(\bar{X}) = \mu$ y $\text{Var}(\bar{X}) = \sigma^2/n$:

$$P\Big(|\bar{X} - \mu| > \varepsilon\Big) \leq \frac{\text{Var}(\bar{X})}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

Cuando $n \to \infty$, el lado derecho converge a cero para todo $\varepsilon > 0$ fijo. Por lo tanto:

$$\lim_{n\to\infty} P\Big(|\bar{X} - \mu| > \varepsilon\Big) = 0.$$

■

Observación. *La consistencia de $\bar{X}$ es la **Ley Débil de los Grandes Números** — uno de los resultados más importantes de toda la probabilidad. Establece que el promedio de una muestra aleatoria converge en probabilidad a la media poblacional cuando el tamaño muestral crece. La demostración via Chebyshev que presentamos aquí es elemental pero completa — no requiere ningún resultado adicional más allá de lo que ya hemos desarrollado en este apunte.*

Las cuatro proposiciones juntas establecen que $\bar{X}$ cumple todo lo que el marco teórico de este capítulo exige de un buen estimador — y más: no solo es insesgado, eficiente y consistente, sino que es **óptimo en sentido absoluto** para la familia Normal, en el sentido de que ningún estimador insesgado puede superarlo. Esto cierra el círculo: partimos de propiedades definidas empíricamente, las justificamos con Cramér-Rao, y terminamos demostrando que el estimador más natural de todos las satisface todas — y las satisface al máximo nivel posible.

4.9 Distribución muestral y Teorema del Límite Central

En la sección anterior demostramos que $\bar{X}$ tiene media μ y varianza σ^2/n. Pero conocer los primeros dos momentos no es suficiente para calcular probabilidades sobre $\bar{X}$ — para eso necesitamos conocer su **distribución completa**. La distribución de probabilidad de un estadístico recibe un nombre propio, y determinarla

para $\bar{X}$ es el objetivo de esta sección. La respuesta es el resultado más importante de toda la probabilidad.

Definición 4.15 — Distribución muestral

La **distribución muestral** de un estadístico $T = g(X_1, \ldots, X_n)$ es la distribución de probabilidad de T cuando $X_1, \ldots, X_n$ es una muestra aleatoria de P_{θ_0}.

Observación. *La distribución muestral no es la distribución de la población — es la distribución del estadístico calculado sobre la muestra. Para un mismo parámetro θ_0, distintos estadísticos tienen distintas distribuciones muestrales. La distribución muestral de $\bar{X}$ responde la pregunta: si tomara muchas muestras de tamaño n y calculara $\bar{X}$ en cada una, ¿cómo se distribuirían esos valores?*

Ya sabemos que $E(\bar{X}) = \mu$ y $\mathrm{Var}(\bar{X}) = \sigma^2/n$ para cualquier población con media μ y varianza σ^2. Pero ¿qué *forma* tiene la distribución muestral de $\bar{X}$? La respuesta depende de la población:

- Si la población es Normal, la distribución de $\bar{X}$ es exactamente Normal para cualquier n.
- Si la población **no** es Normal, el Teorema del Límite Central garantiza que la distribución de $\bar{X}$ se aproxima a una Normal cuando n crece.

Observación. *En el lenguaje formal de este capítulo, decir que **la población es Normal** significa que la distribución P_{θ_0} que gobierna la variable de interés pertenece a la familia paramétrica $\mathcal{F} = \{N(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$, es decir, que cada observación X_i de la muestra aleatoria sigue una distribución Normal. Cuando la población **no** es Normal, P_{θ_0} pertenece a otra familia — Uniforme, Exponencial, Poisson, o cualquier otra — y el TLC garantiza que $\bar{X}$ converge a la Normal de todas formas, independientemente de cuál sea esa familia.*

Teorema 4.2 — Teorema del Límite Central

Sea $X_1, X_2, \ldots, X_n$ una muestra aleatoria con $E(X_i) = \mu$ y $\mathrm{Var}(X_i) = \sigma^2 < \infty$. Se define

$$Z_n := \frac{\sum_{i=1}^{n} X_i - n\mu}{\sigma\sqrt{n}}.$$

Entonces la función de distribución de Z_n converge hacia la función de

distribución Normal estándar cuando $n \to \infty$:

$$\lim_{n\to\infty} P(Z_n \leq z) = \Phi(z) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\, dt \qquad \text{para todo } z \in \mathbb{R}.$$

Es equivalente escribirlo en función de la media muestral $\bar{X}$:

$$Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}},$$

puesto que ambas expresiones difieren solo en dividir numerador y denominador por n.

Observación. *El teorema no dice nada sobre la distribución de cada X_i — solo exige que existan su media y su varianza. La convergencia a la Normal ocurre independientemente de la forma de la distribución poblacional. En la práctica, la aproximación $P(Z_n \leq z) \approx \Phi(z)$ es adecuada para $n \geq 30$, aunque este umbral depende de cuán alejada esté la población de la simetría.*

Observación. *La demostración del TLC requiere el concepto de **función característica** $\varphi_X(t) = E[e^{itX}]$ — la transformada de Fourier de la distribución de X — y el resultado de que la convergencia de funciones características implica convergencia en distribución. Estas herramientas pertenecen al ámbito del análisis real y están fuera del alcance de este curso. Lo que sí podemos hacer es entender por qué el resultado es verdadero intuitivamente, y verificarlo en casos particulares.*

Observación. *El TLC es la respuesta a la pregunta que dejamos abierta en el Tema 3 al estudiar la distribución Normal: ¿por qué la Normal aparece en fenómenos tan distintos como alturas, errores de medición y precios financieros? La respuesta es que en todos esos casos la variable observada es la suma — o el promedio — de muchos factores independientes pequeños. El TLC garantiza que esa suma converge a una Normal independientemente de la distribución de los factores individuales. La Normal no aparece por coincidencia — aparece porque es el atractor universal de las sumas de variables aleatorias independientes.*

Lo anterior implica además que la suma $\sum_{i=1}^{n} X_i = n\bar{X}$ también se distribuye aproximadamente Normal:

$$\sum_{i=1}^{n} X_i \approx N(n\mu,\, n\sigma^2) \qquad \text{para } n \geq 30.$$

Proposición 4.6 — Caso exacto: población Normal

Si la población es $N(\mu, \sigma^2)$, entonces para **cualquier** n:

$$\bar{X} \sim N\left(\mu,\, \frac{\sigma^2}{n}\right) \qquad \text{y} \qquad \sum_{i=1}^{n} X_i \sim N(n\mu,\, n\sigma^2).$$

Demostración. La suma de variables normales independientes es normal — resultado que se demuestra usando funciones características o la propiedad de reproductividad de la distribución Normal. Específicamente, si $X_i \sim N(\mu, \sigma^2)$ i.i.d., entonces por la propiedad de reproductividad:

$$\sum_{i=1}^{n} X_i \sim N(n\mu,\, n\sigma^2).$$

Dividiendo por n y usando las propiedades de la Normal bajo transformaciones afines (Proposición 3.10):

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \sim N\left(\mu,\, \frac{\sigma^2}{n}\right).$$

■

Observación. *La diferencia entre el caso exacto y el TLC es fundamental. Cuando la población es Normal, la distribución de* $\bar{X}$ *es exactamente Normal para cualquier* n*, incluso* $n = 1$*. Cuando la población no es Normal, la distribución de* $\bar{X}$ *solo se* aproxima *a la Normal, y la aproximación mejora con* n*. En la práctica,* $n \geq 30$ *suele ser suficiente para que la aproximación sea adecuada, aunque esto depende de cuán alejada esté la población de la simetría.*

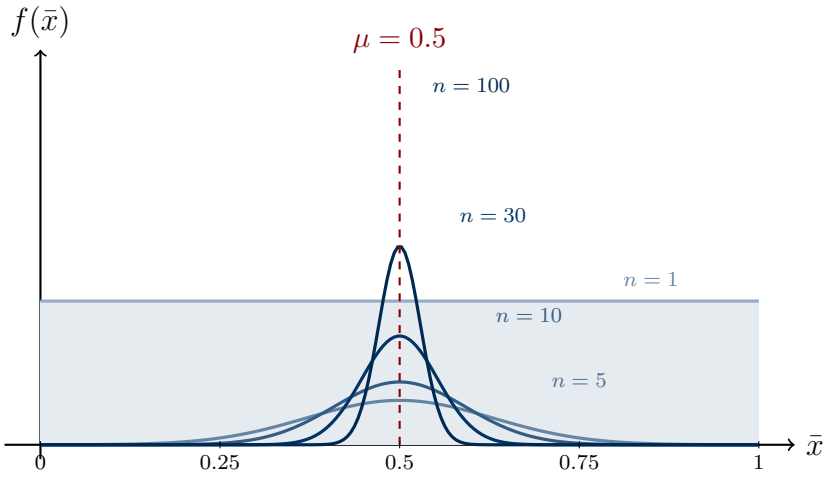


Figura 4.3: Distribución muestral de $\bar{X}$ para distintos tamaños de muestra n, cuando la población es $U(0,1)$ — una distribución completamente no Normal (rectángulo). Para $n = 1$, la distribución de $\bar{X}$ es la misma Uniforme. A medida que n crece, la distribución se concentra alrededor de $\mu = 0.5$ y adquiere la forma de campana gaussiana. Para $n \geq 30$ la aproximación Normal es adecuada.

El Teorema del Límite Central es la respuesta completa a la pregunta que dejamos abierta en el Tema 3: ¿por qué la distribución Normal aparece en fenómenos tan distintos como alturas, errores de medición y precios financieros? La respuesta no es que el mundo sea normal — es que el mundo está lleno de fenómenos que son sumas de muchos factores independientes pequeños, y el TLC garantiza que esas sumas convergen a la Normal sin importar la distribución de cada factor individual. La altura de una persona es la suma de miles de factores genéticos y ambientales. El error de medición es la suma de miles de perturbaciones pequeñas. El precio de una acción es la acumulación de miles de decisiones independientes. En todos esos casos opera el TLC — y produce la campana gaussiana. En términos simples: **la distribución Normal no es un supuesto sobre el mundo, es una consecuencia matemática inevitable de la independencia y la acumulación.**

Tema 5

Introducción a la inferencia estadística

Todo el aparato que hemos construido — variables aleatorias, distribuciones, estimadores, Teorema del Límite Central — tenía un objetivo implícito: aprender algo sobre una población a partir de una muestra. Hasta ahora ese aprendizaje tomó la forma de una **estimación puntual**: dado un parámetro desconocido θ_0, calculamos $\hat{\theta}$ como nuestra mejor aproximación.

Pero en la práctica, la pregunta que enfrentan los tomadores de decisiones rara vez es "¿cuánto vale θ_0?". Más frecuentemente es "¿es θ_0 mayor que cierto umbral?", "¿cambió θ_0 después de una intervención?", o "¿son compatibles los datos con cierta afirmación sobre θ_0?". Esas son preguntas de **decisión**, no de estimación.

La inferencia estadística provee dos herramientas para responderlas:

Herramienta	**Pregunta que responde**
Test de hipótesis	¿Son los datos compatibles con cierta afirmación sobre θ_0?
Intervalo de confianza	¿En qué rango de valores es plausible que esté θ_0?

Ambas herramientas están íntimamente relacionadas — un intervalo de confianza puede construirse a partir de un test de hipótesis y viceversa. Las estudiaremos en orden.

5.1 Test de hipótesis

Imaginemos que una empresa farmacéutica afirma que su nuevo medicamento reduce la presión arterial media a menos de 120 mmHg. Un regulador de salud quiere verificar esa afirmación. No puede medir a toda la población — solo tiene acceso a una muestra. ¿Cómo usa esa muestra para tomar una decisión?

La respuesta es el **test de hipótesis**: un procedimiento formal para decidir, sobre la base de evidencia muestral, si una afirmación sobre el parámetro poblacional es compatible con los datos o no.

5.1.1 Hipótesis nula e hipótesis alternativa

Todo test de hipótesis parte de dos afirmaciones contrapuestas sobre el parámetro θ_0.

Definición 5.1 — Hipótesis nula e hipótesis alternativa

La **hipótesis nula** H_0 es la afirmación que se supone cierta inicialmente — la posición de referencia o *statu quo*. La **hipótesis alternativa** H_1 es la afirmación contradictoria a H_0 que se desea detectar si los datos lo justifican. Si μ denota el parámetro de interés y μ_0 es un valor específico llamado **valor nulo**, la hipótesis nula toma la forma

$$H_0 : \mu = \mu_0,$$

y la hipótesis alternativa tiene una de las tres formas:

1. $H_1 : \mu \neq \mu_0$ (prueba **bilateral**)
2. $H_1 : \mu > \mu_0$ (prueba **unilateral derecha**)
3. $H_1 : \mu < \mu_0$ (prueba **unilateral izquierda**)

Observación. *En el lenguaje formal del Capítulo 4, la hipótesis nula $H_0 : \mu = \mu_0$ afirma que el verdadero parámetro es $\theta_0 = \mu_0$. El test de hipótesis pregunta: ¿son los datos compatibles con esa afirmación, o constituyen evidencia suficiente para rechazarla?*

5.1.2 La lógica del test: por qué partimos de H_0

La estructura del test de hipótesis — partir de H_0 y buscar evidencia para rechazarla, nunca para "probarla" — no es una convención arbitraria. Tiene raíces profundas en la filosofía de la ciencia, específicamente en el **falsacionismo** del filósofo austríaco Karl Popper (1902–1994).

El problema de la inducción

Durante siglos, la ciencia opero bajo la lógica **inductiva**: observar muchos casos favorables y concluir que una ley general es verdadera. Si veo mil cisnes blancos, induzco que "todos los cisnes son blancos". El problema — señalado ya por David

Hume en el siglo XVIII — es que ninguna cantidad finita de observaciones favorables puede *probar* una afirmación universal. Siempre podría existir un contraejemplo no observado aún.

Y en efecto: cuando los europeos llegaron a Australia, encontraron cisnes negros. Mil observaciones favorables no bastaron.

La solución de Popper: falsabilidad

Popper propuso invertir la lógica. En lugar de buscar confirmaciones, la ciencia debería buscar **refutaciones**. Una afirmación científica válida no es aquella que puede confirmarse, sino aquella que puede *falsarse* — es decir, aquella para la que existe al menos un experimento concebible que podría demostrar que es falsa.

La asimetría es crucial:

- **Confirmar** requiere infinitas observaciones favorables — nunca se puede estar seguro.
- **Refutar** requiere una sola observación contradictoria — y eso sí es definitivo.

Por eso Popper argumentó que la ciencia avanza **descartando hipótesis**, no confirmándolas. Una teoría que no puede refutarse en principio — que es compatible con cualquier observación posible — no es científica. Es infalsable, y por lo tanto vacía de contenido empírico.

De Popper al test de hipótesis

El test de hipótesis opera exactamente con esa lógica. La hipótesis nula H_0 juega el papel de la teoría que queremos intentar refutar:

1. **Asumimos H_0 como verdadera** — el *statu quo* que ponemos a prueba. No porque creamos que es verdadera, sino porque es la posición que la evidencia debe superar.
2. **Calculamos qué tan probable sería observar los datos que tenemos si H_0 fuera cierta**. Si esa probabilidad es muy pequeña, los datos son incompatibles con H_0.
3. **Si la probabilidad es suficientemente pequeña, rechazamos H_0** — al igual que Popper refuta una teoría con un contraejemplo, rechazamos H_0 porque los datos son demasiado improbables bajo ella.
4. **Si la probabilidad no es pequeña, no rechazamos H_0** — pero esto **no significa que H_0 sea verdadera**. Solo significa que los datos no proporcionan evidencia suficiente para descartarla. Exactamente como en Popper: la ausencia de refutación no es confirmación.

Observación. *La distinción entre "no rechazar H_0" y "aceptar H_0" es una de las más importantes — y más frecuentemente violadas — de toda la estadística aplicada. Un test que no rechaza H_0 no ha "probado" nada: solo ha constatado que la evidencia disponible es insuficiente para refutarla. Puede que H_0 sea falsa y la muestra simplemente demasiado pequeña para detectarlo. En la jerga estadística, esto se expresa diciendo que el test tiene* ***baja potencia*** *— un concepto que estudiaremos más adelante.*

La confusión entre ambas es directamente popperiana: creer que la ausencia de refutación implica confirmación es el error inductivo que Popper pasó su vida criticando.

Observación. *El falsacionismo también explica por qué H_0 toma siempre la forma de una* ***igualdad*** *$\mu = \mu_0$ y no de una desigualdad. Una igualdad es más fácil de refutar — define un punto preciso en el espacio paramétrico, y cualquier alejamiento suficiente de ese punto constituye evidencia en su contra. Una hipótesis nula de la forma $\mu \geq \mu_0$ sería más difícil de tratar formalmente porque no define un único valor bajo el cual calcular probabilidades.*

5.1.3 Errores en el test de hipótesis

Al tomar una decisión basada en una muestra — y no en la población completa — siempre existe la posibilidad de equivocarse. Hay exactamente dos formas de cometer un error.

Definición 5.2 — Error de tipo I y error de tipo II

Un **error de tipo I** consiste en rechazar H_0 cuando H_0 es verdadera. Un **error de tipo II** consiste en no rechazar H_0 cuando H_0 es falsa.
Sus probabilidades se denotan:

$$P(\text{error tipo I}) = \alpha, \qquad P(\text{error tipo II}) = \beta.$$

El parámetro α se denomina **nivel de significancia** del test.

		Realidad	
		H_0 verdadera	H_0 falsa
Decisión	No rechazar H_0	Sin error	Error tipo II (β)
	Rechazar H_0	Error tipo I (α)	Sin error

Cuadro 5.1: Los cuatro posibles resultados de un test de hipótesis. Solo dos de ellos constituyen errores.

Observación. *Existe una* ***tensión fundamental*** *entre los dos tipos de error: reducir α — ser más exigente para rechazar H_0 — inevitablemente aumenta β, y viceversa. No es posible minimizar ambos simultáneamente con una muestra de tamaño fijo. La única forma de reducir ambos a la vez es* ***aumentar*** *n — con más datos, la evidencia es más precisa y ambos errores pueden controlarse mejor.*

La convención estándar en la práctica es fijar α en un valor pequeño — típicamente 0.05 o 0.01 — y diseñar el test de modo que α no supere ese umbral. Esto refleja la asimetría popperiana: se es más cuidadoso con rechazar H_0 erróneamente que con no detectar una alternativa verdadera.

5.2 Estimación por intervalos de confianza

5.3 Pruebas de hipótesis

5.3.1 El procedimiento de cinco pasos

5.3.2 Prueba para la media con varianza conocida

5.3.3 Prueba para la media con varianza desconocida