Estadísticas y Data Science

EST108 | Ingeniería Comercial

Universidad Adolfo Ibáñez

Apuntes por **Agustín Miranda**

Primer semestre de 2026

Basado en el material de la profesora Florencia Darrigrandi.

Índice general

Introducción: ¿Qué es la estadística? **5**

1. Probabilidad **7**
1.1. ¿Qué es la probabilidad? . . . 7
1.2. ¿Qué es un experimento? . . . 7
1.3. Espacio muestral y eventos . . . 7
1.3.1. Operaciones entre eventos . . . 8
1.4. Interpretaciones de la probabilidad . . . 8
1.4.1. Interpretación clásica o equiprobable . . . 8
1.4.2. Interpretación frecuentista . . . 9
1.4.3. Interpretación subjetiva (bayesiana) . . . 9
1.5. Los axiomas de Kolmogorov . . . 10
1.5.1. Propiedades derivadas . . . 11
1.6. Probabilidad condicional . . . 13
1.6.1. Definición . . . 14
1.6.2. Regla de la multiplicación . . . 15
1.7. Independencia de eventos . . . 15
1.8. Probabilidad total y Teorema de Bayes . . . 17
1.8.1. Partición del espacio muestral . . . 17
1.8.2. Teorema de probabilidades totales . . . 17
1.8.3. Teorema de Bayes . . . 19

2. Variable aleatoria discreta **23**
2.1. ¿Qué es una variable aleatoria? . . . 23
2.2. Clasificación de las variables aleatorias . . . 24
2.3. Función de masa de probabilidad . . . 25
2.3.1. Propiedades . . . 26
2.4. Función de distribución acumulada . . . 27
2.4.1. Propiedades . . . 27
2.4.2. Cálculo de probabilidades con la FDA . . . 28
2.5. Valor esperado y varianza . . . 30
2.5.1. Valor esperado . . . 30
2.5.2. Varianza . . . 32

2.6. Distribuciones importantes 35
2.6.1. Distribución Binomial 35
2.6.2. Distribución de Poisson 35

3. Variable aleatoria continua **37**
3.1. De lo discreto a lo continuo 37
3.2. Función de densidad de probabilidad 37
3.3. Función de distribución acumulada 37
3.4. Distribución Normal 37
3.4.1. ¿Por qué $\sqrt{2\pi}$? 37
3.5. Teorema del Límite Central 37

4. Muestreo y distribución de muestreo **39**
4.1. Población, muestra y parámetro 39
4.2. Estadístico y estimador 39
4.3. Distribuciones de muestreo 39
4.3.1. Distribución t de Student 39
4.3.2. Distribución Chi-cuadrado χ^2 39
4.3.3. Distribución F de Fisher 39

5. Introducción a la inferencia estadística **41**
5.1. Estimación por intervalos de confianza 41
5.2. Pruebas de hipótesis 41
5.2.1. El procedimiento de cinco pasos 41
5.2.2. Prueba para la media con varianza conocida 41
5.2.3. Prueba para la media con varianza desconocida 41

Introducción: ¿Qué es la estadística?

—El término «estadística» deriva del latín *statisticum collegium* (consejo de Estado), y de la palabra italiana *statista* («hombre de estado», «político» o «estadista»). Pero su uso contemporáneo fue acuñado por el historiador y jurista alemán Gottfried Achenwall en 1749 para referirse al análisis de datos acerca del Estado, significando «ciencia del Estado».

Durante el siglo XIX e inicios del XX, el término se fue transformando en una disciplina matemática propiamente rigurosa bajo el trabajo de Francis Galton, Karl Pearson, Ronald Fisher, entre otros que acuñaron los métodos estadísticos modernos que conocemos hoy en día.

De esta manera, podemos definir a la estadística como la ciencia de recolectar, analizar, presentar e interpretar datos.

Tema 1

Probabilidad

1.1 ¿Qué es la probabilidad?

La probabilidad es el lenguaje matemático para cuantificar la incertidumbre.

1.2 ¿Qué es un experimento?

Un experimento es el modelo matemático para cualquier procedimiento que puede ser repetido infinitamente y tiene un conjunto de posibles resultados, que conocemos como:

1.3 Espacio muestral y eventos

Definición 1.1 — Espacio muestral

El espacio muestral (denotado usualmente Ω o S) es el conjunto de **todos los resultados posibles** de un experimento aleatorio.

Definición formal:

$$\Omega = \{\omega : \omega \text{ es un resultado posible del experimento}\}$$

Cada elemento $\omega \in \Omega$ se llama **punto muestral** o **resultado elemental**.

Los subconjuntos de Ω son llamados **eventos**. Dado que los eventos son subconjuntos de Ω, las operaciones de la teoría de conjuntos —unión, intersección y complemento— se aplican directamente, adquiriendo aquí una interpretación probabilística:

1.3.1 Operaciones entre eventos

Ω	Espacio muestral
ω	Resultado (punto o elemento)
A	Evento (subconjunto de Ω)
A^c	Complemento de A (no A)
$A \cup B$	Unión (A o B)
$A \cap B$ o AB	Intersección (A y B)
$A - B$	Diferencia (ω en A pero no en B)
$A \subset B$	Inclusión (A implica B)
$\emptyset$	Evento imposible (siempre falso)
Ω	Evento seguro (siempre verdadero)
$A \cap B = \emptyset$	A y B son mutuamente excluyentes

1.4 Interpretaciones de la probabilidad

Antes de formalizar la probabilidad, es útil preguntarse qué *significa* que un evento tenga probabilidad p. Existen tres respuestas clásicas a esta pregunta, cada una con supuestos y limitaciones distintas.

1.4.1 Interpretación clásica o equiprobable

Definición 1.2 — Espacio equiprobable

Un espacio muestral Ω es **equiprobable** si todos sus elementos tienen igual probabilidad de ocurrir. En este caso, la probabilidad de un evento A se define como:

$$P(A) = \frac{\#A}{\#\Omega} = \frac{\text{casos favorables}}{\text{casos totales}}$$

donde $\#A$ denota la cardinalidad del conjunto A.

Esta interpretación es la más antigua, se remonta a los trabajos del matemático francés Pierre-Simon Laplace (1749-1827) sobre juegos de azar, y es la que se aplica naturalmente cuando todos los resultados del experimento son igualmente posibles: lanzar una moneda justa, tirar un dado equilibrado, extraer una carta de una baraja bien mezclada.

Observación. *La condición de equiprobabilidad debe justificarse, no asumirse. Un error común es definir el espacio muestral de forma que los elementos no sean igualmente probables y luego aplicar la fórmula de Laplace de todos modos. Por*

ejemplo, si una urna contiene 4 fichas con el número 1 y 2 fichas con el número 2, el espacio muestral correcto es $\Omega = \{1_a, 1_b, 1_c, 1_d, 2_a, 2_b\}$ *con* $\#\Omega = 6$*, y no* $\Omega = \{1, 2\}$ *con* $\#\Omega = 2$*, pues en este último los elementos no son equiprobables.*

1.4.2 Interpretación frecuentista

La interpretación frecuentista define la probabilidad de un evento A como el límite de su frecuencia relativa cuando el experimento se repite un número muy grande de veces bajo condiciones idénticas:

$$P(A) = \lim_{n\to\infty} \frac{n_A}{n}$$

donde n es el número total de repeticiones y n_A es el número de veces que ocurrió A.

Esta es la interpretación que subyace a la estadística aplicada: si lanzamos una moneda 10.000 veces y obtenemos cara en 5.032 de ellas, estimamos $P(\text{cara}) \approx 0.5$. A mayor número de repeticiones, mejor la estimación.

Observación. *La interpretación frecuentista tiene una limitación fundamental: exige que el experimento sea repetible en condiciones idénticas. Esto la hace inaplicable a eventos únicos o irrepetibles — como la probabilidad de que llueva mañana en Santiago, o de que una empresa quiebre el próximo año — para los cuales no existe una frecuencia relativa observable.*

1.4.3 Interpretación subjetiva (bayesiana)

La interpretación subjetiva define la probabilidad como un **grado de creencia racional** sobre la ocurrencia de un evento, basado en la información disponible. No requiere repetición del experimento ni equiprobabilidad de los resultados.

Bajo esta visión, dos agentes con información distinta pueden asignar probabilidades distintas al mismo evento sin que ninguno esté "equivocado". Lo que se exige es que las creencias sean *coherentes*, es decir, que satisfagan los axiomas de Kolmogórov que presentaremos en la siguiente sección.

Observación. *Las tres interpretaciones no son mutuamente excluyentes en la práctica. La interpretación clásica es un caso especial de la frecuentista bajo simetría perfecta; y la frecuentista puede entenderse como un caso especial de la subjetiva cuando la evidencia empírica es abrumadora. Lo que unifica las tres es que, en todos los casos, la función* P *debe satisfacer los axiomas que veremos en la sección 1.1.*

1.5 Los axiomas de Kolmogorov

Los axiomas de probabilidad son las condiciones mínimas que deben verificarse para que una función definida sobre un conjunto de sucesos determine consistentemente sus probabilidades. Fueron formulados por el matemático soviético Andréi Kolmogórov en 1933. Y estos son:

Sea Ω un espacio muestral y $\mathcal{A}$ una σ-álgebra de subconjuntos de Ω.

Definición 1.3 — σ-álgebra

Sea Ω un espacio muestral. Una **σ-álgebra** $\mathcal{A}$ sobre Ω es una colección de subconjuntos de Ω que satisface las siguientes tres propiedades:

S1) $\Omega \in \mathcal{A}$.

S2) Si $A \in \mathcal{A}$, entonces $A^c \in \mathcal{A}$ (cerrada bajo complementos).

S3) Si $A_1, A_2, \ldots \in \mathcal{A}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$ (cerrada bajo uniones contables).

A los elementos de $\mathcal{A}$ los llamamos **eventos**, y a la terna $(\Omega, \mathcal{A})$ se la denomina **espacio medible**.

En la práctica, para espacios muestrales finitos o contables, $\mathcal{A}$ corresponde simplemente al conjunto de todos los subconjuntos posibles de Ω — también llamado *conjunto potencia* y denotado 2^{Ω} — por lo que no es necesario preocuparse por esta distinción. La σ-álgebra cobra importancia técnica en espacios continuos, donde no todos los subconjuntos de Ω admiten una asignación de probabilidad consistente.

A los elementos de $\mathcal{A}$ los llamamos **eventos** o **sucesos**, y más precisamente **conjuntos $\mathcal{A}$-medibles**. A la terna $(\Omega, \mathcal{A})$ se la denomina **espacio medible** o **espacio probabilizable**, según el contexto.

Corolario de S1 y S2: $\emptyset \in \mathcal{A}$, pues $\emptyset = \Omega^c$ y $\Omega \in \mathcal{A}$ por S1, luego S2 garantiza que $\Omega^c = \emptyset \in \mathcal{A}$.

Axioma 1.1 — Axiomas de Kolmogórov

Una función $P : \mathcal{A} \longrightarrow \mathbb{R}$ es una **función de probabilidad** sobre $(\Omega, \mathcal{A})$ si se cumplen los siguientes axiomas:

A1) La probabilidad de cualquier suceso S es no negativa:

$$P(S) \geq 0 \quad \forall S \in \mathcal{A}.$$

A2) La probabilidad del suceso seguro es igual a uno:

$$P(\Omega) = 1.$$

A3) Si $\{S_n\}_{n\in\mathbb{N}} \subseteq \mathcal{A}$ son sucesos mutuamente excluyentes, es decir, $S_i \cap S_j = \emptyset \quad \forall i \neq j$, entonces:

$$P\left(\bigcup_{n=1}^{\infty} S_n\right) = \sum_{n=1}^{\infty} P(S_n).$$

A la terna $(\Omega, \mathcal{A}, P)$ se la denomina **espacio de probabilidad**, esto es, un espacio de sucesos (espacio muestral) en el que se han definido los posibles sucesos a considerar (la σ-álgebra de sucesos) y la probabilidad de cada suceso (la función de probabilidad).

Una vez establecidos los tres axiomas, podemos nombrar formalmente el objeto que hemos construido.

Definición 1.4 — Espacio de probabilidad

Un **espacio de probabilidad** es una terna $(\Omega, \mathcal{A}, P)$ donde:

- Ω es el espacio muestral,
- $\mathcal{A}$ es una σ-álgebra sobre Ω (véase Definición 1.3),
- $P : \mathcal{A} \to [0, 1]$ es una función de probabilidad que satisface los axiomas A1, A2 y A3.

El espacio de probabilidad $(\Omega, \mathcal{A}, P)$ es el objeto matemático fundamental sobre el que descansa toda la teoría. Cualquier noción probabilística que desarrollemos — variables aleatorias, esperanza, independencia — vive dentro de este marco.

1.5.1 Propiedades derivadas

De los axiomas de Kolmogórov se deducen las siguientes propiedades. A diferencia de los axiomas, estas no se asumen sino que se *demuestran*.

Proposición 1.1 — Probabilidad del complemento

Para cualquier evento $A \in \mathcal{A}$:

$$P(A^c) = 1 - P(A)$$

Demostración. Como A y A^c son mutuamente excluyentes y $A \cup A^c = \Omega$, por A3:

$$P(A \cup A^c) = P(A) + P(A^c)$$

Por A2, $P(\Omega) = 1$, luego $1 = P(A) + P(A^c)$, de donde:

$$P(A^c) = 1 - P(A)$$

■

Proposición 1.2 — Probabilidad del evento imposible

$$P(\emptyset) = 0$$

Demostración. Basta notar que $\emptyset = \Omega^c$. Aplicando la proposición anterior:

$$P(\emptyset) = P(\Omega^c) = 1 - P(\Omega) = 1 - 1 = 0$$

■

Proposición 1.3 — Monotonía y diferencia de eventos

Si $A \subset B$, entonces:

$$P(A) \leq P(B) \qquad \text{y} \qquad P(B - A) = P(B) - P(A)$$

Demostración. Si $A \subset B$, entonces B puede descomponerse como unión disjunta:

$$B = A \cup (B - A), \qquad A \cap (B - A) = \emptyset$$

Por A3:

$$P(B) = P(A) + P(B - A)$$

Como por A1 $P(B - A) \geq 0$, se sigue que $P(A) \leq P(B)$. Despejando:

$$P(B - A) = P(B) - P(A)$$

■

Proposición 1.4 — Aditividad general (regla de la suma)

Para cualquier par de eventos $A, B \in \mathcal{A}$:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Demostración. Descomponemos $A \cup B$ en tres partes mutuamente excluyentes:

$$A \cup B = (A - B) \cup (A \cap B) \cup (B - A)$$

Por A3:

$$P(A \cup B) = P(A - B) + P(A \cap B) + P(B - A)$$

Aplicando la proposición anterior a $A \cap B \subset A$ y $A \cap B \subset B$:

$$P(A - B) = P(A) - P(A \cap B), \qquad P(B - A) = P(B) - P(A \cap B)$$

Sustituyendo:

$$P(A \cup B) = P(A) - P(A \cap B) + P(A \cap B) + P(B) - P(A \cap B)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

■

Propiedad	**Expresión**	**Condición**
Complemento	$P(A^c) = 1 - P(A)$	—
Evento imposible	$P(\emptyset) = 0$	—
Monotonía	$P(A) \leq P(B)$	$A \subset B$
Diferencia	$P(B - A) = P(B) - P(A)$	$A \subset B$
Regla de la suma	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$	—

1.6 Probabilidad condicional

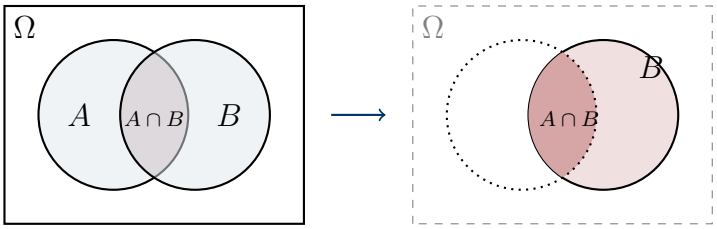
Hasta ahora hemos calculado probabilidades sobre el espacio muestral completo Ω. Sin embargo, muchas veces disponemos de información parcial: sabemos que cierto evento B *ya ocurrió*, y queremos actualizar la probabilidad de otro evento A a la luz de ese conocimiento.

Motivación: la reducción del espacio muestral

La idea central es la siguiente. Si sabemos con certeza que B ocurrió, entonces los resultados fuera de B dejan de ser posibles. En efecto, nuestro universo de referencia se **reduce** de Ω a B: el evento B pasa a funcionar como un nuevo espacio muestral.

Dentro de este universo reducido, la única parte de A que sigue siendo relevante es la que cae dentro de B, es decir, $A \cap B$. La figura 1.1 ilustra esta reducción.

Ahora bien, para que las probabilidades dentro de este nuevo universo B vuelvan a sumar 1, debemos *re-escalar* dividiendo por $P(B)$. Esto motiva la siguiente definición.



Sin condicionar Condicionado en B

Figura 1.1: Al condicionar en B, el espacio muestral se reduce de Ω a B. Lo único relevante de A pasa a ser $A \cap B$.

1.6.1 Definición

Definición 1.5 — Probabilidad condicional

Sean A y B dos eventos con $P(B) \neq 0$. La **probabilidad condicional de A dado B** se define como:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

La condición $P(B) \neq 0$ es esencial: no tiene sentido condicionar en un evento que no puede ocurrir, pues el universo reducido sería vacío.

Observación. *La probabilidad condicional $P(\cdot \mid B)$ es, ella misma, una función de probabilidad legítima sobre el espacio reducido: satisface los tres axiomas de Kolmogórov. En particular, $P(B \mid B) = 1$, lo que confirma que B actúa como el nuevo evento seguro.*

Demostración. Verificamos los tres axiomas para $P(\cdot \mid B)$:

A1 — No negatividad: Sea $A \in \mathcal{A}$. Como $A \cap B \subseteq B$ y P satisface A1, tenemos $P(A \cap B) \geq 0$. Como además $P(B) > 0$ por hipótesis:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \geq 0$$

A2 — Normalización:

$$P(\Omega \mid B) = \frac{P(\Omega \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1$$

donde usamos que $\Omega \cap B = B$.

A3 — Aditividad contable: Sean $A_1, A_2, \ldots \in \mathcal{A}$ eventos mutuamente excluyentes. Entonces los eventos $A_1 \cap B,\ A_2 \cap B, \ldots$ también son mutuamente excluyentes,

pues:

$$(A_i \cap B) \cap (A_j \cap B) = (A_i \cap A_j) \cap B = \emptyset \cap B = \emptyset \quad \forall\, i \neq j$$

Aplicando A3 de Kolmogórov a la función P original:

$$P\left(\bigcup_{n=1}^{\infty} A_n \;\middle|\; B\right) = \frac{P((\bigcup_{n=1}^{\infty} A_n) \cap B)}{P(B)} = \frac{P(\bigcup_{n=1}^{\infty}(A_n \cap B))}{P(B)} = \frac{\sum_{n=1}^{\infty} P(A_n \cap B)}{P(B)} = \sum_{n=1}^{\infty} P(A_n \mid B)$$

donde usamos la distributividad de la intersección sobre la unión. ■

1.6.2 Regla de la multiplicación

Despejando $P(A \cap B)$ de la definición anterior obtenemos una identidad muy útil para calcular probabilidades de intersecciones:

Proposición 1.5 — Regla de la multiplicación

Sean A y B dos eventos con $P(B) \neq 0$. Entonces:

$$P(A \cap B) = P(A \mid B) \cdot P(B)$$

Demostración. Despejando $P(A \cap B)$ directamente de la Definición 1.5:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \implies P(A \cap B) = P(A \mid B) \cdot P(B)$$

■

Esta regla es especialmente útil en experimentos secuenciales —por ejemplo, extracciones sucesivas sin reposición— donde la probabilidad de cada etapa depende del resultado de la anterior.

1.7 Independencia de eventos

Al estudiar la probabilidad condicional, vimos que $P(A \mid B)$ cuantifica cómo el conocimiento de B modifica la probabilidad de A. Surge entonces una pregunta natural: ¿qué ocurre cuando ese conocimiento no modifica nada? Es decir, ¿cuándo saber que B ocurrió es completamente irrelevante para A?

Definición 1.6 — Independencia de eventos

Sean A y B dos eventos con $P(B) \neq 0$. Decimos que A y B son **independientes** si:

$$P(A \mid B) = P(A)$$

Es decir, el conocimiento de que B ocurrió no altera la probabilidad de A.

Observación. *Esta definición exige $P(B) \neq 0$ para que $P(A \mid B)$ esté definida. La proposición siguiente elimina esa restricción y constituye el criterio operacional que se usa en la práctica.*

Proposición 1.6 — Criterio de independencia

Sean A y B dos eventos. A y B son independientes si y solo si:

$$P(A \cap B) = P(A) \cdot P(B)$$

Demostración. Partimos de la definición de independencia $P(A \mid B) = P(A)$ y aplicamos la regla de la multiplicación (Proposición 1.5):

$$P(A \cap B) = P(A \mid B) \cdot P(B) = P(A) \cdot P(B)$$

■

Esta caracterización es más general que la definición porque no requiere $P(B) \neq 0$, y es simétrica en A y B — lo que hace evidente que si A es independiente de B, entonces B es independiente de A.

Observación. ***Independencia vs. exclusión mutua.*** *Estos conceptos son frecuentemente confundidos, pero son casi opuestos. Si A y B son mutuamente excluyentes ($A \cap B = \emptyset$) y ambos tienen probabilidad positiva, entonces:*

$$P(A \cap B) = 0 \neq P(A) \cdot P(B)$$

luego no son independientes. De hecho, la exclusión mutua implica la máxima dependencia posible: saber que A ocurrió hace imposible que ocurra B.

Proposición 1.7 — Independencia de complementos

Si A y B son independientes, entonces A^c y B^c también son independientes.

Demostración. Por la Proposición 1.6, basta mostrar que $P(A^c \cap B^c) = P(A^c) \cdot P(B^c)$.

Observamos primero que $A^c \cap B^c = (A \cup B)^c$ por las leyes de De Morgan. Luego, usando la Proposición 1.1 y la regla de la suma (Proposición 1.4):

$$P(A^c \cap B^c) = P((A \cup B)^c) = 1 - P(A \cup B)$$

$$= 1 - P(A) - P(B) + P(A \cap B)$$

Como A y B son independientes, $P(A \cap B) = P(A) \cdot P(B)$:

$$= 1 - P(A) - P(B) + P(A) \cdot P(B)$$

Factorizando:

$$= (1 - P(A))(1 - P(B)) = P(A^c) \cdot P(B^c)$$

■

1.8 Probabilidad total y Teorema de Bayes

1.8.1 Partición del espacio muestral

Definición 1.7 — Partición

Una colección de eventos $A_1, A_2, \ldots, A_k$ constituye una **partición** del espacio muestral Ω si satisface:

P1) Son **mutuamente excluyentes**: $A_i \cap A_j = \emptyset$ para todo $i \neq j$.

P2) Son **exhaustivos**: $\bigcup_{i=1}^{k} A_i = \Omega$.

Intuitivamente, una partición divide a Ω en piezas que no se solapan y que, en conjunto, lo cubren por completo. Exactamente uno de los eventos A_i ocurre siempre.

1.8.2 Teorema de probabilidades totales

A veces no es posible calcular $P(B)$ de manera directa, pero sí conocemos cómo se comporta B dentro de cada pieza de una partición. El teorema de probabilidades totales permite recomponer $P(B)$ a partir de esa información parcial.

La idea geométrica se aprecia en la figura 1.2: la partición $\{A_1, A_2, A_3\}$ divide a Ω en franjas, y el evento B queda automáticamente descompuesto en las piezas disjuntas $B \cap A_1$, $B \cap A_2$ y $B \cap A_3$.

Teorema 1.1 — Probabilidades totales

Sea $A_1, A_2, \ldots, A_k$ una partición de Ω con $P(A_i) > 0$ para todo i. Entonces,

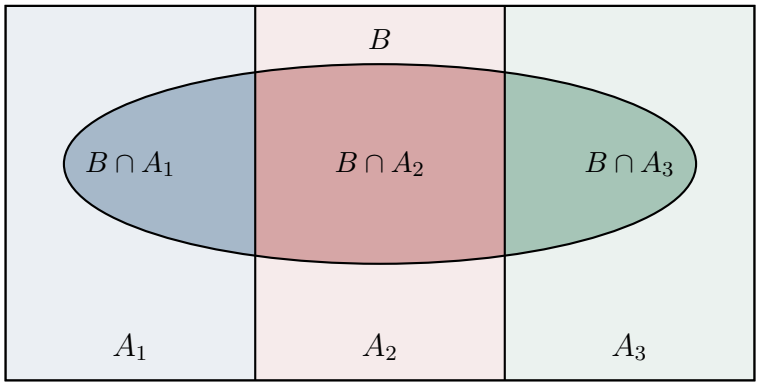


Figura 1.2: La partición $\{A_1, A_2, A_3\}$ descompone al evento B en las piezas disjuntas $B \cap A_i$.

para cualquier evento B:

$$P(B) = \sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)$$

Demostración. La demostración consta de tres pasos.

Paso 1 — Descomposición de B. Como los A_i son exhaustivos, $B = B \cap \Omega = B \cap \left(\bigcup_{i=1}^{k} A_i\right)$. Por distributividad:

$$B = \bigcup_{i=1}^{k} (B \cap A_i)$$

Paso 2 — Aditividad. Como los A_i son mutuamente excluyentes, también lo son los eventos $B \cap A_i$:

$$(B \cap A_i) \cap (B \cap A_j) = B \cap (A_i \cap A_j) = B \cap \emptyset = \emptyset \quad \forall\, i \neq j$$

Aplicando el axioma A3:

$$P(B) = \sum_{i=1}^{k} P(B \cap A_i)$$

Paso 3 — Regla de la multiplicación. Aplicando la Proposición 1.5 a cada término:

$$P(B \cap A_i) = P(B \mid A_i)\, P(A_i)$$

Sustituyendo:

$$P(B) = \sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)$$

■

Observación. *El teorema puede leerse como un* ***promedio ponderado****: la probabilidad total de B es el promedio de las probabilidades condicionales $P(B \mid A_i)$, donde cada una se pondera por el "peso" $P(A_i)$ de su pieza en la partición.*

1.8.3 Teorema de Bayes

El teorema de probabilidades totales responde a la pregunta: ¿cuál es la probabilidad de B? El teorema de Bayes responde la pregunta *inversa*: si observamos que B ocurrió, ¿cuál es la probabilidad de que la pieza responsable haya sido A?

Versión simple: dos eventos

Comencemos con el caso más sencillo, en que la partición consta de un evento A y su complemento A^c.

Teorema 1.2 — Regla de Bayes (forma simple)

Sean A y B dos eventos con $P(A) > 0$ y $P(B) > 0$. Entonces:

$$P(A \mid B) = \frac{P(B \mid A)\, P(A)}{P(B)}$$

Demostración. Por la definición de probabilidad condicional aplicada a $P(A \mid B)$, y luego la regla de la multiplicación en el numerador:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B \mid A)\, P(A)}{P(B)}$$

■

Esta forma es la más fácil de memorizar y expone la idea esencial: el teorema **invierte** la condicional, permitiéndonos pasar de $P(B \mid A)$ a $P(A \mid B)$.

Versión general: una partición

Cuando disponemos de una partición completa $A_1, \ldots, A_k$ y no conocemos $P(B)$ directamente, podemos expandir el denominador mediante el teorema de probabilidades totales. Esto da la forma general.

Teorema 1.3 — Regla de Bayes (forma general)

Sea $A_1, A_2, \ldots, A_k$ una partición de Ω con $P(A_i) > 0$ para todo i, y sea B un evento con $P(B) > 0$. Entonces, para cada j:

$$P(A_j \mid B) = \frac{P(B \mid A_j)\, P(A_j)}{\sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)}$$

Demostración. Partimos de la forma simple aplicada a A_j:

$$P(A_j \mid B) = \frac{P(B \mid A_j)\, P(A_j)}{P(B)}$$

y reemplazamos el denominador $P(B)$ por su expresión según el Teorema 1.1 de probabilidades totales:

$$P(A_j \mid B) = \frac{P(B \mid A_j)\, P(A_j)}{\sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)}$$

■

Observación. *La forma simple es el caso particular de la general con $k = 2$, tomando $A_1 = A$ y $A_2 = A^c$. En efecto, el denominador se convierte en $P(B \mid A)\, P(A) + P(B \mid A^c)\, P(A^c) = P(B)$.*

Interpretación geométrica y un ejemplo concreto

La forma simple de Bayes tiene una lectura geométrica muy intuitiva, que además revela *por qué* la fórmula es válida. La clave está en que la probabilidad de la intersección $P(A \cap B)$ puede calcularse de dos maneras distintas, según el orden en que descompongamos:

$$P(A \cap B) = P(B \mid A)\, P(A) = P(A \mid B)\, P(B)$$

Igualando las dos expresiones y despejando $P(A \mid B)$ se obtiene directamente el teorema de Bayes. Toda la fuerza del resultado descansa en esta simple identidad.

Consideremos un ejemplo concreto. Supongamos un grupo de 12 personajes, cada uno de los cuales puede ser un asesino (A) o no (A^c), y puede comportarse de manera sospechosa (B) o no (B^c). La siguiente tabla de contingencia resume cuántos hay de cada tipo:

De la tabla leemos directamente:

$$P(A) = \tfrac{4}{12}, \quad P(B) = \tfrac{5}{12}, \quad P(B \mid A) = \tfrac{3}{4}, \quad P(A \mid B) = \tfrac{3}{5}, \quad P(A \cap B) = \tfrac{3}{12}$$

	B	B^c	suma
A	**3**	**1**	4
A^c	**2**	**6**	8
suma	5	7	12

Figura 1.3: Tabla de contingencia: hay 3 asesinos sospechosos, 1 asesino no sospechoso, 2 no asesinos sospechosos y 6 no asesinos no sospechosos.

Ahora bien, la identidad geométrica se aprecia en la figura 1.4: el área del rectángulo $A \cap B$ es la misma sin importar cómo la construyamos. A la izquierda la obtenemos tomando primero la fracción $P(A)$ y luego, dentro de ella, la fracción $P(B \mid A)$. A la derecha tomamos primero $P(B)$ y luego $P(A \mid B)$. Ambos caminos llegan al mismo rectángulo.

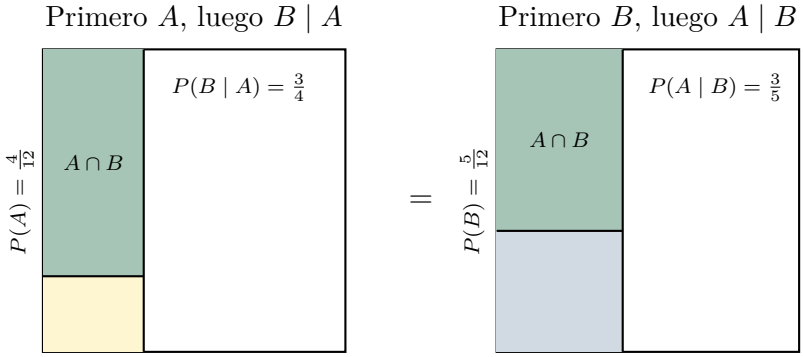


Figura 1.4: El área de $A \cap B$ se construye de dos formas: $P(A)\,P(B \mid A)$ (izquierda) y $P(B)\,P(A \mid B)$ (derecha). Como ambas dan la misma área, igualarlas produce el teorema de Bayes.

Verifiquémoslo numéricamente. Por la izquierda:

$$P(B \mid A)\,P(A) = \tfrac{3}{4} \cdot \tfrac{4}{12} = \tfrac{3}{12}$$

Por la derecha:

$$P(A \mid B)\,P(B) = \tfrac{3}{5} \cdot \tfrac{5}{12} = \tfrac{3}{12}$$

Ambas coinciden, como debía ser. Y despejando $P(A \mid B)$ de la igualdad recuperamos Bayes:

$$P(A \mid B) = \frac{P(B \mid A)\,P(A)}{P(B)} = \frac{\frac{3}{4} \cdot \frac{4}{12}}{\frac{5}{12}} = \frac{3}{5}$$

que es exactamente el valor que habíamos leído directamente de la tabla.

Observación. *El teorema de Bayes es la herramienta formal que permite* ***invertir***

condicionales: pasar de $P(B \mid A_j)$ —lo que típicamente conocemos— a $P(A_j \mid B)$ —lo que deseamos inferir. En el lenguaje bayesiano, $P(A_j)$ es la ***probabilidad a priori*** *(lo que sabemos antes de observar) y $P(A_j \mid B)$ es la* ***probabilidad a posteriori*** *(lo que sabemos después de observar la evidencia B).*

El teorema de Bayes nació de una pregunta filosófica, no técnica. En su *Investigación sobre el entendimiento humano*, Hume había planteado que la inducción carece de justificación lógica (que consiste en observar patrones o casos específicos en el mundo real para llegar a una conclusión general): por más veces que hayamos observado que el sol sale cada mañana, ninguna cantidad de observaciones pasadas garantiza lógicamente que saldrá mañana. Los fundamentos de esto se deben a la visión empirista radical de este filósofo, pues para Hume la única fuente del conocimiento debe ser la experiencia sensible. Si esto es así, el conocimiento empírico —incluida toda la ciencia newtoniana— descansaría sobre una base irracional.

Thomas Bayes, ministro presbiteriano inglés y contemporáneo de Hume, buscaba una respuesta rigurosa a ese problema. La encontró escondida dentro de la definición de probabilidad condicional que ya existía: su fórmula revela que conocer $P(B \mid A)$ es suficiente para inferir $P(A \mid B)$ —pasar del efecto a la causa, de la evidencia observable a la hipótesis no observable. No se necesita certeza lógica para aprender racionalmente; basta un mecanismo coherente de actualización de creencias, y ese mecanismo es la fórmula de Bayes.

A más evidencia acumulada, más convergen las probabilidades a posteriori hacia la verdad, independientemente de cuál fuera la creencia inicial. Es una respuesta pragmática y matemáticamente precisa al escepticismo de Hume. Por eso el teorema —publicado póstumamente en 1763 por su amigo Richard Price— aparece hoy en dominios tan distintos como el diagnóstico médico, los filtros de spam, la navegación autónoma y el aprendizaje automático: en todos ellos subyace el mismo problema que preocupaba a Hume y a Bayes, esto es, dado lo que observo, ¿qué puedo inferir sobre lo que no veo?

Tema 2

Variable aleatoria discreta

2.1 ¿Qué es una variable aleatoria?

Hasta ahora hemos trabajado con eventos — subconjuntos abstractos del espacio muestral Ω. Sin embargo, en la práctica queremos asociar *números* a los resultados de un experimento aleatorio: el número de clientes que llegan en una hora, el monto de una transacción, la cantidad de fallas en un proceso. Para eso necesitamos una función que traduzca los elementos de Ω a la recta numérica. Ese objeto es la **variable aleatoria**.

Definición 2.1 — Variable aleatoria

Sea $(\Omega, \mathcal{A}, P)$ un espacio de probabilidad. Una **variable aleatoria** es una función:

$$X : \Omega \longrightarrow \mathbb{R}$$

que satisface la condición de **medibilidad**: para todo $x \in \mathbb{R}$,

$$\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{A}$$

Es decir, el conjunto de resultados para los cuales X no supera el valor x siempre es un evento — pertenece a la σ-álgebra $\mathcal{A}$.

Observación. *La condición de medibilidad exige que $\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{A}$ para todo $x \in \mathbb{R}$. Esto garantiza que siempre tenga sentido calcular $P(X \leq x)$ — si ese conjunto no perteneciera a $\mathcal{A}$, la función P no estaría definida sobre él. En espacios finitos o contables, toda función $X : \Omega \to \mathbb{R}$ es automáticamente medible, por lo que la condición solo cobra relevancia técnica en espacios continuos.*

Observación. *Usaremos letras mayúsculas (X, Y, Z) para denotar variables aleatorias y letras minúsculas (x, y, z) para los valores concretos que estas pueden tomar. La notación $P(X = x)$ significa la probabilidad del evento $\{\omega \in \Omega : X(\omega) = x\}$.*

Ejemplo: suma de dos dados

Lanzamos dos dados equilibrados. El espacio muestral es:

$$\Omega = \{(i, j) : i, j \in \{1, 2, 3, 4, 5, 6\}\}, \quad \#\Omega = 36$$

Definimos la variable aleatoria X como la *suma* de los valores obtenidos:

$$X(i, j) = i + j$$

Por ejemplo, $X(1, 2) = 3$, $X(3, 3) = 6$ y $X(6, 6) = 12$. La figura 2.1 ilustra cómo X mapea elementos de Ω a valores en $\mathbb{R}$.

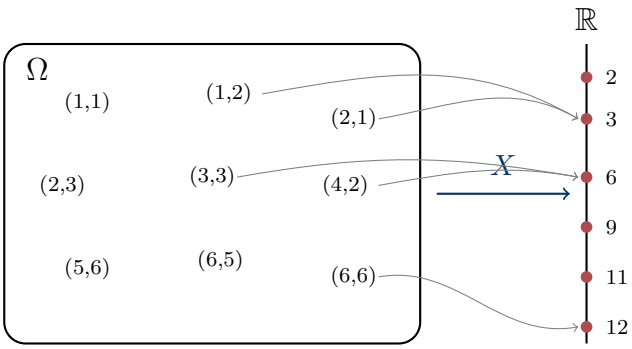


Figura 2.1: La variable aleatoria X como función $\Omega \to \mathbb{R}$. Distintos elementos de Ω pueden mapearse al mismo valor real (por ejemplo, $(1, 2)$ y $(2, 1)$ ambos mapean a $X = 3$).

Nótese un hecho importante: varios elementos de Ω mapean al mismo valor de X. Los pares $(1, 2)$ y $(2, 1)$ producen ambos $X = 3$; los pares $(1, 5)$, $(2, 4)$, $(3, 3)$, $(4, 2)$ y $(5, 1)$ producen todos $X = 6$. Esto es lo esperable — la variable aleatoria *resume* información del resultado, colapsando múltiples resultados en un mismo número.

2.2 Clasificación de las variables aleatorias

Definición 2.2 — Variable aleatoria discreta

Una variable aleatoria X es **discreta** si su recorrido $\text{Rec}(X) = \{x \in \mathbb{R} : P(X = x) > 0\}$ es finito o contable. Es decir, sus valores posibles pueden listarse como una sucesión $x_1, x_2, x_3, \ldots$

Definición 2.3 — Variable aleatoria continua

Una variable aleatoria X es **continua** si su recorrido abarca un intervalo (o unión de intervalos) de la recta numérica. En este caso, $P(X = x) = 0$ para todo valor particular x, y la probabilidad solo tiene sentido sobre intervalos.

Observación. *La distinción entre discreta y continua no es solo técnica — implica herramientas matemáticas distintas. Para variables discretas usaremos sumas; para variables continuas, integrales. En este capítulo nos concentramos en el caso discreto. El caso continuo se trata en el Tema 3.*

En el ejemplo de los dos dados, $X = i + j$ toma valores en $\{2, 3, 4, \ldots, 12\}$ — un conjunto finito — por lo que es una variable aleatoria **discreta**. En cambio, el tiempo de espera hasta que llega el próximo cliente puede tomar cualquier valor en $[0, +\infty)$, por lo que sería **continua**.

2.3 Función de masa de probabilidad

Una vez definida una variable aleatoria discreta X, la pregunta natural es: ¿cómo se distribuye la probabilidad sobre sus valores posibles? La función de masa de probabilidad responde exactamente eso — asigna a cada valor posible de X la probabilidad de que X tome ese valor.

Definición 2.4 — Función de masa de probabilidad

Sea X una variable aleatoria discreta con recorrido $\mathrm{Rec}(X)$. La **función de masa de probabilidad** de X es la función $p_X : \mathbb{R} \to [0, 1]$ definida por:

$$p_X(x) = P(X = x) = P(\{\omega \in \Omega : X(\omega) = x\})$$

para todo $x \in \mathbb{R}$, donde $p_X(x) = 0$ para todo $x \notin \mathrm{Rec}(X)$.

El nombre **función de masa** no es arbitrario — proviene de la mecánica clásica. Si imaginamos los valores del recorrido $x \in \mathrm{Rec}(X)$ como posiciones sobre una recta, y las probabilidades $p_X(x)$ como **masas puntuales** concentradas en esas posiciones, entonces la distribución de probabilidad discreta es formalmente idéntica a un sistema físico de partículas. Esta analogía no es solo pedagógica — es una identidad matemática exacta que veremos reflejada en las definiciones de valor esperado y varianza.

Observación. ***Sobre la terminología.*** *En el curso, y en muchos textos de estadística aplicada, esta función se denomina función de distribución de probabilidad. Esta terminología es técnicamente imprecisa: el término distribución está reservado más apropiadamente para la función de distribución acumulada*

$F_X(x) = P(X \leq x)$, que veremos en la sección siguiente. La denominación correcta para $p_X(x) = P(X = x)$ es ***función de masa de probabilidad****, que es la que usaremos en este apunte. La distinción se vuelve especialmente importante en el Tema 3, cuando introduzcamos la* ***función de densidad de probabilidad*** *para variables continuas — un objeto distinto que también suele llamarse coloquialmente "función de distribución", generando confusión.*

Observación. ***Sobre la notación.*** *En este apunte usamos $p_X(x)$ para la función de masa de probabilidad, distinguiéndola de P — la función de probabilidad sobre eventos definida en los axiomas de Kolmogórov (Definición 1.4). La distinción es:*

$P(A)$	*probabilidad de un evento $A \in \mathcal{A}$*	*(Kolmogórov)*
$p_X(x)$	*probabilidad de que X tome el valor x*	*(función de masa)*

La relación entre ambas es: $p_X(x) = P(\{\omega : X(\omega) = x\})$ — la función de masa es simplemente P aplicada al evento $\{X = x\}$.

En el curso y en muchos textos aplicados esta función también aparece denotada $P(x)$, $p(x)$ o $f(x)$. Todas son la misma cosa. Usaremos $p_X(x)$ por claridad, pero reconoceremos cualquiera de estas notaciones en evaluaciones.

2.3.1 Propiedades

La función de masa de probabilidad satisface dos propiedades que se deducen directamente de los axiomas de Kolmogórov.

Proposición 2.1 — Propiedades de la función de masa

Sea p_X la función de masa de probabilidad de una variable aleatoria discreta X. Entonces:

P1) $0 \leq p_X(x) \leq 1$ para todo $x \in \mathbb{R}$.

P2) $\displaystyle\sum_{x \in \text{Rec}(X)} p_X(x) = 1$.

Demostración. **P1)** Por definición $p_X(x) = P(\{X = x\})$. Como P satisface A1:

$$P(\{X = x\}) \geq 0$$

Como $\{X = x\} \subseteq \Omega$ y $P(\Omega) = 1$, por la Proposición 1.3:

$$P(\{X = x\}) \leq P(\Omega) = 1$$

Luego $0 \leq p_X(x) \leq 1$. □

P2) Los eventos $\{X = x\}$ para $x \in \text{Rec}(X)$ son mutuamente excluyentes y exhaustivos, luego forman una partición de Ω. Aplicando A3:

$$\sum_{x \in \text{Rec}(X)} p_X(x) = \sum_{x \in \text{Rec}(X)} P(X = x) = P\left(\bigcup_{x \in \text{Rec}(X)} \{X = x\} \right) = P(\Omega) = 1$$

■

Observación. *Estas dos propiedades también caracterizan completamente a las funciones de masa: cualquier función $p : \mathbb{R} \to [0, 1]$ que satisfaga P1 y P2 es la función de masa de alguna variable aleatoria discreta. Son el análogo discreto de los axiomas de Kolmogórov para la función de probabilidad sobre eventos.*

2.4 Función de distribución acumulada

La función de masa $p_X(x)$ responde preguntas del tipo $P(X = x)$ — la probabilidad de un valor exacto. Sin embargo, en la práctica casi siempre nos interesan preguntas sobre intervalos: ¿cuál es la probabilidad de que X no supere cierto umbral? ¿De que caiga entre dos valores? La función de distribución acumulada es la herramienta que responde esas preguntas de manera eficiente.

Definición 2.5 — Función de distribución acumulada

Sea X una variable aleatoria discreta con función de masa p_X. La **función de distribución acumulada** (FDA) de X es la función $F_X : \mathbb{R} \to [0, 1]$ definida por:

$$F_X(x) = P(X \leq x) = \sum_{t \leq x} p_X(t) \qquad \text{para todo } x \in \mathbb{R}$$

donde la suma recorre todos los valores $t \in \text{Rec}(X)$ con $t \leq x$.

2.4.1 Propiedades

Proposición 2.2 — Propiedades de la FDA

Sea F_X la función de distribución acumulada de una variable aleatoria discreta X. Entonces:

P1) F_X es **no decreciente**: si $a \leq b$ entonces $F_X(a) \leq F_X(b)$.

P2) F_X tiene **límites en el infinito**:

$$\lim_{x \to -\infty} F_X(x) = 0 \qquad \text{y} \qquad \lim_{x \to +\infty} F_X(x) = 1$$

P3) F_X es **continua por la derecha**: para todo $x \in \mathbb{R}$,

$$\lim_{t \to x^+} F_X(t) = F_X(x)$$

Demostración. **P1)** Si $a \leq b$, entonces el conjunto $\{t \in \text{Rec}(X) : t \leq a\} \subseteq \{t \in \text{Rec}(X) : t \leq b\}$. Como $p_X(t) \geq 0$ para todo t, sumar sobre un conjunto más grande no puede disminuir el resultado:

$$F_X(a) = \sum_{t \leq a} p_X(t) \leq \sum_{t \leq b} p_X(t) = F_X(b) \qquad \square$$

P2) Cuando $x \to -\infty$, no hay valores de $\text{Rec}(X)$ que satisfagan $t \leq x$, luego la suma es vacía y vale 0. Cuando $x \to +\infty$, todos los valores de $\text{Rec}(X)$ satisfacen $t \leq x$, luego por P2 de la Proposición 2.1:

$$\lim_{x \to +\infty} F_X(x) = \sum_{t \in \text{Rec}(X)} p_X(t) = 1 \qquad \square$$

P3) Para t suficientemente cerca de x por la derecha, no hay valores de $\text{Rec}(X)$ en el intervalo $(x, t]$ — el recorrido es discreto, luego existe un salto mínimo entre valores consecutivos. Por tanto $F_X(t) = F_X(x)$ para t suficientemente próximo a x por la derecha, lo que prueba la continuidad por la derecha. ■

Observación. *La propiedad P3 explica la convención de los puntos* ***cerrados*** *y* ***abiertos*** *en la gráfica de la FDA: en cada salto, el punto cerrado (valor que toma F_X) está siempre a la derecha, reflejando que F_X incluye el valor x mismo en la suma — es decir, $P(X \leq x)$ y no $P(X < x)$.*

2.4.2 Cálculo de probabilidades con la FDA

La utilidad principal de la FDA es que permite calcular probabilidades sobre intervalos con una simple resta, sin necesidad de sumar término a término.

Proposición 2.3 — Probabilidades de intervalos

Sea F_X la FDA de una variable aleatoria discreta X. Para cualquier $a < b$:

$$P(a < X \leq b) = F_X(b) - F_X(a)$$

Demostración. Los eventos $\{X \leq a\}$ y $\{a < X \leq b\}$ son mutuamente excluyentes y su unión es $\{X \leq b\}$. Por A3:

$$P(X \leq b) = P(X \leq a) + P(a < X \leq b)$$

Despejando:

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F_X(b) - F_X(a)$$

■

Observación. *Nótese que el intervalo es abierto en a y cerrado en b: $P(a < X \leq b)$ excluye a e incluye b. Esto es consecuencia directa de la continuidad por la derecha de F_X. Para otros tipos de intervalos:*

$$\begin{aligned} P(X > a) &= 1 - F_X(a) \\ P(X \geq a) &= 1 - F_X(a) + p_X(a) = 1 - F_X(a^-) \\ P(a \leq X \leq b) &= F_X(b) - F_X(a) + p_X(a) \end{aligned}$$

Ejemplo: demanda diaria de un tractor

Una empresa arrienda su tractor para trabajos de remoción. La demanda diaria X — el número de veces que se usa el tractor en un día — tiene la siguiente distribución de probabilidad, donde $P(5)$ se deduce de la propiedad P2 de la función de masa: la suma de todas las probabilidades debe ser 1, luego $p_X(5) = 1 - 0.10 - 0.20 - 0.30 - 0.25 - 0.10 = 0.05$.

x	$p_X(x)$	$F_X(x)$
0	0.10	0.10
1	0.20	0.30
2	0.30	0.60
3	0.25	0.85
4	0.10	0.95
5	0.05	1.00

La figura 2.2 muestra la FDA como función escalera. Cada salto ocurre en un valor de $\text{Rec}(X)$ y su altura es exactamente $p_X(x)$.

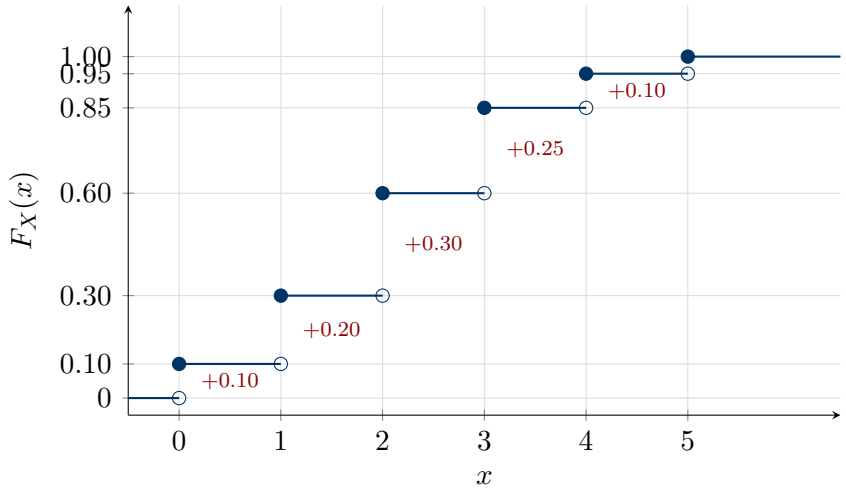


Figura 2.2: Función de distribución acumulada F_X para el ejemplo del tractor. Los puntos cerrados indican continuidad por la derecha. Los saltos en rojo corresponden a $p_X(x)$.

Usando la proposición de intervalos:

$$P(X > 3) = 1 - F_X(3) = 1 - 0.85 = 0.15$$

$$P(1 < X \leq 4) = F_X(4) - F_X(1) = 0.95 - 0.30 = 0.65$$

2.5 Valor esperado y varianza

2.5.1 Valor esperado

Sabemos que una variable aleatoria discreta X puede tomar distintos valores con distintas probabilidades. Una pregunta natural es: ¿cuál es el valor *típico* o *central* de X? La respuesta es el **valor esperado** — un promedio ponderado de los valores posibles de X, donde cada valor se pondera por su probabilidad.

Definición 2.6 — Valor esperado

Sea X una variable aleatoria discreta con función de masa p_X y recorrido $\text{Rec}(X)$. El **valor esperado**, **valor medio** o **esperanza** de X, denotado $E(X)$, μ_X o μ, es:

$$E(X) = \sum_{x \in \text{Rec}(X)} x \cdot p_X(x)$$

La definición del valor esperado no es arbitraria — tiene un origen físico preciso. En mecánica clásica, el **centro de masa** de un sistema de partículas con masas

m_i en posiciones x_i es:

$$\bar{x} = \frac{\sum_i m_i x_i}{\sum_i m_i}$$

Si normalizamos las masas para que sumen 1 — definiendo $p_i = m_i / \sum_j m_j$ — obtenemos exactamente:

$$\bar{x} = \sum_i x_i \, p_i = E(X)$$

El valor esperado es el punto donde la distribución estaría en equilibrio si la colocáramos sobre un fulcro. La figura 2.3 muestra este paralelismo explícitamente.

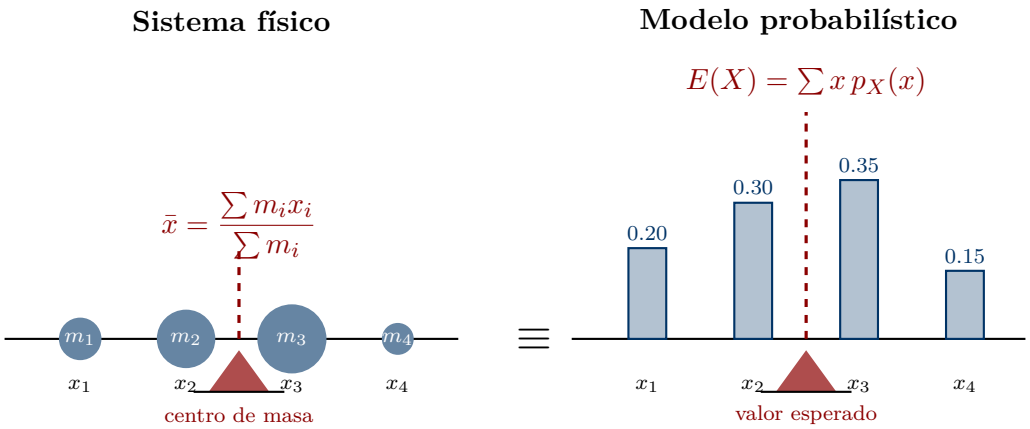


Figura 2.3: El valor esperado como centro de masa. Las masas físicas m_i normalizadas corresponden a las probabilidades $p_X(x_i)$; el punto de equilibrio físico corresponde a $E(X)$.

Proposición 2.4 — Valor esperado de una función de X

Sea $h : \mathbb{R} \to \mathbb{R}$ una función. El valor esperado de $h(X)$ es:

$$E(h(X)) = \sum_{x \in \text{Rec}(X)} h(x) \cdot p_X(x)$$

Proposición 2.5 — Linealidad del valor esperado

Si a y b son constantes, entonces:

$$E(aX + b) = aE(X) + b$$

Demostración. Aplicamos la Proposición 2.4 con $h(x) = ax + b$:

$$E(aX+b) = \sum_{x \in \text{Rec}(X)} (ax+b)\, p_X(x) = a \sum_{x \in \text{Rec}(X)} x\, p_X(x) + b \sum_{x \in \text{Rec}(X)} p_X(x) = aE(X)+b$$

donde en el último paso usamos la definición de $E(X)$ y la propiedad P2 de la función de masa ($\sum p_X(x) = 1$). ■

Ejemplo: demanda mensual

Una empresa registra la demanda mensual X de un producto durante dos años y obtiene la siguiente distribución:

x	300	400	500	600
$p_X(x)$	0.20	0.30	0.35	0.15

El valor esperado es:

$$E(X) = 300(0.20) + 400(0.30) + 500(0.35) + 600(0.15) = 60 + 120 + 175 + 90 = 445$$

La figura 2.4 muestra la función de masa con el valor esperado marcado como centro de la distribución.

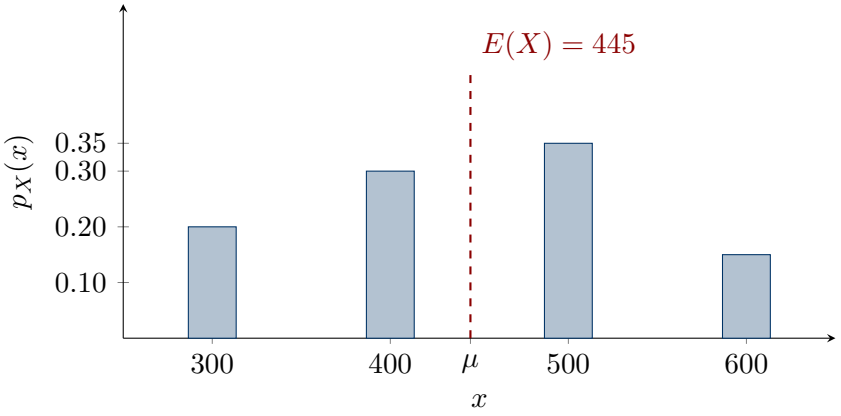


Figura 2.4: Función de masa p_X para la demanda mensual. La línea roja marca el valor esperado $E(X) = 445$ — el centro de masa de la distribución.

2.5.2 Varianza

El valor esperado nos dice dónde está el centro de la distribución, pero no dice nada sobre qué tan dispersos están los valores de X alrededor de ese centro. Dos distribuciones pueden tener el mismo $E(X)$ y ser completamente distintas en su dispersión. La **varianza** cuantifica esa dispersión.

Definición 2.7 — Varianza

Sea X una variable aleatoria discreta con $E(X) = \mu$. La **varianza** de X, denotada $\text{Var}(X)$, $V(X)$, σ_X^2 o σ^2, es:

$$\text{Var}(X) = E\Big[(X-\mu)^2\Big] = \sum_{x \in \text{Rec}(X)} (x-\mu)^2 \, p_X(x)$$

La **desviación estándar** de X es $\sigma_X = \sqrt{\text{Var}(X)}$.

El paralelismo con la física se extiende a la varianza. En mecánica clásica, el **momento de inercia** de un sistema de partículas respecto a un eje que pasa por el centro de masa es:

$$I = \sum_i m_i (x_i - \bar{x})^2$$

Bajo normalización de las masas, esto es exactamente:

$$I = \sum_i (x_i - \bar{x})^2 \, p_i = \text{Var}(X)$$

La varianza mide lo mismo que el momento de inercia: qué tan *lejos* están las masas — o las probabilidades — del centro. Un sistema con masas muy dispersas tiene momento de inercia grande; una distribución con valores muy dispersos alrededor de μ tiene varianza grande. La figura 2.5 ilustra esta equivalencia.

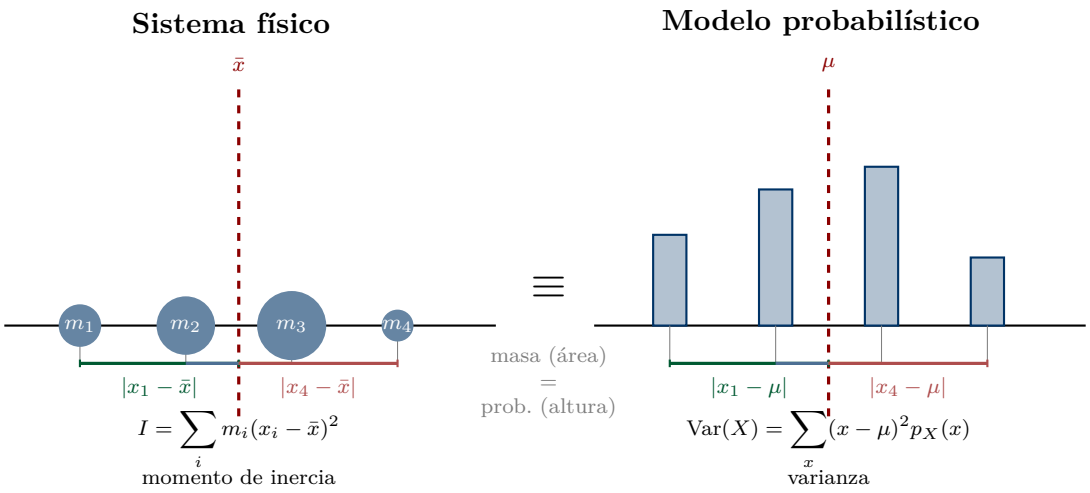


Figura 2.5: La varianza como momento de inercia. Los segmentos de color bajo el eje muestran la distancia $|x_i - \bar{x}|$ de cada valor al centro. La varianza pondera el *cuadrado* de esas distancias por la masa (o probabilidad) correspondiente.

Observación. *La varianza promedia el cuadrado de las desviaciones respecto a μ, no las desviaciones directas. Esto tiene dos razones: primero, las desviaciones positivas y negativas no se cancelan; segundo, las desviaciones grandes pesan desproporcionadamente más, lo que hace a la varianza sensible a valores extremos. La desviación estándar σ_X devuelve la dispersión a las unidades originales de X.*

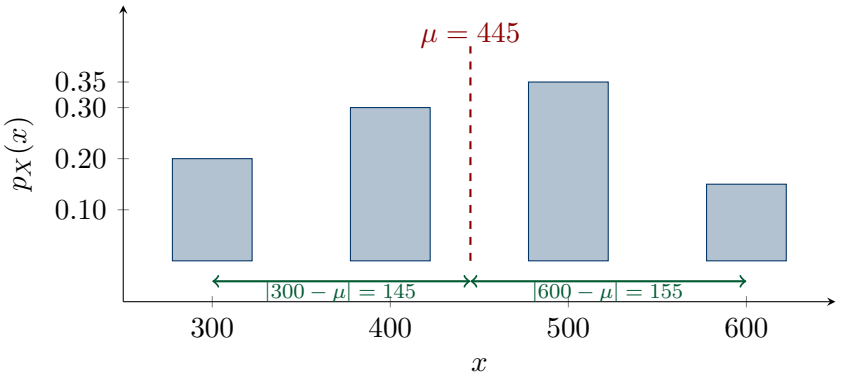


Figura 2.6: La varianza mide la dispersión de X alrededor de $\mu = E(X) = 445$. Las flechas ilustran las desviaciones $|x - \mu|$ para los valores extremos del recorrido.

Proposición 2.6 — Fórmula alternativa de la varianza

$$\mathrm{Var}(X) = E(X^2) - (E(X))^2$$

Demostración. Sea $\mu = E(X)$. Expandimos el cuadrado en la definición:

$$\mathrm{Var}(X) = \sum_{x \in \mathrm{Rec}(X)} (x - \mu)^2 \, p_X(x) = \sum_x (x^2 - 2\mu x + \mu^2) \, p_X(x)$$

Distribuimos la suma:

$$= \sum_x x^2 \, p_X(x) - 2\mu \sum_x x \, p_X(x) + \mu^2 \sum_x p_X(x)$$

Reconocemos cada término: el primero es $E(X^2)$ por la Proposición 2.4 con $h(x) = x^2$; el segundo usa $\sum x \, p_X(x) = \mu$; el tercero usa $\sum p_X(x) = 1$:

$$= E(X^2) - 2\mu \cdot \mu + \mu^2 \cdot 1 = E(X^2) - 2\mu^2 + \mu^2 = E(X^2) - \mu^2 = E(X^2) - (E(X))^2$$

■

Observación. *La fórmula alternativa es la que se usa en la práctica: calcular $E(X^2) - (E(X))^2$ requiere solo dos sumas, mientras que la definición directa requiere calcular $(x - \mu)^2$ para cada valor del recorrido — más laborioso cuando el recorrido es grande.*

Proposición 2.7 — Propiedades de la varianza

Sean a y b constantes. Entonces:

i) $\mathrm{Var}(X) \geq 0$

ii) $\mathrm{Var}(a) = 0$

iii) $\mathrm{Var}(aX+b) = a^2\,\mathrm{Var}(X) \quad$ y $\quad \sigma_{aX+b} = |a|\,\sigma_X$

Demostración. **i)** Cada término $(x-\mu)^2 p_X(x) \geq 0$, luego la suma también. □

ii) Si a es constante, $E(a) = a$ y $(a - E(a))^2 = 0$ para todo resultado, luego $\mathrm{Var}(a) = 0$. □

iii) Por la linealidad del valor esperado (Proposición 2.5), $E(aX+b) = aE(X) + b = a\mu + b$. Aplicando la fórmula alternativa:

$$\mathrm{Var}(aX+b) = E\Big[(aX+b)^2\Big] - (aE(X)+b)^2$$

$$= E\Big[a^2X^2 + 2abX + b^2\Big] - (a^2\mu^2 + 2ab\mu + b^2)$$

$$= a^2E(X^2) + 2ab\mu + b^2 - a^2\mu^2 - 2ab\mu - b^2 = a^2\Big(E(X^2) - \mu^2\Big) = a^2\,\mathrm{Var}(X)$$

La desviación estándar sigue como $\sigma_{aX+b} = \sqrt{a^2\,\mathrm{Var}(X)} = |a|\,\sigma_X$. ■

Observación. *La propiedad iii revela algo importante: sumar una constante b a X* ***no cambia la varianza*** *— desplaza la distribución pero no altera su dispersión. Solo la multiplicación por a escala la varianza, y lo hace de manera cuadrática.*

2.6 Distribuciones importantes

2.6.1 Distribución Binomial

2.6.2 Distribución de Poisson

Tema 3

Variable aleatoria continua

3.1 De lo discreto a lo continuo

3.2 Función de densidad de probabilidad

3.3 Función de distribución acumulada

3.4 Distribución Normal

3.4.1 ¿Por qué $\sqrt{2\pi}$?

3.5 Teorema del Límite Central

Tema 4

Muestreo y distribución de muestreo

4.1 Población, muestra y parámetro

4.2 Estadístico y estimador

4.3 Distribuciones de muestreo

4.3.1 Distribución t de Student

4.3.2 Distribución Chi-cuadrado χ^2

4.3.3 Distribución F de Fisher

Tema 5

Introducción a la inferencia estadística

5.1 Estimación por intervalos de confianza

5.2 Pruebas de hipótesis

5.2.1 El procedimiento de cinco pasos

5.2.2 Prueba para la media con varianza conocida

5.2.3 Prueba para la media con varianza desconocida