Estadísticas y Data Science

EST108 | Ingeniería Comercial

Universidad Adolfo Ibáñez

Apuntes por **Agustín Miranda**

Primer semestre de 2026

Basado en el material de la profesora Florencia Darrigrandi.

Índice general

Introducción: ¿Qué es la estadística? **5**

1. Probabilidad **7**
1.1. ¿Qué es la probabilidad? . . . 7
1.2. ¿Qué es un experimento? . . . 7
1.3. Espacio muestral y eventos . . . 7
1.3.1. Operaciones entre eventos . . . 8
1.4. Interpretaciones de la probabilidad . . . 8
1.4.1. Interpretación clásica o equiprobable . . . 8
1.4.2. Interpretación frecuentista . . . 9
1.4.3. Interpretación subjetiva (bayesiana) . . . 9
1.5. Los axiomas de Kolmogorov . . . 10
1.5.1. Propiedades derivadas . . . 11
1.6. Probabilidad condicional . . . 13
1.6.1. Definición . . . 14
1.6.2. Regla de la multiplicación . . . 15
1.7. Independencia de eventos . . . 15
1.8. Probabilidad total y Teorema de Bayes . . . 17
1.8.1. Partición del espacio muestral . . . 17
1.8.2. Teorema de probabilidades totales . . . 17
1.8.3. Teorema de Bayes . . . 18

2. Variable aleatoria discreta **23**
2.1. ¿Qué es una variable aleatoria? . . . 23
2.2. Variable aleatoria discreta . . . 23
2.3. Función de distribución de probabilidad . . . 23
2.4. Función de distribución acumulada . . . 23
2.5. Valor esperado y varianza . . . 23
2.5.1. Valor esperado . . . 23
2.5.2. Varianza . . . 23
2.6. Distribuciones importantes . . . 23
2.6.1. Distribución Binomial . . . 23
2.6.2. Distribución de Poisson . . . 23

3. Variable aleatoria continua **25**
3.1. De lo discreto a lo continuo . . . 25
3.2. Función de densidad de probabilidad . . . 25
3.3. Función de distribución acumulada . . . 25
3.4. Distribución Normal . . . 25
3.4.1. ¿Por qué $\sqrt{2\pi}$? . . . 25
3.5. Teorema del Límite Central . . . 25

4. Muestreo y distribución de muestreo **27**
4.1. Población, muestra y parámetro . . . 27
4.2. Estadístico y estimador . . . 27
4.3. Distribuciones de muestreo . . . 27
4.3.1. Distribución t de Student . . . 27
4.3.2. Distribución Chi-cuadrado χ^2 . . . 27
4.3.3. Distribución F de Fisher . . . 27

5. Introducción a la inferencia estadística **29**
5.1. Estimación por intervalos de confianza . . . 29
5.2. Pruebas de hipótesis . . . 29
5.2.1. El procedimiento de cinco pasos . . . 29
5.2.2. Prueba para la media con varianza conocida . . . 29
5.2.3. Prueba para la media con varianza desconocida . . . 29

Introducción: ¿Qué es la estadística?

—El término «estadística» deriva del latín *statisticum collegium* (consejo de Estado), y de la palabra italiana *statista* («hombre de estado», «político» o «estadista»). Pero su uso contemporáneo fue acuñado por el historiador y jurista alemán Gottfried Achenwall en 1749 para referirse al análisis de datos acerca del Estado, significando «ciencia del Estado».

Durante el siglo XIX e inicios del XX, el término se fue transformando en una disciplina matemática propiamente rigurosa bajo el trabajo de Francis Galton, Karl Pearson, Ronald Fisher, entre otros que acuñaron los métodos estadísticos modernos que conocemos hoy en día.

De esta manera, podemos definir a la estadística como la ciencia de recolectar, analizar, presentar e interpretar datos.

Tema 1

Probabilidad

1.1 ¿Qué es la probabilidad?

La probabilidad es el lenguaje matemático para cuantificar la incertidumbre.

1.2 ¿Qué es un experimento?

Un experimento es el modelo matemático para cualquier procedimiento que puede ser repetido infinitamente y tiene un conjunto de posibles resultados, que conocemos como:

1.3 Espacio muestral y eventos

Definición 1.1 — Espacio muestral

El espacio muestral (denotado usualmente Ω o S) es el conjunto de **todos los resultados posibles** de un experimento aleatorio.

Definición formal:

$$\Omega = \{\omega : \omega \text{ es un resultado posible del experimento}\}$$

Cada elemento $\omega \in \Omega$ se llama **punto muestral** o **resultado elemental**.

Los subconjuntos de Ω son llamados **eventos**. Dado que los eventos son subconjuntos de Ω, las operaciones de la teoría de conjuntos —unión, intersección y complemento— se aplican directamente, adquiriendo aquí una interpretación probabilística:

1.3.1 Operaciones entre eventos

Ω	Espacio muestral
ω	Resultado (punto o elemento)
A	Evento (subconjunto de Ω)
A^c	Complemento de A (no A)
$A \cup B$	Unión (A o B)
$A \cap B$ o AB	Intersección (A y B)
$A - B$	Diferencia (ω en A pero no en B)
$A \subset B$	Inclusión (A implica B)
$\emptyset$	Evento imposible (siempre falso)
Ω	Evento seguro (siempre verdadero)
$A \cap B = \emptyset$	A y B son mutuamente excluyentes

1.4 Interpretaciones de la probabilidad

Antes de formalizar la probabilidad, es útil preguntarse qué *significa* que un evento tenga probabilidad p. Existen tres respuestas clásicas a esta pregunta, cada una con supuestos y limitaciones distintas.

1.4.1 Interpretación clásica o equiprobable

Definición 1.2 — Espacio equiprobable

Un espacio muestral Ω es **equiprobable** si todos sus elementos tienen igual probabilidad de ocurrir. En este caso, la probabilidad de un evento A se define como:

$$P(A) = \frac{\#A}{\#\Omega} = \frac{\text{casos favorables}}{\text{casos totales}}$$

donde $\#A$ denota la cardinalidad del conjunto A.

Esta interpretación es la más antigua, se remonta a los trabajos del matemático francés Pierre-Simon Laplace (1749-1827) sobre juegos de azar, y es la que se aplica naturalmente cuando todos los resultados del experimento son igualmente posibles: lanzar una moneda justa, tirar un dado equilibrado, extraer una carta de una baraja bien mezclada.

Observación. *La condición de equiprobabilidad debe justificarse, no asumirse. Un error común es definir el espacio muestral de forma que los elementos no sean igualmente probables y luego aplicar la fórmula de Laplace de todos modos. Por*

ejemplo, si una urna contiene 4 fichas con el número 1 y 2 fichas con el número 2, el espacio muestral correcto es $\Omega = \{1_a, 1_b, 1_c, 1_d, 2_a, 2_b\}$ *con* $\#\Omega = 6$*, y no* $\Omega = \{1, 2\}$ *con* $\#\Omega = 2$*, pues en este último los elementos no son equiprobables.*

1.4.2 Interpretación frecuentista

La interpretación frecuentista define la probabilidad de un evento A como el límite de su frecuencia relativa cuando el experimento se repite un número muy grande de veces bajo condiciones idénticas:

$$P(A) = \lim_{n\to\infty} \frac{n_A}{n}$$

donde n es el número total de repeticiones y n_A es el número de veces que ocurrió A.

Esta es la interpretación que subyace a la estadística aplicada: si lanzamos una moneda 10.000 veces y obtenemos cara en 5.032 de ellas, estimamos $P(\text{cara}) \approx 0.5$. A mayor número de repeticiones, mejor la estimación.

Observación. *La interpretación frecuentista tiene una limitación fundamental: exige que el experimento sea repetible en condiciones idénticas. Esto la hace inaplicable a eventos únicos o irrepetibles — como la probabilidad de que llueva mañana en Santiago, o de que una empresa quiebre el próximo año — para los cuales no existe una frecuencia relativa observable.*

1.4.3 Interpretación subjetiva (bayesiana)

La interpretación subjetiva define la probabilidad como un **grado de creencia racional** sobre la ocurrencia de un evento, basado en la información disponible. No requiere repetición del experimento ni equiprobabilidad de los resultados.

Bajo esta visión, dos agentes con información distinta pueden asignar probabilidades distintas al mismo evento sin que ninguno esté "equivocado". Lo que se exige es que las creencias sean *coherentes*, es decir, que satisfagan los axiomas de Kolmogórov que presentaremos en la siguiente sección.

Observación. *Las tres interpretaciones no son mutuamente excluyentes en la práctica. La interpretación clásica es un caso especial de la frecuentista bajo simetría perfecta; y la frecuentista puede entenderse como un caso especial de la subjetiva cuando la evidencia empírica es abrumadora. Lo que unifica las tres es que, en todos los casos, la función* P *debe satisfacer los axiomas que veremos en la sección 1.1.*

1.5 Los axiomas de Kolmogorov

Los axiomas de probabilidad son las condiciones mínimas que deben verificarse para que una función definida sobre un conjunto de sucesos determine consistentemente sus probabilidades. Fueron formulados por el matemático soviético Andréi Kolmogórov en 1933. Y estos son:

Sea Ω un espacio muestral y $\mathcal{A}$ una σ-álgebra de subconjuntos de Ω.

Definición 1.3 — σ-álgebra

Sea Ω un espacio muestral. Una **σ-álgebra** $\mathcal{A}$ sobre Ω es una colección de subconjuntos de Ω que satisface las siguientes tres propiedades:

S1) $\Omega \in \mathcal{A}$.

S2) Si $A \in \mathcal{A}$, entonces $A^c \in \mathcal{A}$ (cerrada bajo complementos).

S3) Si $A_1, A_2, \ldots \in \mathcal{A}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$ (cerrada bajo uniones contables).

A los elementos de $\mathcal{A}$ los llamamos **eventos**, y a la terna $(\Omega, \mathcal{A})$ se la denomina **espacio medible**.

En la práctica, para espacios muestrales finitos o contables, $\mathcal{A}$ corresponde simplemente al conjunto de todos los subconjuntos posibles de Ω — también llamado *conjunto potencia* y denotado 2^{Ω} — por lo que no es necesario preocuparse por esta distinción. La σ-álgebra cobra importancia técnica en espacios continuos, donde no todos los subconjuntos de Ω admiten una asignación de probabilidad consistente.

A los elementos de $\mathcal{A}$ los llamamos **eventos** o **sucesos**, y más precisamente **conjuntos $\mathcal{A}$-medibles**. A la terna $(\Omega, \mathcal{A})$ se la denomina **espacio medible** o **espacio probabilizable**, según el contexto.

Corolario de S1 y S2: $\emptyset \in \mathcal{A}$, pues $\emptyset = \Omega^c$ y $\Omega \in \mathcal{A}$ por S1, luego S2 garantiza que $\Omega^c = \emptyset \in \mathcal{A}$.

Axioma 1.1 — Axiomas de Kolmogórov

Una función $P : \mathcal{A} \longrightarrow \mathbb{R}$ es una **función de probabilidad** sobre $(\Omega, \mathcal{A})$ si se cumplen los siguientes axiomas:

A1) La probabilidad de cualquier suceso S es no negativa:

$$P(S) \geq 0 \quad \forall S \in \mathcal{A}.$$

A2) La probabilidad del suceso seguro es igual a uno:

$$P(\Omega) = 1.$$

A3) Si $\{S_n\}_{n\in\mathbb{N}} \subseteq \mathcal{A}$ son sucesos mutuamente excluyentes, es decir, $S_i \cap S_j = \emptyset \quad \forall i \neq j$, entonces:

$$P\left(\bigcup_{n=1}^{\infty} S_n\right) = \sum_{n=1}^{\infty} P(S_n).$$

A la terna $(\Omega, \mathcal{A}, P)$ se la denomina **espacio de probabilidad**, esto es, un espacio de sucesos (espacio muestral) en el que se han definido los posibles sucesos a considerar (la σ-álgebra de sucesos) y la probabilidad de cada suceso (la función de probabilidad).

De estos axiomas, podemos demostrar las siguientes propiedades:

1.5.1 Propiedades derivadas

De los axiomas de Kolmogórov se deducen las siguientes propiedades. A diferencia de los axiomas, estas no se asumen sino que se *demuestran*.

Proposición 1.1 — Probabilidad del complemento

Para cualquier evento $A \in \mathcal{A}$:

$$P(A^c) = 1 - P(A)$$

Demostración. Como A y A^c son mutuamente excluyentes y $A \cup A^c = \Omega$, por A3:

$$P(A \cup A^c) = P(A) + P(A^c)$$

Por A2, $P(\Omega) = 1$, luego $1 = P(A) + P(A^c)$, de donde:

$$P(A^c) = 1 - P(A)$$

■

Proposición 1.2 — Probabilidad del evento imposible

$$P(\emptyset) = 0$$

Demostración. Basta notar que $\emptyset = \Omega^c$. Aplicando la proposición anterior:

$$P(\emptyset) = P(\Omega^c) = 1 - P(\Omega) = 1 - 1 = 0$$

■

Proposición 1.3 — Monotonía y diferencia de eventos

Si $A \subset B$, entonces:

$$P(A) \leq P(B) \qquad \text{y} \qquad P(B - A) = P(B) - P(A)$$

Demostración. Si $A \subset B$, entonces B puede descomponerse como unión disjunta:

$$B = A \cup (B - A), \qquad A \cap (B - A) = \emptyset$$

Por A3:

$$P(B) = P(A) + P(B - A)$$

Como por A1 $P(B - A) \geq 0$, se sigue que $P(A) \leq P(B)$. Despejando:

$$P(B - A) = P(B) - P(A)$$

■

Proposición 1.4 — Aditividad general (regla de la suma)

Para cualquier par de eventos $A, B \in \mathcal{A}$:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Demostración. Descomponemos $A \cup B$ en tres partes mutuamente excluyentes:

$$A \cup B = (A - B) \cup (A \cap B) \cup (B - A)$$

Por A3:

$$P(A \cup B) = P(A - B) + P(A \cap B) + P(B - A)$$

Aplicando la proposición anterior a $A \cap B \subset A$ y $A \cap B \subset B$:

$$P(A - B) = P(A) - P(A \cap B), \qquad P(B - A) = P(B) - P(A \cap B)$$

Sustituyendo:

$$P(A \cup B) = P(A) - P(A \cap B) + P(A \cap B) + P(B) - P(A \cap B)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

■

Propiedad	Expresión	Condición
Complemento	$P(A^c) = 1 - P(A)$	—
Evento imposible	$P(\emptyset) = 0$	—
Monotonía	$P(A) \leq P(B)$	$A \subset B$
Diferencia	$P(B - A) = P(B) - P(A)$	$A \subset B$
Regla de la suma	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$	—

1.6 Probabilidad condicional

Hasta ahora hemos calculado probabilidades sobre el espacio muestral completo Ω. Sin embargo, muchas veces disponemos de información parcial: sabemos que cierto evento B *ya ocurrió*, y queremos actualizar la probabilidad de otro evento A a la luz de ese conocimiento.

Motivación: la reducción del espacio muestral

La idea central es la siguiente. Si sabemos con certeza que B ocurrió, entonces los resultados fuera de B dejan de ser posibles. En efecto, nuestro universo de referencia se **reduce** de Ω a B: el evento B pasa a funcionar como un nuevo espacio muestral.

Dentro de este universo reducido, la única parte de A que sigue siendo relevante es la que cae dentro de B, es decir, $A \cap B$. La figura 1.1 ilustra esta reducción.

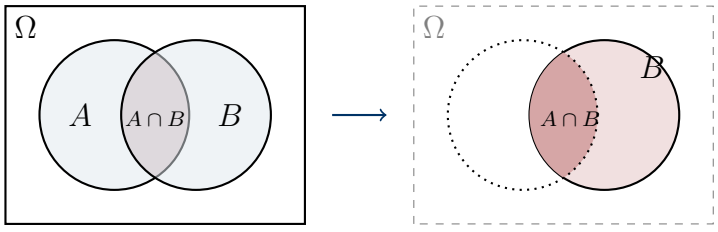


Figura 1.1: Al condicionar en B, el espacio muestral se reduce de Ω a B. Lo único relevante de A pasa a ser $A \cap B$.

Ahora bien, para que las probabilidades dentro de este nuevo universo B vuelvan a sumar 1, debemos *re-escalar* dividiendo por $P(B)$. Esto motiva la siguiente definición.

1.6.1 Definición

Definición 1.4 — Probabilidad condicional

Sean A y B dos eventos con $P(B) \neq 0$. La **probabilidad condicional de A dado B** se define como:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

La condición $P(B) \neq 0$ es esencial: no tiene sentido condicionar en un evento que no puede ocurrir, pues el universo reducido sería vacío.

Observación. *La probabilidad condicional $P(\cdot \mid B)$ es, ella misma, una función de probabilidad legítima sobre el espacio reducido: satisface los tres axiomas de Kolmogórov. En particular, $P(B \mid B) = 1$, lo que confirma que B actúa como el nuevo evento seguro.*

Demostración. Verificamos los tres axiomas para $P(\cdot \mid B)$:

A1 — No negatividad: Sea $A \in \mathcal{A}$. Como $A \cap B \subseteq B$ y P satisface A1, tenemos $P(A \cap B) \geq 0$. Como además $P(B) > 0$ por hipótesis:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \geq 0$$

A2 — Normalización:

$$P(\Omega \mid B) = \frac{P(\Omega \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1$$

donde usamos que $\Omega \cap B = B$.

A3 — Aditividad contable: Sean $A_1, A_2, \ldots \in \mathcal{A}$ eventos mutuamente excluyentes. Entonces los eventos $A_1 \cap B,\ A_2 \cap B, \ldots$ también son mutuamente excluyentes, pues:

$$(A_i \cap B) \cap (A_j \cap B) = (A_i \cap A_j) \cap B = \emptyset \cap B = \emptyset \quad \forall\, i \neq j$$

Aplicando A3 de Kolmogórov a la función P original:

$$P\left(\bigcup_{n=1}^{\infty} A_n \,\middle|\, B\right) = \frac{P((\bigcup_{n=1}^{\infty} A_n) \cap B)}{P(B)} = \frac{P(\bigcup_{n=1}^{\infty}(A_n \cap B))}{P(B)} = \frac{\sum_{n=1}^{\infty} P(A_n \cap B)}{P(B)} = \sum_{n=1}^{\infty} P(A_n \mid B)$$

donde usamos la distributividad de la intersección sobre la unión. ■

1.6.2 Regla de la multiplicación

Despejando $P(A \cap B)$ de la definición anterior obtenemos una identidad muy útil para calcular probabilidades de intersecciones:

Proposición 1.5 — Regla de la multiplicación

Sean A y B dos eventos con $P(B) \neq 0$. Entonces:

$$P(A \cap B) = P(A \mid B) \cdot P(B)$$

Demostración. Despejando $P(A \cap B)$ directamente de la Definición 1.4:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \implies P(A \cap B) = P(A \mid B) \cdot P(B)$$

■

Esta regla es especialmente útil en experimentos secuenciales —por ejemplo, extracciones sucesivas sin reposición— donde la probabilidad de cada etapa depende del resultado de la anterior.

1.7 Independencia de eventos

Al estudiar la probabilidad condicional, vimos que $P(A \mid B)$ cuantifica cómo el conocimiento de B modifica la probabilidad de A. Surge entonces una pregunta natural: ¿qué ocurre cuando ese conocimiento no modifica nada? Es decir, ¿cuándo saber que B ocurrió es completamente irrelevante para A?

Definición 1.5 — Independencia de eventos

Sean A y B dos eventos con $P(B) \neq 0$. Decimos que A y B son **independientes** si:

$$P(A \mid B) = P(A)$$

Es decir, el conocimiento de que B ocurrió no altera la probabilidad de A.

Observación. *Esta definición exige $P(B) \neq 0$ para que $P(A \mid B)$ esté definida. La proposición siguiente elimina esa restricción y constituye el criterio operacional que se usa en la práctica.*

Proposición 1.6 — Criterio de independencia

Sean A y B dos eventos. A y B son independientes si y solo si:

$$P(A \cap B) = P(A) \cdot P(B)$$

Demostración. Partimos de la definición de independencia $P(A \mid B) = P(A)$ y aplicamos la regla de la multiplicación (Proposición 1.5):

$$P(A \cap B) = P(A \mid B) \cdot P(B) = P(A) \cdot P(B)$$

■

Esta caracterización es más general que la definición porque no requiere $P(B) \neq 0$, y es simétrica en A y B — lo que hace evidente que si A es independiente de B, entonces B es independiente de A.

Observación. ***Independencia vs. exclusión mutua.*** *Estos conceptos son frecuentemente confundidos, pero son casi opuestos. Si A y B son mutuamente excluyentes ($A \cap B = \emptyset$) y ambos tienen probabilidad positiva, entonces:*

$$P(A \cap B) = 0 \neq P(A) \cdot P(B)$$

luego no son independientes. De hecho, la exclusión mutua implica la máxima dependencia posible: saber que A ocurrió hace imposible que ocurra B.

Proposición 1.7 — Independencia de complementos

Si A y B son independientes, entonces A^c y B^c también son independientes.

Demostración. Por la Proposición 1.6, basta mostrar que $P(A^c \cap B^c) = P(A^c) \cdot P(B^c)$.

Observamos primero que $A^c \cap B^c = (A \cup B)^c$ por las leyes de De Morgan. Luego, usando la Proposición 1.1 y la regla de la suma (Proposición 1.4):

$$P(A^c \cap B^c) = P((A \cup B)^c) = 1 - P(A \cup B)$$

$$= 1 - P(A) - P(B) + P(A \cap B)$$

Como A y B son independientes, $P(A \cap B) = P(A) \cdot P(B)$:

$$= 1 - P(A) - P(B) + P(A) \cdot P(B)$$

Factorizando:

$$= (1 - P(A))(1 - P(B)) = P(A^c) \cdot P(B^c)$$

■

1.8 Probabilidad total y Teorema de Bayes

1.8.1 Partición del espacio muestral

Definición 1.6 — Partición

Una colección de eventos $A_1, A_2, \ldots, A_k$ constituye una **partición** del espacio muestral Ω si satisface:

P1) Son **mutuamente excluyentes**: $A_i \cap A_j = \emptyset$ para todo $i \neq j$.

P2) Son **exhaustivos**: $\bigcup_{i=1}^{k} A_i = \Omega$.

Intuitivamente, una partición divide a Ω en piezas que no se solapan y que, en conjunto, lo cubren por completo. Exactamente uno de los eventos A_i ocurre siempre.

1.8.2 Teorema de probabilidades totales

A veces no es posible calcular $P(B)$ de manera directa, pero sí conocemos cómo se comporta B dentro de cada pieza de una partición. El teorema de probabilidades totales permite recomponer $P(B)$ a partir de esa información parcial.

La idea geométrica se aprecia en la figura 1.2: la partición $\{A_1, A_2, A_3\}$ divide a Ω en franjas, y el evento B queda automáticamente descompuesto en las piezas disjuntas $B \cap A_1$, $B \cap A_2$ y $B \cap A_3$.

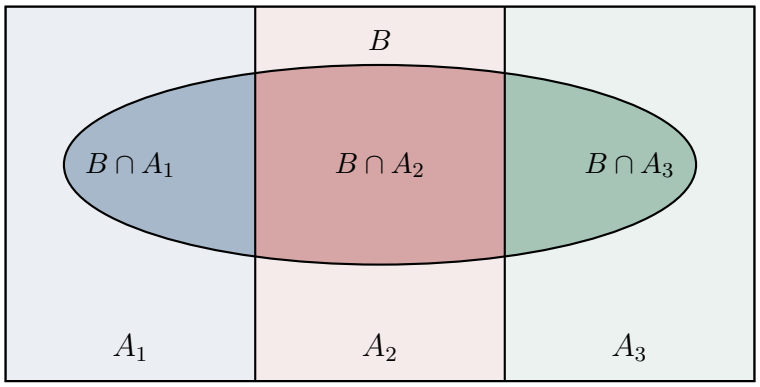


Figura 1.2: La partición $\{A_1, A_2, A_3\}$ descompone al evento B en las piezas disjuntas $B \cap A_i$.

Teorema 1.1 — Probabilidades totales

Sea $A_1, A_2, \ldots, A_k$ una partición de Ω con $P(A_i) > 0$ para todo i. Entonces, para cualquier evento B:

$$P(B) = \sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)$$

Demostración. La demostración consta de tres pasos.

Paso 1 — Descomposición de B. Como los A_i son exhaustivos, $B = B \cap \Omega = B \cap \left(\bigcup_{i=1}^{k} A_i\right)$. Por distributividad:

$$B = \bigcup_{i=1}^{k} (B \cap A_i)$$

Paso 2 — Aditividad. Como los A_i son mutuamente excluyentes, también lo son los eventos $B \cap A_i$:

$$(B \cap A_i) \cap (B \cap A_j) = B \cap (A_i \cap A_j) = B \cap \emptyset = \emptyset \quad \forall\, i \neq j$$

Aplicando el axioma A3:

$$P(B) = \sum_{i=1}^{k} P(B \cap A_i)$$

Paso 3 — Regla de la multiplicación. Aplicando la Proposición 1.5 a cada término:

$$P(B \cap A_i) = P(B \mid A_i)\, P(A_i)$$

Sustituyendo:

$$P(B) = \sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)$$

■

Observación. *El teorema puede leerse como un **promedio ponderado**: la probabilidad total de B es el promedio de las probabilidades condicionales $P(B \mid A_i)$, donde cada una se pondera por el "peso" $P(A_i)$ de su pieza en la partición.*

1.8.3 Teorema de Bayes

El teorema de probabilidades totales responde a la pregunta: ¿cuál es la probabilidad de B? El teorema de Bayes responde la pregunta *inversa*: si observamos que B ocurrió, ¿cuál es la probabilidad de que la pieza responsable haya sido A?

Versión simple: dos eventos

Comencemos con el caso más sencillo, en que la partición consta de un evento A y su complemento A^c.

Teorema 1.2 — Regla de Bayes (forma simple)

Sean A y B dos eventos con $P(A) > 0$ y $P(B) > 0$. Entonces:

$$P(A \mid B) = \frac{P(B \mid A)\, P(A)}{P(B)}$$

Demostración. Por la definición de probabilidad condicional aplicada a $P(A \mid B)$, y luego la regla de la multiplicación en el numerador:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B \mid A)\, P(A)}{P(B)}$$

■

Esta forma es la más fácil de memorizar y expone la idea esencial: el teorema **invierte** la condicional, permitiéndonos pasar de $P(B \mid A)$ a $P(A \mid B)$.

Versión general: una partición

Cuando disponemos de una partición completa $A_1, \ldots, A_k$ y no conocemos $P(B)$ directamente, podemos expandir el denominador mediante el teorema de probabilidades totales. Esto da la forma general.

Teorema 1.3 — Regla de Bayes (forma general)

Sea $A_1, A_2, \ldots, A_k$ una partición de Ω con $P(A_i) > 0$ para todo i, y sea B un evento con $P(B) > 0$. Entonces, para cada j:

$$P(A_j \mid B) = \frac{P(B \mid A_j)\, P(A_j)}{\displaystyle\sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)}$$

Demostración. Partimos de la forma simple aplicada a A_j:

$$P(A_j \mid B) = \frac{P(B \mid A_j)\, P(A_j)}{P(B)}$$

y reemplazamos el denominador $P(B)$ por su expresión según el Teorema 1.1 de

probabilidades totales:

$$P(A_j \mid B) = \frac{P(B \mid A_j)\, P(A_j)}{\sum_{i=1}^{k} P(B \mid A_i)\, P(A_i)}$$

■

Observación. *La forma simple es el caso particular de la general con $k = 2$, tomando $A_1 = A$ y $A_2 = A^c$. En efecto, el denominador se convierte en $P(B \mid A)\, P(A) + P(B \mid A^c)\, P(A^c) = P(B)$.*

Interpretación geométrica

El teorema de Bayes admite una lectura geométrica muy intuitiva. Mientras el teorema de probabilidades totales sumaba las piezas $B \cap A_i$ para reconstruir B, Bayes hace lo contrario: **fija su atención dentro de** B y pregunta qué fracción de B corresponde a cada franja A_j.

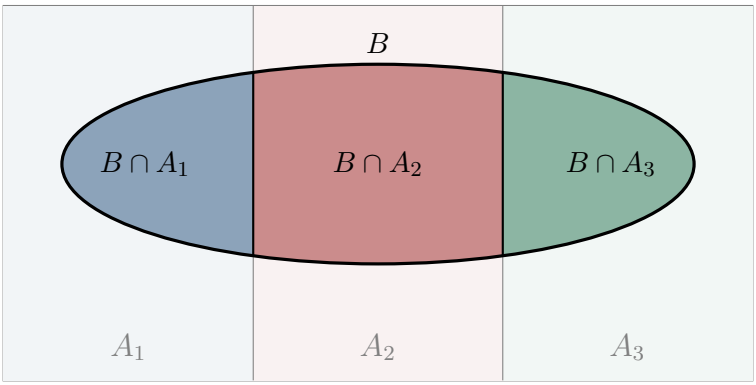


Figura 1.3: Interpretación geométrica de Bayes: una vez que sabemos que el resultado cayó en B (contorno grueso), este se convierte en el nuevo universo. La probabilidad $P(A_j \mid B)$ es la fracción de B ocupada por $B \cap A_j$.

En la figura 1.3, el espacio Ω y las franjas A_i quedan en segundo plano: una vez condicionados en B, lo único relevante es el interior de la elipse. Geométricamente:

$$P(A_j \mid B) = \frac{\text{área de } B \cap A_j}{\text{área total de } B}$$

Esto explica por qué $P(A_j \mid B)$ puede diferir tanto de $P(A_j)$: la primera mide la proporción de A_j *dentro de* B, mientras que la segunda la mide dentro de todo Ω. Si B se concentra desproporcionadamente en una franja, condicionar en B redistribuye el peso hacia esa franja.

Observación. *El teorema de Bayes es la herramienta formal que permite* ***invertir*** *condicionales: pasar de $P(B \mid A_j)$ —lo que típicamente conocemos— a $P(A_j \mid B)$*

—lo que deseamos inferir. En el lenguaje bayesiano, $P(A_j)$ es la ***probabilidad a priori*** *(lo que sabemos antes de observar) y $P(A_j \mid B)$ es la* ***probabilidad a posteriori*** *(lo que sabemos después de observar la evidencia B).*

El teorema de Bayes nació de una pregunta filosófica, no técnica. En su *Investigación sobre el entendimiento humano*, Hume había planteado que la inducción carece de justificación lógica: por más veces que hayamos observado que el sol sale cada mañana, ninguna cantidad de observaciones pasadas garantiza lógicamente que saldrá mañana. Si esto es así, el conocimiento empírico —incluida toda la ciencia newtoniana— descansaría sobre una base irracional.

Thomas Bayes, ministro presbiteriano inglés y contemporáneo de Hume, buscaba una respuesta rigurosa a ese problema. La encontró escondida dentro de la definición de probabilidad condicional que ya existía: su fórmula revela que conocer $P(B \mid A)$ es suficiente para inferir $P(A \mid B)$ —pasar del efecto a la causa, de la evidencia observable a la hipótesis no observable. No se necesita certeza lógica para aprender racionalmente; basta un mecanismo coherente de actualización de creencias, y ese mecanismo es la fórmula de Bayes.

A más evidencia acumulada, más convergen las probabilidades a posteriori hacia la verdad, independientemente de cuál fuera la creencia inicial. Es una respuesta pragmática y matemáticamente precisa al escepticismo de Hume. Por eso el teorema —publicado póstumamente en 1763 por su amigo Richard Price— aparece hoy en dominios tan distintos como el diagnóstico médico, los filtros de spam, la navegación autónoma y el aprendizaje automático: en todos ellos subyace el mismo problema que preocupaba a Hume y a Bayes, esto es, dado lo que observo, ¿qué puedo inferir sobre lo que no veo?

Tema 2

Variable aleatoria discreta

2.1 ¿Qué es una variable aleatoria?

2.2 Variable aleatoria discreta

2.3 Función de distribución de probabilidad

2.4 Función de distribución acumulada

2.5 Valor esperado y varianza

2.5.1 Valor esperado

2.5.2 Varianza

2.6 Distribuciones importantes

2.6.1 Distribución Binomial

2.6.2 Distribución de Poisson

Tema 3

Variable aleatoria continua

3.1 De lo discreto a lo continuo

3.2 Función de densidad de probabilidad

3.3 Función de distribución acumulada

3.4 Distribución Normal

3.4.1 ¿Por qué $\sqrt{2\pi}$?

3.5 Teorema del Límite Central

Tema 4

Muestreo y distribución de muestreo

4.1 Población, muestra y parámetro

4.2 Estadístico y estimador

4.3 Distribuciones de muestreo

4.3.1 Distribución t de Student

4.3.2 Distribución Chi-cuadrado χ^2

4.3.3 Distribución F de Fisher

Tema 5

Introducción a la inferencia estadística

5.1 Estimación por intervalos de confianza

5.2 Pruebas de hipótesis

5.2.1 El procedimiento de cinco pasos

5.2.2 Prueba para la media con varianza conocida

5.2.3 Prueba para la media con varianza desconocida